
Titulo del TFG
Title in english



Trabajo de Fin de Grado
Curso 2025–2026

Autor
Eva Paula Mik

Director
Ismael Sagredo Olivenza

Colaborador
Colaborador no definido. Usa \colaboradorPortada

Grado en Desarrollo de Videojuegos
Facultad de Informática
Universidad Complutense de Madrid

Titulo del TFG
Title in english

Trabajo de Fin de Grado en Desarrollo de Videojuegos

Autor
Eva Paula Mik

Director
Ismael Sagredo Olivenza

Colaborador
Colaborador no definido. Usa \colaboradorPortada

Convocatoria: *Junio 2026*

Grado en Desarrollo de Videojuegos
Facultad de Informática
Universidad Complutense de Madrid

27 de abril de 2026

Dedicatoria

*A toda la gente que nos ha hecho llegar hasta
aquí,
un besazo.
A todos los que han estado a nuestro lado.*

Agradecimientos

Os amo!

Mik

Os amo!

Pau

Os amo!

Eva

Resumen

Titulo del TFG

Nuestro estudio se basa en la comparativa de distintos modelos de IA para la frente a la simulación de físicas costosas en proyectos 3D en motores de videojuegos. Para ello creamos una simulación en Unity con un objeto con componente Cloth y distintos colliders que interactuasen con ella. Tras generar los datasets, probamos distintos modelos de IA e integramos los datos. Finalmente exportamos a unity con Sentis y realizamos comparativas teniendo en cuenta GPU, CPU. Observamos que el modelo que mejores resultados obtuvo en cuanto a tal métrica fue X.

Palabras clave

Inteligencia Artificial, Simulación física, Unity, Videojuegos, Optimización, PyTorch, ML

Abstract

Title in english

We need to do this.

Keywords

We need to do this.

Índice

1. Introducción	1
1.1. Motivación	1
1.2. Objetivos	2
1.3. Plan de trabajo	2
1.4. Metodología	3
1.5. Estructura de la memoria (propuesta)	4
2. Estado de la Cuestión	5
2.1. Simulación física en videojuegos	5
2.1.1. Motores de física	6
2.1.2. Motores de videojuegos	6
2.2. Simulación de telas	7
2.2.1. ¿Qué es Cloth?	7
2.2.2. El problema de optimización	7
2.2.3. Soluciones	8
2.3. Inteligencia Artificial en videojuegos	8
2.3.1. Librerías	9
2.3.1.1. Pytorch	9
2.3.1.2. ONNX	9
2.3.1.3. Sentis	9
2.3.2. Modelos de optimización de telas	9
2.3.2.1. Towards Generalized Position-Based Dynamics	9
2.3.2.2. Neural Cloth Simulation	10
2.3.2.3. PBNS: Physically Based Neural Simulation for Un-supervised Garment Pose Space Deformation	10
2.3.2.4. Subspace Neural Physics: Fast Data-Driven Interactive Simulation	10
2.3.2.5. Cloth and Skin Deformation with a Triangle Mesh Based Convolutional Neural Network	11
2.3.3. DeepSD: Real-time Cloth Simulation with Deep Learning	12
2.3.3.1. SNUG	12

2.3.3.2. HOOD: Hierarchical Graphs for Generalized Modeling of Clothing Dynamics	12
3. Descripción del Trabajo	15
3.1. SimulacionUnity	15
3.2. Dataset	15
3.3. EntrenamientoPython	15
3.4. SimulacionUnity	15
3.5. ModelosFuncionales	15
3.6. PruebaTesters	15
4. Conclusiones y Trabajo Futuro	17
4.1. Conclusiones	17
4.1.1. Conclusiones de la búsqueda de datasets	17
4.1.2. Conclusiones de la blablabla	17
4.1.3. Limitaciones	17
4.2. Trabajo Futuro	17
Contribuciones Personales	19
Bibliografía	21
A. Carteles para la generación del dataset	23
B. Formulario de recogida de citas	27
C. Resultados de los distintos modelos CNN	29
C.1. Intervalo 0.2s	29
C.2. Intervalo 0.4s	31
C.3. Intervalo 0.6s	32
C.4. Intervalo 0.8s	34
C.5. Intervalo 1.0s	35
Glosario	37
Licencia de uso del documento	39
Licencia de uso del código fuente	41

Índice de figuras

1.1. Diagrama de Gantt del proyecto	3
A.1. Cartel colgado en la facultad de informática	23
A.2. Cartel colgado en redes sociales	24
A.3. Cartel colgado en pantallas de la facultad	25
B.1. Formulario de recogida de citas (primera parte)	27
B.2. Formulario de recogida de citas (segunda parte)	28
C.1. Esquema del modelo CNN con 0.2s de intervalo	29
C.2. Matriz de confusión del modelo CNN con 0.2s de intervalo	30
C.3. Gráfico de entrenamiento del modelo CNN con 0.2s de intervalo (mejor val_accuracy = 0.28777)	30
C.4. Esquema del modelo CNN con 0.4s de intervalo	31
C.5. Matriz de confusión del modelo CNN con 0.4s de intervalo	31
C.6. Gráfico de entrenamiento del modelo CNN con 0.4s de intervalo (mejor val_accuracy = 0.49473)	32
C.7. Esquema del modelo CNN con 0.6s de intervalo	32
C.8. Matriz de confusión del modelo CNN con 0.6s de intervalo	33
C.9. Gráfico de entrenamiento del modelo CNN con 0.6s de intervalo (mejor val_accuracy = 0.44952)	33
C.10. Esquema del modelo CNN con 0.8s de intervalo	34
C.11. Matriz de confusión del modelo CNN con 0.8s de intervalo	34
C.12. Gráfico de entrenamiento del modelo CNN con 0.8s de intervalo (mejor val_accuracy = 0.40583)	35
C.13. Esquema del modelo CNN con 1.0s de intervalo	35
C.14. Matriz de confusión del modelo CNN con 1.0s de intervalo	36
C.15. Gráfico de entrenamiento del modelo CNN con 1.0s de intervalo (mejor val_accuracy = 0.56002)	36

Índice de tablas

Introducción

En los últimos años, el aumento en el tamaño y la complejidad en los videojuegos ha supuesto la imprescindible optimización y automatización de diversos aspectos de su desarrollo, tanto en el ámbito del renderizado como en la lógica interna de los sistemas. Particularmente, en la evolución de entornos 3D con el objetivo de obtener gráficos más detallados, lo que conlleva un incremento significativo en el coste computacional.

Elementos como el cabello, los fluidos o las telas requieren una carga de cálculos que dificulta el alcance de comportamientos realistas en tiempo real, lo que afecta negativamente al rendimiento de los videojuegos, en especial en términos de tasa de fotogramas. En consecuencia, se ha producido un avance en la recogida de técnicas basadas en ML y DL en la industria de los videojuegos.

Empresas pioneras en hardware y software han desarrollado tecnologías para mejorar el rendimiento gráfico incorporando esta clase de algoritmos. Entre ellas destacan: NVIDIA con DLSS (Deep Learning Super Sampling), donde tenemos el Resident Evil Requiem que usa DLSS 4; y AMD con FSR (FidelityFX Super Resolution). Asimismo, varias compañías lo incorporan en el propio curso del juego simulando comportamientos y mecánicas como EA (FIFA), Embark Studios (Arc Raiders) o Ubisoft con sus múltiples líneas de investigación con la IA.

En este contexto, la aplicación de modelos de aprendizaje automático en simulaciones físicas se presenta de forma prometedora.

1.1. Motivación

Las simulaciones físicas no solo se dan en sistemas de alto rendimiento con hardware especializado y gráficas delicadas, sino que también deben ejecutarse en máquinas con recursos más limitados. Esta necesidad surge por el crecimiento de distintas plataformas, incluyendo a su vez otros tipos de dispositivos, como los móviles.

En motores de videojuegos como Unity, más utilizado por desarrolladores indie, se utiliza principalmente la CPU para calcular físicas, lo que puede convertirse en un cuello de botella cuando se pasa a escenarios más complejos. Esto conllevaría, por ejemplo, a simplificar modelos, reducir la calidad de las animaciones o limitar la

interacción física, afectando al desarrollo del producto y la experiencia de usuario. Creemos que incorporar la IA puede ser clave para este reto técnico, permitiendo agilizar el proceso en máquinas de menor rendimiento.

Frente a esta problemática, el uso de modelos de aprendizaje automático ofrece una alternativa para aproximar un comportamiento físico detallado con un menor coste computacional en tiempo de ejecución. Este enfoque implica una carga elevada al inicio de entrenamiento de modelos, compensado con una ejecución eficiente en los próximos pasos. Cabe destacar que, si bien utilizar la IA es sacrificar que las físicas sean precisas, creemos que esto es caer en la falacia de la inmersión [Salen y Zimmerman \(2004\)](#). Nuestro objetivo es lograr simulaciones visualmente verosímiles que mantengan una percepción fiel de realismo, adoptando así una perspectiva cercana al diseño de videojuegos. Por ello, se ha escogido Cloth, simulación de telas, como caso de estudio debido a que representa un equilibrio adecuado entre accesibilidad tecnológica, complejidad física e impacto visual. De esta manera, realizaremos un análisis tanto técnico como perceptivo.

1.2. Objetivos

El objetivo general de este proyecto es la implementación de un modelo de IA que permita replicar el movimiento en tiempo real de una tela en un motor de videojuegos con baja latencia. Para cumplir con este objetivo, se plantean las siguientes metas durante el desarrollo del proyecto:

1. Generar una animación de una tela y un colisionador que varíe su trayectoria en cada ejecución de la escena.
2. Generar y procesar datasets con la información relevante de la tela respecto a su entorno y colisionador.
3. Implementar, entrenar y evaluar los distintos modelos de aprendizaje automático, tales como redes neuronales (LSTM, CNN y RNN, GNN).
4. Analizar y comparar los resultados visuales de los distintos modelos.

1.3. Plan de trabajo

El desarrollo del proyecto se llevará a cabo en el periodo lectivo del curso 2025-2026. Dados los objetivos del apartado anterior, la planificación se divide en las siguientes iteraciones:

- **Iteración 0:** En esta etapa se concretan los objetivos reales de la investigación y se establece la planificación del trabajo respecto a la propuesta inicial.
- **Iteración 1:** Etapa de preparación, donde se cumplirán los siguientes subobjetivos para implementar un sistema de simulación adecuado para ser procesado por los modelos en un futuro.

- **Iteración 1.1:** Se realizará una investigación de trabajos relacionados con nuestro tópico, relevante para dirigir el desarrollo de nuestros experimentos. Se analizarán distintas alternativas y se decidirá cuales resultarán más interesantes de replicar, se definirán qué tipo de datos deberemos recopilar para el entrenamiento y qué tipo de redes podrán llevarlo a cabo.
 - **Iteración 1.2:** Se creará una simulación básica en Unity y un sistema de registro de datos relevantes a la tela.
- **Iteración 2:** Se establecerá un entorno de trabajo para el entrenamiento de los datos recopilados. Se generará un pipeline claro en el que se integre la simulación de recogida de datos, su limpieza y posterior uso para entrenar el modelo y, finalmente, la incorporación de este al entorno de simulación. Para poder asegurarnos del correcto funcionamiento de este sistema se generará un modelo simple y se comprobará que el pipeline es correcto. En esta fase se comenzarán a redactar los primeros capítulos de la memoria.
 - **Iteración 3:** Con una base sólida ya montada, se aumentará la complejidad y, por consiguiente, el coste de la simulación. Se implementarán distintos modelos y se llevarán a cabo pruebas con todos ellos para asegurarse de su fiabilidad.
 - **Iteración 4:** Si las anteriores iteraciones funcionan de manera correcta esta última no tendrá ninguna carga de implementación. Se alcanzará la última meta definida: hacer distintas pruebas entrenando los modelos ya desarrollados, sacar métricas de todos ellos para poder hacer comparaciones y hacer un análisis exhaustivo de estos resultados, sacando así las conclusiones de la investigación.

El desarrollo de las tareas y su planificación se puede ver en la figura 1.1.




Figura 1.1: Diagrama de Gantt del proyecto

1.4. Metodología

Para el desarrollo de esta investigación se emplearán herramientas de libre acceso y uso gratuito, con el objetivo de facilitar la reproducibilidad de los resultados obtenidos.

El entorno de desarrollo principal será Windows 11, al tratarse del sistema operativo utilizado por el equipo de trabajo y extendido entre los potenciales usuarios. La simulación de la tela, así como la integración del modelo de inteligencia artificial, se llevarán a cabo en Unity (versión 6000.3.2f1, correspondiente a una versión de soporte a largo plazo). En cuanto a los lenguajes de programación, se empleará C# para el desarrollo dentro de Unity, incluyendo la generación de la simulación y la recopilación de datos, mientras que se utilizará Python, empleando Pytorch,v para el entrenamiento de los modelos de aprendizaje automático. La integración de los modelos entrenados en el entorno de ejecución se realizará a traves de Unity Sentis.

Para la gestión del código fuente y el trabajo colaborativo se utilizará GitHub, basado en el sistema de control de versiones Git. Asimismo, se empleará la herramienta GitHub Projects para la planificación, asignación y seguimiento de tareas. Como herramientas adicionales, se utilizará Google Drive para el almacenamiento de documentación, apuntes de reuniones y materiales de trabajo puntuales, y Discord para la coordinación del equipo mediante reuniones online, además de encuentros presenciales semanales.

1.5. Estructura de la memoria (propuesta)

Capítulo 2

Estado de la Cuestión

En este capítulo se presenta una breve descripción del desarrollo de las simulaciones físicas en videojuegos, así como el hardware y software que ha hecho que esta evolución sea posible, se presenta la simulación de telas en específico, las maneras que existen de implementarla, los problemas de optimización que estas suponen y los avances en modelos de IA que permiten imaginar otras soluciones.

2.1. Simulación física en videojuegos

Basta con remontarse a la creación del Pong en 1972, para darse cuenta de la importancia que las simulaciones físicas han tenido en el ámbito de los videojuegos desde el primer momento. Al fin y al cabo, las físicas permiten crear situaciones del gameplay que no están predefinidas, enriqueciendo así la experiencia del jugador.

En los inicios del desarrollo de videojuegos, las técnicas más rudimentarias para implementar estas físicas incluían:

- **La prerenderización:** Dada la capacidad de cómputo con la que solían contar las máquinas, era imposible hacer todos los cálculos físicos en tiempo real, por lo que las interacciones físicas podían diseñarse previamente para parecer realistas. [Templet \(2021\)](#)
- **La implementación forzada de cada elemento:** El comportamiento de cada elemento podía ser implementado únicamente para él, en vez de seguir unas normas físicas generales. Por ejemplo, en el caso de un proyectil, podía codificarse calculando su trayectoria y velocidad en pocas líneas de código.

Estos métodos eran claramente limitados en la precisión que ofrecían, y quedaba clara la necesidad de una solución más general y reproducible. El mismo Ian Millington menciona en su libro *Game Physics Engine Development* [Millington \(2007\)](#) el juego Exile, creado por Peter Irvin y Jeremy Smith. Si bien este juego fue publicado en 1988 ya contaba con conservación del momento en colisiones, gravedad, fuerzas como el viento o explosiones. Lo resaltamos como uno de los primeros juegos que

cuenta con un motor de físicas completo.

2.1.1. Motores de física

La creación de motores de física completos aportó a los videojuegos escalabilidad en su gameplay, manteniendo la coherencia de sus elementos físicos. Esto último resulta imprescindible para la inmersión del jugador. Hecker (2000) En los años 90, con la popularidad del 3D y gráficos cada vez más avanzados, la física era la siguiente área en la que marcar la diferencia. La evolución de estos motores era inevitable. Todos estos cálculos en tiempo real suponían además una gran carga para la CPU, planteando así dos grandes retos: el avance de los motores físicos cada vez más precisos/realistas y potentes, y, por otro lado, la optimización del hardware para llegar a la demanda computacional que esto suponía. Mirar incluir algo más concreto d juegos, primeros avances con motores? Paul et al. (2012)

En este contexto nacen los primeros motores físicos. En 2002, se funda Ageia Technologies, responsable de la creación del primer procesador de física dedicado para ordenadores, denominado PhysX PPU (Physics Processing Unit), así como del motor PhysX, que sigue siendo líder en la industria a día de hoy. Posteriormente, NVIDIA Corporation, conocida por su papel en la producción de GPUs, adquiere Ageia, impulsando el cálculo de físicas en GPU. <https://developer.nvidia.com/physx-sdk> Esto sumado a la dificultad de penetrar en el mercado del hardware hace que la producción de PPU's quede obsoleta. Por otro lado, Intel adquiere Havok https://media.gdcdvault.com/GD_Mag_Archives/GDM_October_2000.pdf, otro de los primeros motores de físicas, en 2007, cancelando el programa HavokFX que pretendía llevar el cálculo de físicas a la GPU. Posteriormente es adquirido por microsoft en 2015, que el 2016 empieza a trabajar en DirectPhysics, ????? ns que ha pasado en esto ??????. Por lo que hoy en día la carga computacional quede entre la CPU y GPU, que discutiremos durante el desarrollo de este proyecto.

2.1.2. Motores de videojuegos

Los motores físicos, sumados a otros elementos análogos como los motores de renderizado, de sonido... crean el software al que nos referimos como motores de videojuegos. Unreal Engine, Unity y los motores propios de los grandes estudios dominan el mercado. https://app.sensortower.com/vgi/assets/reports/The_Big_Game_Engines_Report_of_2025.pdf

Unreal es un motor de videojuegos creado por Epic Games en 1998. Desde ... y hasta la introducción de Chaos Physics en su versión más reciente, la 5.7, Unreal usaba PhysX. En lo que a este proyecto respecta chaos plantea nuevos avances en la simulación de telas muy interesantes que se comentarán más adelante.

Sin embargo,UNITY (justificamos por qué unity: libre acceso, motor principal usado para desarrollo?) Unity es un motor de videojuegos creado por Unity

Technologies en 2005. Utiliza como motor físico: PhysX. <https://docs.unity3d.com/Manual/physics-integrations.html> Extensiones accesibles , ej. Sentis, se indagará más adelante.

2.2. Simulación de telas

Entendemos los objetos deformables o soft-bodies como aquellos que no son rígidos. Así como en los objetos rígidos podemos simular su movimiento sabiendo su motion y centro de masa, para los objetos deformables necesitamos tener en cuenta todas las partículas y propiedades físicas que lo componen. Entre estos encontramos elementos como las telas, el agua o el viento [Kenny Erleben \(2005\)](#).

2.2.1. ¿Qué es Cloth?

Cloth es un componente que nos proporciona Unity3D que funciona junto al Skinned Mesh Renderer para simular telas. Está basado en Cloth de PhysX y fue incorporado con el objeto de poder disponer de ropa para personajes. Tiene múltiples propiedades como la resistencia a la flexión, rigidez, damping, uso de gravedad...

Se trata la tela como una malla de partículas conectadas por restricciones. El Skinned Renderer calcula las transformaciones basándose en una malla de baja resolución sobre la que realiza los movimientos en los vértices, que dinámicamente se aplican en la malla real y obtenemos la simulación visual. Un constraint de distancia máxima 0 significa que está fijo en el espacio y que no se calculan sus deformaciones. La cloth cuenta con capacidad de colisionar internamente y con dos tipos de colliders externos: cápsulas o esferas. Cualquier objeto externo con el que se quiera colisionar tendrá que ser un conjunto de estos colliders.

Un solver es un algoritmo computacional que se encarga de predecir el comportamiento del objeto deformable en renderizados gráficos y simulaciones físicas. Encontramos infinitos tipos de solvers. Los primeros solvers se basan en los algoritmos que emplean la fuerza bruta: realizan cálculos en masa para sistemas de muelles (MSS). Los solvers más actuales resultan en el PBD proceso iterativo que proyecta las posiciones de las partículas sobre un "espacio de restricciones" [Müller et al. \(2007\)](#).

El solver de PhysX se basa en PBD, es decir, trabaja directamente sobre las posiciones. Encontramos también XPBD [Macklin et al. \(2016\)](#) , una versión extendida que puede incorporarse en proyectos.

2.2.2. El problema de optimización

La simulación de cloth en tiempo real es un problema recurrente, que aún continúa buscando la optimización a día de hoy. Debido a la alta carga computacional, los frames decaen inmediatamente en cuanto se complica o aumenta la geometría de la tela. Esto dificulta enormemente el realismo, y resulta un gran impedimento

en entornos dónde se requiere un alto framerate como son los juegos VR frente al motion sickness.

Mientras que el Cloth de PhysX puede delegar la simulación a GPUs compatibles con CUDA, el Cloth integrado por defecto en Unity realiza todo su trabajo en la CPU, lo cual ralentiza mucho la ejecución.

2.2.3. Soluciones

Encontramos varios tipos de soluciones para la optimización de la simulación de telas:

- Optimización por CPU: encontramos la extensión de Obi Cloth [Method \(2019\)](#), que aprovecha el sistema de Jobs de Unity para paralelizar la simulación y acelerar la simulación sin salir de la CPU. Es uno de los paquetes más populares para solucionar este problema.
- Paralelización en GPU: a través de shaders se delega la fuerza de cálculo del skinning en la GPU. Encontramos diferentes estudios que aportan diferentes enfoques para la optimización: Jim Hugunin realiza una investigación para alcanzar altas resoluciones y evitar colisiones en las mallas [Jim Hugunin \(2016\)](#), mientras que otros se centran en la mejora de rendimiento pura para adaptar simulaciones a entornos VR [Va et al. \(2021\)](#).
- Entrenamiento con IA: el enfoque más actual de la resolución de simulaciones complejas como Cloth es la Inteligencia Artificial. Se entrenan modelos de ML y DL con los datos de las mallas animadas o en simulación, con lo que obtenemos más adelante mejor rendimiento en tiempo real. Se sacrifica memoria y tiempo de entrenamiento para obtener mejores y mucho más rápidas simulaciones de tela en escena. Actualmente, nos encontramos en el paso de investigación a implementación en grandes empresas: Unreal ya proporciona una simulación de tela a través de aprendizaje automático [Games \(2025\)](#), en el que destaca su realismo. Aún así, cuenta con limitaciones al basarse un NearestNeighborSearch: él sistema es capaz de predecir detalles como arrugas pero no movimiento dinámico como ondulaciones o drapeados'. En la próxima sección detallaremos las numerosas investigaciones recientes que abarcan aspectos desde la reproducción de arrugas, el compromiso entre calidad, coste y rendimiento hasta colisiones y penetraciones en las mallas.

2.3. Inteligencia Artificial en videojuegos

Como se ha introducido previamente, en la industria del videojuego, así como en muchas otras, las miradas están fijadas en la inteligencia artificial. Entre las muchas aplicaciones que se le están dando, en este apartado se presentan los elementos más relevantes para el desarrollo de este proyecto.

2.3.1. Librerías

Las librerías Pytorch, ONNX y Sentis, han sido indispensables para entrenar los modelos de IA y conectarlos a la simulación en Unity.

2.3.1.1. Pytorch

Pytorch es una de las librerías de código abierto que permite escribir redes neuronales propias. Los tensores, matrices multi-dimensionales análogas a los NumPy arrays de Python, permiten optimizar las redes tanto para el uso de CPU como de GPU. [Contributors \(2026\)](#) Suele ser la más elegida en entornos académicos, ya que permite prototipado rápido y entrenamiento dinámico. Fue originalmente desarrollado por Facebook, y todavía cuenta con una enorme comunidad de desarrolladores.

2.3.1.2. ONNX

ONNX es un formato creado para representar modelos de aprendizaje automático. [Project \(2026\)](#) También fue introducido por Facebook y Microsoft en 2017, con el objetivo de facilitar el cambio de entornos de trabajo en aprendizaje automático.

2.3.1.3. Sentis

Sentis es una librería de inferencia de redes neuronales para Unity, predecesora introducida en el 2023 de la librería Barracuda. Permite importar modelos de redes neuronales entrenados a Unity y ejecutarlos en tiempo real tanto con la CPU como con la GPU. [Technologies \(2026\)](#)

2.3.2. Modelos de optimización de telas

Avance de simulación Towards Generalized Position-Based Dynamics

La optimización de simulaciones con redes neuronales cuenta ya con un amplio recorrido, en este apartado se describen los estudios más destacados de los últimos años. Son también inspiración directa para la implementación de nuestros experimentos, con el objetivo de descubrir cuales de estas técnicas son verdaderamente aplicables a menor escala (q tal darle un aproach d no se puede hacer la mitad por q somos indies)

2.3.2.1. Towards Generalized Position-Based Dynamics

- Partiendo de sus nuevas ecuaciones para el calculo fisico: citechaudhary2025towards we iterate over each individual force term in the system (for example, the force due to one element on its adjacent vertices in a FEM mesh), and update it implicitly using a low-dimensional Newton solve on the element strain. Our proposed scheme is expressive enough to apply to any nonlinear energy-based elastic model

is extremely popular in interactive applications due to its stability, performance, and ease of implementation. Unlike most other iterative techniques used for dynamics simulation, PBD is a so-called “dual” descent method [Macklin et al. 2020]: it

iterates over the forces in the system, and updates the effect of each force one at a time, rather than updating vertex positions as in “primal” methods. All forces must be expressed as constraints and computed through Lagrange multipliers

d_i is the displacement caused by each force. position-based dynamics can be viewed as a way to iteratively update d_i for each force, and thus obtain the solution x

- Esto permite implementar: Hablan de data driven simulations pero son configuraciones pre grabadas POSES podemos comentarlo como machine learning (en tmbn lo q hace cahos d unreal) En hood aparecen otros paper q tmbn hablan d esto: Learned Deformation Models [20, 30, 39, 42] [20] Peng Guan, Loretta Reiss, David A Hirshberg, Alexander Weiss, and Michael J Black. Drape: Dressing any person. ACM Transactions on Graphics (ToG) [30] Qianli Ma, Jinlong Yang, Anurag Ranjan, Sergi Pujades, Gerard Pons-Moll, Siyu Tang, and Michael J Black. Learning to dress 3d people in generative clothing. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 6469–6478, 2020 [39] Chaitanya Patel, Zhouyingcheng Liao, and Gerard Pons Moll. Tailornet: Predicting clothing in 3d as a function of human pose, shape and garment style. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 7365–7375, 2020. [42] Igor Santesteban, Miguel A Otaduy, and Dan Casas. Learning-based animation of clothing for virtual try-on. Computer Graphics Forum, 38(2):355–366, 2019

2.3.2.2. Neural Cloth Simulation

Subspace, Recurrent encoder-decoder.

ANTERIORMENTE tmbn hemos mencionado CAHOS UNREAL q hace lo mismo....

2.3.2.3. PBNS: Physically Based Neural Simulation for Unsupervised Garment Pose Space Deformation

MLP (LBS, relu) Pose based? Pau Pau Pau

2.3.2.4. Subspace Neural Physics: Fast Data-Driven Interactive Simulation

(tengo que reducirlo pero buen + mention kolmogorov or verlet)

Este desasallo de la unidad de investigación Ubisoft La Forge implementa la primera técnica que incorpora reducción de modelo o el uso de subespacios con colisiones con objetos externos en la cloth. El estudio se centra en conseguir un balance entre el rendimiento en tiempo real y el coste y memoria necesarios para realizar el pre-cómputo. Se extraen las posiciones de los vértices de una simulación hecha en Maya. Las posiciones de los vértices se aplanan en un vector, y se construye otro vector plano con los parámetros necesarios como posición del suelo, valor del viento, o collisionadores con la tela. Se aplica un PCA denotando cuántos ejes de deformación de la tela se tienen en cuenta (64, 128, 256, siendo este último el que conserva casi el mismo nivel de detalle que la simulación original). (especificar la fórmula del PCA?)

El modelo que predice la posición del vértice tiene en cuenta los dos frames anteriores y los colisionadores de ese frame:

$$z_t = \alpha \odot z_{t-1} + \beta \odot (z_{t-1} - z_{t-2})$$

La versión extendida:

$$z_t = \bar{z}_t + \bar{z}_t \odot z_{t-1} w_t^T$$

(la que tiene en cuenta las colisiones externas).

Aquí dice una cosa importante sobre el error que hay que corregir usando window frames: *We repeat this training procedure on mini-batches of size 16, using overlapping windows of size 32, for around 100 epochs or until training converges. We use a learning rate of 0.0001, and a learning rate decay ratio of 0.999. We use a noise standard deviation σ of 0.01, which we found by visualizing the result of this perturbation in the first 3 components of the PCA space. Training takes between 10 and 48 hours depending on the complexity of the setup and the number of PCA bases used.*

Finalmente se carga en una aplicación interactiva 3D los pesos en C++, y se deja al usuario manipular al personaje con un gamepad. Se aceleran calculos necesarios para el input con shaders en GPU (gpu decompression). At render time it is not sufficient to only have access to vertex positions, as the deformed vertex normals are also needed for rendering. Esto no lo vamos a tener en cuenta porque aun no tenemos modelos complejos. Pero se tendría que hacer.

Limitaciones: simulacion erronea quitada a mano, falta de pruebas en objetos plásticos, self collisions may occur, external object fixed in place (such as throwing boxes at a deformable object and having it react by rolling around on the floors)

Se toman los ejes de deformación necesarios para reconstruir la simulación original.

2.3.2.5. Cloth and Skin Deformation with a Triangle Mesh Based Convolutional Neural Network

Our networks are built using three basic building blocks, namely Convolution, Pooling and Unpooling operators that operate directly on a manifold triangle mesh.

Este estudio es un ejemplo de uso de CNN para la simulación de cloth. Reseña la dificultad de integrar una CNN debido a la construcción de la malla, en primer lugar incompatible con una grid 2D. Resuelve el problema entrenando mallas "manifold" triangulares: es decir, mallas cuyos bordes están conectados por al menos dos caras (menos los extremos) dejando una separación entre exterior e interior. Mapear la mesh a una imagen 2D es lo que permite realizar la convolución. Crean un encoder-decoder network que está formado por bloques UpConv and DownConv con operadores nuevos de convolución, pooling y unpooling. Destacamos como reduce la

dimensionalidad de la malla en el pooling: colpasa los edges siguiendo un método en espiral. También señala la importancia de usar Leaky-CNN: para no dejar neuronas muertas, que resulta un problema en la simulación. también de usar L2 además de L2 para que no se quede el error concretado en ciertos vértices. También usa el Adam optimizer. Este estudio afirma conseguir resultados muy cercanos a la GT, usa la Berkley animation base, cuenta con PC potente, y no obstante, indican una vez más los largos tiempos de entrenamiento (4-20horas) y la necesidad de calidad y cantidad de datos de entrenamiento. Y la incapacidad de asegurar deformaciones sin

Este estudio incluye joints, inclusion de brazos y manos, (maybe i should talk about this?)

+ Cloth unsampling, Pose to cloth, PCA back to original space.

2.3.3. DeepSD: Real-time Cloth Simulation with Deep Learning

CNN. También esta deep wrinkles

2.3.3.1. SNUG

citesantesteban2022snug Sistema de muelles tmbn (fuerza bruta) pero entrenado en una red recurrente para conseguir equilibrio estático (ley física) lo que hace que pueda ser aprendizaje NO supervisado y NO necesitar base de datos de mallas ya simuladas

2.3.3.2. HOOD: Hierarchical Graphs for Generalized Modelling of Clothing Dynamics

2023 avance!!!! tres pasos importantes

a) graph neural networks that learn the local dynamics in a garment-independent way: trains its network using physics instead of labeled examples. el grafo sirve para propagar mensajes (pura física) NO SÉ SI PLANTEAMOS LLEGAR TAN LEJOS LOL: Our method learns to predict physically realistic fabric behavior by reasoning about the map between local deformations, forces, and accelerations. Thanks to its locality, our method is agnostic to both the global structure and shape of the garment and directly generalizes to arbitrary body shapes and motions.

b) hierarchical message-passing for the efficient capture of long-range coupling: related a MeshGraphNets pero con más mensajes (multi-level) y entre varias estrategias de pooling que se están llevando ellos hacen: graph coarsening strategy that allows our network to implicitly learn transitions between graph levels

c) a physics-based loss function that enables self-supervised training: utiliza incremental potential for implicit time stepping como loss function en esto se refiere a la propia ecuación de simulación física: implicit time integration, where the next state of the cloth is found by minimizing an energy (potential) that encodes: stretching / bending energies, inertia (how velocity continues), contact, friction, etc. This energy (often called an incremental potential) is a scalar function of the cloth configura-

tion at the next time step. Aplicando la propia física correcta como loss, consigue aprendizaje NO SUPERVISADO

Soluciona PROBLEMAS q otros estudios: - huesos a la tela para poder extender de las prendas apretadas - telas como point clouds para poder adaptarse a la topología lo coloca dentro d Learned Deformation Models

Limites: Velocidad d sim, self-coll...

Capítulo 3

Descripción del Trabajo

3.1. SimulacionUnity

3.2. Dataset

UVs utilizadas para aproximarnos a graph nns pero d manera barata para nosotros

3.3. EntrenamientoPython

se acumula el error: - segundo modelo // segunda comprobación - red recurrente
-

3.4. SimulacionUnity

3.5. ModelosFuncionales

3.6. PruebaTesters

Conclusiones y Trabajo Futuro

4.1. Conclusiones

Las conclusiones de cada una de las partes del trabajo se presentan en las siguientes secciones de manera más detalladas.

4.1.1. Conclusiones de la búsqueda de datasets

Bla.

4.1.2. Conclusiones de la blablabla

Bla.

4.1.3. Limitaciones

Este estudio ha tenido una serie de limitaciones, desde blablabla Los modelos de redes neuronales no han dado los resultados esperados, esto puede ser por la falta de datos, que aunque haya un número que a simple vista parece suficiente no lo es para entrenar redes neuronales, por las limitaciones de hardware para entrenar modelos más complejos y por los tiempos requeridos para la realización de este estudio no ser lo suficientemente largos como para llevar a cabo entrenamientos más extensos y con mayor búsqueda de hiperparámetros.

Todas estas limitaciones, han llevado al siguiente plan de trabajo a futuro.

4.2. Trabajo Futuro

El trabajo a futuro de este estudio se puede centrar en varios esfuerzos:

- bla
- bla

- bla

Contribuciones Personales

Eva

Muchas cosas.

Pau

Muchas cosas.

Mik

Muchas cosas.

Bibliografía

The sciences, each straining in its own direction, have hitherto harmed us little; but some day the piecing together of dissociated knowledge will open up such terrifying vistas of reality, and of our frightful position therein, that we shall either go mad from the revelation or flee from the deadly light into the peace and safety of a new dark age.

H.P. Lovecraft, *The Call of Cthulhu*

CONTRIBUTORS, P. Pytorch documentation. <https://docs.pytorch.org/docs/stable/index.html>, 2026. Accessed: April 17, 2026.

GAMES, E. Chaos cloth. <https://dev.epicgames.com/documentation/unreal-engine/machine-learning-cloth-simulation-overview>, 2025. Accessed: (17/04/2026).

HECKER, C. Physics in computer games (title only). *Communications of the ACM*, vol. 43(7), páginas 34–39, 2000.

JIM HUGUNIN, U. Unite 2016 - gpu accelerated high resolution cloth simulation. <https://www.youtube.com/watch?v=kCGHX1LR3l8>, 2016. Accessed: (15/04/2026).

KENNY ERLEBEN, K. H., JON SPORRING. *Physics-based Animation*. Charles River Media, 2005.

MACKLIN, M., MÜLLER, M. y CHENTANEZ, N. XPBD: position-based simulation of compliant constrained dynamics. En *Proceedings of the 9th International Conference on Motion in Games*, páginas 49–54. ACM, Burlingame California, 2016. ISBN 978-1-4503-4592-7.

METHOD, V. Obi cloth. <https://assetstore.unity.com/packages/tools/physics/obi-cloth-81333?aid=1011134eQ>, 2019. Accessed: (16/04/2026).

MILLINGTON, I. *Game Physics Engine Development*. CRC Press, 2007. ISBN 9781482267327.

- MÜLLER, M., HEIDELBERGER, B., HENNIX, M. y RATCLIFF, J. Position based dynamics. *Journal of Visual Communication and Image Representation*, vol. 18(2), páginas 109–118, 2007. ISSN 10473203.
- PAUL, P., GOON, S. y BHATTACHARYA, A. History and comparative study of modern game engines. *International Journal of Advanced Computer and Mathematical Sciences*, vol. 3, páginas 2230–9624, 2012.
- PROJECT, O. Onnx: Open neural network exchange. <https://onnx.ai/>, 2026. Accessed: 2026-04-17.
- SALEN, K. y ZIMMERMAN, E. *Rules of Play: Game Design Fundamentals*. MIT Press, 2004.
- TECHNOLOGIES, U. Unity sentis: Ai inference package v2.4. <https://docs.unity3d.com/Packages/com.unity.ai.inference@2.4/manual/index.html>, 2026. Accessed: 2026-04-17.
- TEMPLET, R. M. *Game Physics: An Analysis of Physics Engines for First-Time Physics Developers*. Tesis Doctoral, California State University, Northridge, 2021.
- VA, H., CHOI, M.-H. y HONG, M. Real-time cloth simulation using compute shader in unity3d for ar/vr contents. *Applied Sciences*, vol. 11(17), 2021. ISSN 2076-3417.

Carteles para la generación del dataset



Figura A.1: Cartel colgado en la facultad de informática




Figura A.2: Cartel colgado en redes sociales



Figura A.3: Cartel colgado en pantallas de la facultad

Formulario de recogida de citas

Participación Dataset para detección de poses

Necesitamos datos para un TFG de la Facultad de Informática de la UCM. Lo importante, **¿qué datos recopilamos?** La siguiente lista de datos son los datos que vamos a recopilar y hacer públicos en el propio estudio del tfg o en un dataset público en [kaggle](#):

- Edad
- Sexo
- Nacionalidad
- Datos de coordenadas de distintas partes del cuerpo dadas por un traje de captura de movimiento

Estos datos se recogerán en un formulario a parte el día de la prueba, siendo hechos desde un correo de los organizadores y permaneciendo totalmente anónimos sin correlación a la persona que ha realizado la prueba.

OBJETIVO DE LOS DATOS: los datos de edad, nacionalidad y sexo son meramente estadísticos, solo se usarán para demostrar la heterogeneidad (o falta de) de los datos tomados. Los datos de coordenadas se usarán para entrenar distintos modelos de clasificación de pose con la intención de poder decir con acierto el gesto o pose que está haciendo una persona mientras lleva el traje puesto.

LOCALIZACIÓN DE LA PRUEBA: [Facultad de Informática \(UCM\)](#), Calle del Prof. José García Santesmases, 9, Moncloa - Aravaca, 28040 Madrid

alejba02@ucm.es [Cambiar de cuenta](#)

* Indica que la pregunta es obligatoria

Correo *

Tu dirección de correo electrónico

¿Aceptas la recogida de datos y la participación en el muestreo? *

☐ Si

☐ No

[Siguiente](#)

Página 1 de 2

[Borrar formulario](#)

Este formulario se creó en Universidad Complutense de Madrid.
¿Parece sospechoso este formulario? [Informe](#)

Figura B.1: Formulario de recogida de citas (primera parte)

Participación Dataset para detección de poses

alejba02@ucm.es [Cambiar de cuenta](#)

Horario disponible

A continuación marca las horas en las podrías estar disponible. Con la respuesta que proporciones te mandaremos un correo con un día y hora determinados.

Lunes

- ☐ 9:00-10:00
- ☐ 10:00-11:00
- ☐ 11:00-12:00
- ☐ 12:00-13:00
- ☐ 13:00-14:00
- ☐ 14:00-15:00
- ☐ 15:00-16:00
- ☐ 16:00-17:00
- ☐ 17:00-18:00
- ☐ 18:00-19:00
- ☐ 19:00-20:00

Figura B.2: Formulario de recogida de citas (segunda parte)

Resultados de los distintos modelos CNN

La línea verde en los gráficos de tensorboard indican la mejor combinación de hiperparámetros encontrada en cada caso

C.1. Intervalo 0.2s




Figura C.1: Esquema del modelo CNN con 0.2s de intervalo




Figura C.2: Matriz de confusión del modelo CNN con 0.2s de intervalo




Figura C.3: Gráfico de entrenamiento del modelo CNN con 0.2s de intervalo (mejor val_accuracy = 0.28777)

C.2. Intervalo 0.4s




Figura C.4: Esquema del modelo CNN con 0.4s de intervalo




Figura C.5: Matriz de confusión del modelo CNN con 0.4s de intervalo




Figura C.6: Gráfico de entrenamiento del modelo CNN con 0.4s de intervalo (mejor $\text{val_accuracy} = 0.49473$)

C.3. Intervalo 0.6s




Figura C.7: Esquema del modelo CNN con 0.6s de intervalo




Figura C.8: Matriz de confusión del modelo CNN con 0.6s de intervalo




Figura C.9: Gráfico de entrenamiento del modelo CNN con 0.6s de intervalo (mejor val_accuracy = 0.44952)

C.4. Intervalo 0.8s




Figura C.10: Esquema del modelo CNN con 0.8s de intervalo




Figura C.11: Matriz de confusión del modelo CNN con 0.8s de intervalo




Figura C.12: Gráfico de entrenamiento del modelo CNN con 0.8s de intervalo (mejor val_accuracy = 0.40583)

C.5. Intervalo 1.0s




Figura C.13: Esquema del modelo CNN con 1.0s de intervalo



Figura C.14: Matriz de confusión del modelo CNN con 1.0s de intervalo




Figura C.15: Gráfico de entrenamiento del modelo CNN con 1.0s de intervalo (mejor val_accuracy = 0.56002)

Glosario

CNN Convolutional Neural Network

Licencia de uso del documento

Esta obra está bajo una licencia [Creative Commons](http://creativecommons.org/licenses/by-sa/4.0/legalcode) «Atribución-NoComercial-CompartirIgual 4.0 Internacional».

<http://creativecommons.org/licenses/by-sa/4.0/legalcode>.



Licencia de uso del código fuente

Los archivos de código fuente para generar este documento se encuentran en <https://github.com/FratosVR/Memoria-TFG> bajo la licencia [GPL-3.0](#)