
IA como apoyo al desarrollo de tools artísticas
y simulación en juegos
AI as a support for art tools and game physics
simulation



Trabajo de Fin de Grado
Curso 2025–2026

Autor

Eva Feliu Aréjola, Paula López Román, Mikele López
de la Hoz

Director

Ismael Sagredo Olivenza

Colaborador

Colaborador no definido. Usa \colaboradorPortada

Grado en Desarrollo de Videojuegos

Facultad de Informática

Universidad Complutense de Madrid

IA como apoyo al desarrollo de tools
artísticas y simulación en juegos
AI as a support for art tools and game
physics simulation

Trabajo de Fin de Grado en Desarrollo de Videojuegos

Autor

Eva Feliu Aréjola, Paula López Román, Mikele López de la
Hoz

Director

Ismael Sagredo Olivenza

Colaborador

Colaborador no definido. Usa \colaboradorPortada

Convocatoria: *Junio 2026*

Grado en Desarrollo de Videojuegos

Facultad de Informática

Universidad Complutense de Madrid

2 de septiembre de 2026

Dedicatoria

*A toda la gente que nos ha hecho llegar hasta
aquí,
un besazo.
A todos los que han estado a nuestro lado.*

Agradecimientos

Os amo!

Mik

Os amo!

Pau

Os amo!

Eva

Resumen

IA como apoyo al desarrollo de tools artísticas y simulación en juegos

Este estudio realiza una comparativa de distintos modelos y técnicas de IA que logren replicar y hacer frente a la simulación de físicas costosas en proyectos 3D en motores de videojuegos.

Se toma como ejemplo el caso de las simulaciones de telas, cuya geometría y características, y consecuente alto coste computacional en simulación, lo convierte en campo experimental para la optimización de físicas mediante redes de neuronas. Para lograr simular una tela, se crea una simulación en Unity3D con un objeto con componente Cloth y un colisionador que genera movimiento y deformaciones en la malla. En el mismo entorno de Unity se generan los datasets, los que se exportan al entorno de entrenamiento para analizar diferentes modelos en Pytorch: una MLP, una RNN, y técnicas de propagación de error así como reducciones de espacio.

Las redes entrenadas se exportan de vuelta a Unity, y en este se ponen en marcha los modelos para simular el movimiento (mediante el paquete Sentsis). Se modifican los vértices de una tela con un componente propio ML, que pide al modelo los desplazamientos a realizar para cada uno. Finalmente, se realizan experimentos y comparativas entre los distintos modelos, tanto en cuanto a precisión del modelo como a resultados visuales. Se concluye que el modelo que obtiene mejores resultados replicando visualmente la tela fue una red neuronal recurrente con una técnica de propagación de error a futuro, no obstante el rendimiento aún precisa de reducciones para ser prometedor.

Palabras clave

Inteligencia Artificial, Simulación física, Unity, Videojuegos, Optimización, PyTorch, ML

Abstract

AI as a support for art tools and game physics simulation

We need to do this.

Keywords

We need to do this.

Índice

1. Introducción	1
1.1. Motivación	2
1.2. Objetivos	2
1.3. Plan de trabajo	3
1.4. Metodología	4
2. Estado de la Cuestión	5
2.1. Motores de videojuegos	5
2.2. Motores de física	6
2.3. Simulación física en videojuegos	7
2.4. Simulación de telas	8
2.4.1. Cloth	8
2.4.2. Optimizaciones en simulación de telas	10
2.5. IA para optimización de telas	12
2.5.1. Modelos de optimización de telas	12
2.5.1.1. Subspace Neural Physics: Fast Data-Driven Interac- tive Simulation	12
2.5.1.2. Cloth and Skin Deformation with a Triangle Mesh Based Convolutional Neural Network	13
2.5.1.3. PBNS: Physically Based Neural Simulation for Un- supervised Garment Pose Space Deformation	14
2.5.1.4. SNUG	15
2.5.1.5. Neural Cloth Simulation	15
2.5.1.6. HOOD: Hierarchical Graphs for Generalized Mode- lling of Clothing Dynamics	15
2.5.2. Librerías	16
2.5.2.1. Pytorch	16
2.5.2.2. ONNX	16
2.5.2.3. Sentis	16
3. Arquitectura de la Solución	19
3.1. Arquitectura General	19

3.2.	La fase de simulación	20
3.2.1.	La simulación	20
3.2.2.	Otras simulaciones	22
3.2.3.	Los parámetros	23
3.2.3.1.	Sistema de coordenadas	24
3.2.3.2.	Elección de parámetros finales	24
3.2.4.	Generación del dataset	25
3.3.	La fase de entrenamiento	26
3.3.1.	El entorno de trabajo	26
3.3.2.	Apartados de la ejecución del entrenamiento	27
3.3.3.	Modelos	28
3.3.3.1.	Tipos de redes y recurrencia	29
3.3.3.2.	Gestión de error acumulado	30
3.3.3.3.	Reducción de dimensionalidad	33
3.3.4.	Bucle de entrenamiento	35
3.4.	La fase de inferencia	37
3.4.1.	Alteraciones en la escena	37
3.4.2.	Componente ClothML	37
3.4.2.1.	Funcionamiento de Sentis	37
3.4.2.2.	Estructura del componente	38
3.4.3.	Post-procesamiento	40
4.	Experimentos	41
4.1.	Recurrencia	43
4.2.	Unrolling	45
4.3.	Velocidad	46
4.4.	PCA	48
4.5.	Aplicacion para la visualización de los experimentos	50
5.	Evaluación y Discusión de los resultados	51
5.1.	Análisis del Rendimiento	51
5.2.	Resultados visuales de la inferencia	52
5.3.	Pruebas de usuario	52
5.3.1.	Objetivos	53
5.3.2.	Diseño de las pruebas	53
5.3.3.	Resultados	54
6.	Conclusiones y Trabajo Futuro	57
6.1.	Conclusiones	57
6.1.1.	Limitaciones	58
6.2.	Trabajo Futuro	59
	Contribuciones Personales	61

Bibliografía	63
Licencia de uso del documento	67
Licencia de uso del código fuente	69

Índice de figuras

1.1. Diagrama de Gantt del proyecto. Representa la organización de las tareas en el tiempo de desarrollo del proyecto.	4
3.1. Diagrama de la arquitectura General del proyecto	19
3.2. Malla de 25 vértices con parte superior fija.	21
3.3. Movimiento aleatorio basado en splines.	21
3.4. Simulación de una camiseta con componente Cloth.	23
3.5. Simulación de una falda con componente Cloth.	23
3.6. Parámetros valorados por el random forest.	25
3.7. Visualización de los puntos de la tela simulada e inferida a lo largo del tiempo.	28
3.8. Visualización del error medio a lo largo del tiempo	28
3.9. Visualización de error de normalización	28
3.10. Error acumulado	30
3.11. Comparación de métodos para el cálculo de LossPos. A la izquierda se encuentra el primero mencionado, comparando la posición absoluta inferida para el frame con la posición real. A la derecha está el siguiente mencionado, el desplazamiento inferido con el desplazamiento necesario para llegar a la posición real tras los pasos de unfolding.	32
3.12. Ejemplo de componentes óptimos para PCA	34
3.13. Array del tamaño [<i>windowsize*vertices*features</i>] de las dimensiones necesarias (1 x secuencia de frames del historial x cantidad de vértices x cantidad de características)	39
3.14. Esquema del contenido de FixedUpdate() de ClothML.	39
4.1. Tela simulada a través de RNN.	44
4.2. Tela simulada a través de MLP.	44
4.3. Estado de la geometría tras 100 segundos de ejecución. En la izquierda, en verde, la tela entrenada con 24 frames de unrolling y en la derecha, en morado, la entrenada sin emplear esta técnica.	45
4.4. Movimientos exagerados al comienzo de la simulación con velocidad. .	47

4.5.	Ejemplo de deformación de la tela pasado un minuto en la simulación con velocidad.	47
4.6.	La tela con PCA se hace a un lado para dejar pasar al colisionador, que viene del fondo.	49
4.7.	Tras lo ocurrido en 4.6, la tela con PCA recupera su estructura de reposo y su movimiento con inercia entre colisiones.	49
4.8.	Menu principal de la aplicación.	50
4.9.	Ejemplo de la ejecución de una simulación de un experimento	50
5.1.	Distribución de la capacidad de los usuarios de identificar correctamente la simulación física y la generada con IA.	54
5.2.	Elección de los usuarios en base al realismo de las telas. Incluye la métrica anterior, colocando los dos subgrupos de usuarios en esta división.	54
5.3.	Identificación de la tela simulada con el modelo de ML de cada subgrupo en base a su frecuencia de uso de videojuegos.	54
5.4.	Características de la simulación ordenadas en base a la media de posición en la que los encuestados las posicionan. Agregadas en negro, las desviaciones típicas de cada media.	55
5.5.	Evaluación de los usuarios del realismo de la tela inferida.	56

Índice de tablas

3.1. Librerías y versiones del entorno de desarrollo.	26
4.1. Resultados del entrenamiento en base a la percepción.	43
4.2. Hiperparámetros y configuración del entrenamiento.	43
4.3. Resultados del entrenamiento en base al rendimiento.	44
4.4. Resultados del entrenamiento en base a la percepción.	44
4.5. Resultados de los entrenamientos en base al rendimiento.	45
4.6. Resultados de los entrenamientos en base a la percepción.	46
4.7. Hiperparámetros y configuración del entrenamiento.	46
4.8. Resultados del entrenamiento en base al rendimiento.	47
4.9. Resultados del entrenamiento en base a la percepción.	47
4.10. Hiperparámetros y configuración del entrenamiento.	48
4.11. Resultados del entrenamiento en base al rendimiento.	48
4.12. Resultados del entrenamiento en base a la percepción.	49

Introducción

En los últimos años, el aumento en el tamaño y la complejidad en los videojuegos ha supuesto la imprescindible optimización y automatización de diversos aspectos de su desarrollo, tanto en el ámbito del renderizado como en la lógica interna de los sistemas. Particularmente la evolución de entornos 3D, con el objetivo de obtener gráficos más detallados, ha implicado un incremento significativo en el coste computacional. Una forma de afrontar estas simulaciones para reducir su impacto computacional, es utilizar modelos de ML que permiten aproximar el comportamiento de estos elementos reduciendo el coste.

Empresas pioneras en hardware y software han desarrollado tecnologías para mejorar el rendimiento gráfico incorporando esta clase de algoritmos. Entre ellas destacan: NVIDIA con DLSS (Deep Learning Super Sampling), donde tenemos el Resident Evil Requiem que usa DLSS 4¹; y AMD con FSR (FidelityFX Super Resolution)². Asimismo, varias compañías lo incorporan en la lógica del juego simulando comportamientos y mecánicas como EA (FIFA), Embark Studios (Arc Raiders) o Ubisoft con sus múltiples líneas de investigación sobre la IA. En este contexto, un tercer campo de aplicación que está en proceso de investigación es la aplicación de modelos de aprendizaje automático en simulaciones físicas.

En el campo de la simulación física, con el incremento de la capacidad de cálculo de los sistemas actuales, se busca una mayor fidelidad en la recreación de las interacciones entre los diferentes elementos. Así por ejemplo, elementos como el cabello, los fluidos o las telas, elementos que hace poco más de una década estaban muy simplificados, en la actualidad se busca cada vez más con comportamiento realista en sus interacciones. Esta simulación física de sus comportamientos resulta en una carga computacional significativa, lo que afecta negativamente al rendimiento de los

¹**Deep Learning Super Sampling:** Aumenta el rendimiento del videojuego permitiéndolo renderizarse con una resolución más baja, ya que esta tecnología consigue reconstruir la imagen a mayor calidad en runtime. Utiliza herramientas como *Ray Reconstruction* para reemplazar sus *denoisers* manuales o DLAA (Deep Learning Anti-Aliasing) para suavizar los bordes.

²**FidelityFX Super Resolution:** técnica desarrollada por AMD de código abierto que consiste en el aumento del rendimiento en videojuegos mediante el escalado de resolución. Se diferencia del DLSS de NVIDIA por no tener requerimientos específicos de hardware.

videojuegos, en especial en términos de tasa de fotogramas. La industria se encuentra en un momento de auge en investigación y aplicación de Machine Learning para solucionarlo. Se puede observar por ejemplo, a través de los estudios de Ubisoft la Forge, el grupo de desarrollo e investigación de Ubisoft³. Entre sus investigaciones se encuentran aplicaciones recientes de ML en distintos campos de simulación; la adaptación de animaciones de personajes a interacciones físicas Bergamin et al. (2019) o la aceleración de simulaciones de cuerpos deformables Holden et al. (2019), sobre el que se profundizará en el siguiente capítulo.

1.1. Motivación

En la misma línea de otras tecnologías ya utilizadas en el desarrollo de videojuegos como la mencionada DLSS de NVIDIA, donde se aplican modelos de redes neuronales profundas para reducir la carga computacional de los juegos en el renderizado, se conducen estudios y empiezan a aplicar técnicas similares en la industria en simulación física. Nace en un contexto donde los juegos tienden a ser distribuidos ya no solo en consolas con hardware y gráficas dedicadas, sino en múltiples plataformas con el objeto de maximizar ingresos, donde no todas tienen las mismas capacidades de cómputo. El uso de estas técnicas de optimización puede permitir recrear estas simulaciones con un grado de fidelidad aceptable, en dispositivos de menor potencia como pueden ser Nintendo Switch, Handle pcs o dispositivos móviles.

La motivación principal de este estudio reside en lograr simulaciones visualmente verosímiles, que se centren en la percepción del usuario. Por ello, se ha optado por la simulación de telas. La simulación de telas se presenta como un caso de físicas complejas, alto dinamismo y aplicación tanto en optimización en juegos integrados como en herramientas para artistas, ofreciendo un amplio rango de usos, que comienza a integrarse a día de hoy en grandes empresas y continua en fase experimental. Se elige este campo de estudio pues representa un equilibrio adecuado entre complejidad física y familiaridad con el resultado visual, que permite llevar a cabo un análisis tanto técnico como perceptivo.

1.2. Objetivos

El objetivo general de este proyecto es construir una infraestructura que permita identificar las limitaciones actuales de la implementación de un modelo de IA que replique el movimiento en tiempo real de una tela en un motor de videojuegos con baja latencia. Para cumplir con este objetivo, se plantean las siguientes metas durante el desarrollo del proyecto:

1. Generar una animación de una tela y un colisionador que varíe su movimiento en cada ejecución de la escena.

³Artículos y publicaciones de Ubisoft la Forge: <https://www.ubisoft.com/en-us/studio/laforge/publications#24A8zwsBgQ1tTM1NRp20b9%C3%A7>

2. Generar y procesar datasets con la información relevante de la tela respecto a su entorno y colisionador.
3. Implementar, entrenar y evaluar los distintos modelos de aprendizaje automático, tales como redes neuronales.
4. Analizar y comparar los resultados tanto visuales como de rendimiento de los distintos modelos.

1.3. Plan de trabajo

El desarrollo del proyecto se llevará a cabo en el periodo lectivo del curso 2025-2026. Dados los objetivos del apartado anterior, la planificación se divide en las siguientes iteraciones:

- **Iteración 0:** En esta etapa se concretan los objetivos reales de la investigación y se establece la planificación del trabajo respecto a la propuesta inicial.
- **Iteración 1:** Etapa de preparación, donde se cumplirán los siguientes subobjetivos para implementar un sistema de simulación adecuado para ser procesado por los modelos en un futuro.
 - **Iteración 1.1:** Se realizará una investigación de trabajos relacionados a este, relevante para dirigir el desarrollo de los experimentos. Se analizarán distintas alternativas y se decidirá cuales resultarán más interesantes de replicar, se definirán qué tipo de datos deberemos recopilar para el entrenamiento y qué tipo de redes podrán llevarlo a cabo.
 - **Iteración 1.2:** Se creará una simulación básica en Unity y un sistema de registro de datos relevantes a la tela.
- **Iteración 2:** Se establecerá un entorno de trabajo para el entrenamiento de los datos recopilados. Se generará un pipeline claro en el que se integre la simulación de recogida de datos, su limpieza y posterior uso para entrenar el modelo y, finalmente, la incorporación de este al entorno de simulación. Para poder asegurar del correcto funcionamiento de este sistema se generará un modelo simple y se comprobará que el pipeline es correcto. En esta fase se comenzarán a redactar los primeros capítulos de la memoria.
- **Iteración 3:** Con una base sólida ya montada, se aumentará la complejidad y, por consiguiente, el coste de la simulación. Se implementarán distintos modelos y se llevarán a cabo pruebas con todos ellos para asegurarse de su fiabilidad.
- **Iteración 4:** Si las anteriores iteraciones funcionan de manera correcta esta última no tendrá ninguna carga de implementación. Se alcanzará la última meta definida: hacer distintas pruebas entrenando los modelos ya desarrollados, sacar métricas de todos ellos para poder hacer comparaciones y hacer un análisis exhaustivo de estos resultados, sacando así las conclusiones de la investigación.

El desarrollo de las tareas y su planificación se puede ver en la figura 1.1.




Figura 1.1: Diagrama de Gantt del proyecto. Representa la organización de las tareas en el tiempo de desarrollo del proyecto.

1.4. Metodología

Para el desarrollo de esta investigación se emplearán herramientas de libre acceso y uso gratuito, con el objetivo de facilitar la reproducibilidad de los resultados obtenidos. El entorno de desarrollo principal será Windows 11, al tratarse del sistema operativo utilizado por el equipo de trabajo y extendido entre los potenciales usuarios. La simulación de la tela, así como la integración del modelo de inteligencia artificial, se llevarán a cabo en Unity (versión 6000.3.2f1, correspondiente a una versión de soporte a largo plazo). En cuanto a los lenguajes de programación, se empleará C# para el desarrollo dentro de Unity, incluyendo la generación de la simulación y la recopilación de datos, mientras que se utilizará Python con Pytorch para el entrenamiento de los modelos de aprendizaje automático. La integración de los modelos entrenados en el entorno de ejecución se realizará a través del paquete Unity Sentis.

Para la gestión del código fuente y el trabajo colaborativo se utilizará GitHub, basado en el sistema de control de versiones Git. Asimismo, se empleará la herramienta GitHub Projects para la planificación, asignación y seguimiento de tareas. Como herramientas adicionales, se utilizará Google Drive para el almacenamiento de documentación, apuntes de reuniones y materiales de trabajo puntuales, y Discord para la coordinación del equipo mediante reuniones online, además de encuentros presenciales semanales.

Capítulo 2

Estado de la Cuestión

En este capítulo se presenta una breve resumen del desarrollo de las simulaciones físicas en videojuegos, así como el hardware y software que ha hecho que esta evolución sea posible. También se presenta la simulación de telas, sus diferencias de implementación, los problemas de optimización que estas suponen y los avances en modelos de IA que permiten imaginar otras soluciones.

2.1. Motores de videojuegos

Si bien este proyecto se centra en la computación física, gestionada por los motores físicos, los motores de videojuegos proporcionan un conjunto más amplio de herramientas comunes para el desarrollo de videojuegos, entre los cuales encontramos también los motores de renderizado, sonido y otros componentes como los sistemas de scripting o interfaz de usuario, que se complementan para satisfacer las necesidades que requiere la creación de un juego. Existe gran cantidad de motores de videojuegos, siendo algunos de los más conocidos Unity y Unreal, que se detallarán a continuación. Además de estos motores comerciales de acceso general, muchos estudios grandes disponen de motores propios adaptados a sus necesidades y especialización. Algunos ejemplos son Frostbite de Electronic Arts y SnowDrop de Ubisoft. Los dos motores comerciales más utilizados son:

- **Unreal Engine:** Es un motor de videojuegos creado por Epic Games en 1998. Destaca por su motor gráfico, que permite gráficos realistas en tiempo real con tecnologías como Nanite para geometría virtualizada o Lumen para iluminación dinámica. Es multiplataforma y se encuentra no sólo en pequeños desarrollos independientes (indie), sino en grandes producciones multimillonarias (producciones AAA'). Se caracteriza por su sistema de programación visual (Blueprints) en programación con C++. Integraba Physx como motor físico hasta la introducción reciente de Chaos Physics en su versión 5.7, que aporta novedades que se destacarán más adelante en el apartado [2.4.2](#).
- **Unity:** Creado por Unity Technologies en 2005, abarca un porcentaje del 51 %

de juegos publicados en 2024 y un 26 % ¹ en las unidades vendidas en Steam. Es el motor de videojuegos más utilizado por desarrolladores indie y cuenta con documentación extensa, una gran comunidad y extensiones como SentiS para la integración de modelos de IA, que explicaremos más adelante. Unity3D integra PhysX como motor de físicas, pero puede incorporar otros sistemas de físicas como Havok bajo licencia ². Está basado en la arquitectura Entidad-Componente en C#, y típicamente se utiliza para juegos más pequeños y menos potentes en cuanto a gráficos.

2.2. Motores de física

Un motor de físicas es un conjunto de funciones y recursos que permite la implementación de sistemas de físicas como cuerpos rígidos con su consecuente detección de colisiones, cuerpos blandos e incluso fluidos.

Los motores de física se extendieron en los años 90, con la popularidad del 3D y gráficos en auge. Los grandes cálculos en tiempo real con su correspondiente carga para la CPU plantearon dos grandes retos: el avance de los motores físicos cada vez más precisos y potentes, y, por otro lado, la optimización del hardware para llegar a la demanda computacional que esto suponía.

En 2002 se funda Ageia Technologies, responsable de la creación del primer procesador de física dedicado para ordenadores, denominado PhysX PPU (Physics Processing Unit), así como del motor PhysX ³, que sigue siendo líder en la industria a día de hoy. Posteriormente, NVIDIA Corporation, conocida por su papel en la producción de GPUs, adquiere Ageia, impulsando el cálculo de físicas en GPU. Esto, sumado a la dificultad de penetrar en el mercado del hardware, hace que la producción de PPUs quede obsoleta.

Por otro lado, Intel adquiere en 2007 Havok ⁴, otro de los primeros motores de físicas, cancelando el programa HavokFX que pretendía llevar el cálculo de físicas a la GPU para realizar estos en sus CPUs multinúcleo. Posteriormente es adquirido por Microsoft en 2015 y se integra en las herramientas de desarrollo como DirectX. Se establece como el middleware más común en grandes producciones y simulaciones complejas en estudios, mientras que Physx se convierte en libre acceso en 2018 y se integra en motores de videojuegos como Unreal.

La incorporación de motores de física completos en el desarrollo de videojuegos aporta escalabilidad en el *gameplay*, manteniendo la coherencia de sus elementos físicos, lo que resulta imprescindible para la inmersión del jugador Hecker (2000).

¹Según The Big Engines Report 2025 por parte de Sensor Tower https://app.sensortower.com/vgi/assets/reports/The_Big_Game_Engines_Report_of_2025.pdf

²Véase distintas físicas integrables en Unity: <https://docs.unity3d.com/Manual/physics-integrations.html>

³Documentación de Physx: <https://developer.nvidia.com/physx-sdk>

⁴Documentación de Havok: <https://www.havok.com/havok-physics/>

2.3. Simulación física en videojuegos

Hasta la llegada de los motores comentados en el apartado 2.2, existían otras técnicas para representar comportamientos físicos que eran todavía muy rudimentarias: se diseñaban las interacciones físicas previamente para parecer realistas, ya que dada la capacidad de cómputo con la que solían contar las máquinas, era imposible hacer todos los cálculos físicos en tiempo real. Se realizaban detecciones de colisiones simples, sin uso de fuerzas y descripciones de movimientos o respuestas de cada elemento del juego en lugar de sistemas de física.

Estos métodos eran claramente limitados en la precisión que ofrecían, y quedaba clara la necesidad de una solución más general y reproducible. Ian Millington introduce en su libro *Game Physics Engine Development* [Millington \(2007\)](#) el juego *Exile* [Superior Software Audiogenic \(1988\)](#), creado por Peter Irvin y Jeremy Smith; si bien este juego fue publicado en 1988, ya contaba con conservación del momento en colisiones, gravedad, y fuerzas como el viento o explosiones. Resalta como uno de los primeros juegos que cuenta con un motor de físicas completo.

Actualmente existen juegos con simulaciones físicas muy realistas como *Red Dead Redemption 2* [Rockstar Studios \(2018\)](#) o *Hogwarts Legacy* [Avalanche Software \(2023\)](#) donde más allá de satisfacer necesidades de gameplay, se consiguen mundos creíbles en su conjunto. Otros juegos se basan directamente en el funcionamiento y excelencia de sus físicas, particularmente simuladores de vehículos o deformaciones como la saga de *Assetto Corsa* [Kunos Simulazioni \(2014\)](#), el nuevo *Forza Horizon 6* [Playground Games \(2026\)](#), *Microsoft Flight Simulator 2024* [Asobo Studio \(2024\)](#) o *BeamNG.drive* [BeamNG \(2015\)](#), que sigue destacando por su física basada en cuerpos blandos.

Es importante conocer la diferencia entre la simulación de un cuerpo rígido y la simulación de un cuerpo blando para comprender la complejidad que implica cada uno. Se entienden los objetos deformables o cuerpos blandos como aquellos que no son rígidos, es decir, que pueden perder o modificar su forma si reciben fuerzas físicas externas. Para un cuerpo rígido, al no ser deformable, solo hay que calcular su posición, rotación y velocidad en un momento dado, en función de su estado previo y de la interacción con otros elementos físicos. Sin embargo, en el caso de un cuerpo blando, a parte de su posición y velocidad y rotación como cuerpo, hay que calcular la posición, velocidad y rotación de las partes que lo componen, a las que se les suele denominar "partículas". Estas partículas se ven afectadas por propiedades físicas como la tensión y la deformación, que modifican el comportamiento de las mismas y su interacción con otros cuerpos. Entre los cuerpos blandos se encuentran elementos como las telas, el agua o el viento [Kenny Erleben \(2005\)](#).

Dada la complejidad de estas simulaciones, se necesita un programa que se en-

cargue de realizar los cálculos necesarios para cada partícula. A estos programas de simulación se les denomina *solvers*. Pese a encontrar múltiples acepciones en el término solver para distintas resoluciones de problemas, aquí nos referiremos como solver al algoritmo computacional que se encarga de predecir el comportamiento de estos objetos deformables en renderizados y simulaciones físicas, específicamente en la próxima sección 2.4.1, de telas.

Otro concepto de gran importancia para este estudio es el *Signed Distance Field* (SDF), que será mencionado frecuentemente en los siguientes apartados a la hora de trabajar con las colisiones con objetos externos. Los SDF representan la distancia entre un punto y la superficie más cercana de un objeto o conjunto de coordenadas. Son frecuentemente usados en la informática gráfica y generalmente se calculan como la distancia ortogonal a un espacio métrico.

2.4. Simulación de telas

El protagonista de la simulación de telas es la vestimenta: vestidos, cintas o capas moviéndose dependiendo de las acciones del jugador, viento y condiciones específicas; lo que permite a los jugadores un mayor grado de inmersión y una mayor credibilidad del mundo del videojuego. Adicionalmente, más allá de los objetos fabricados con tela, tradicionalmente ropa o banderas, las físicas de simulación de telas se pueden encontrar aplicadas en otros elementos como pelo, hierba o cuerpos blandos como podría ser un globo. Havok lo recalca en la siguiente cita: “*Havok Cloth is used to create secondary motion and to enhance any object that flows*”⁵.

Algunos juegos que destacan por comenzar a usar la simulación de telas en tiempo real son *Assasins Creed Unity*(2014) [Ubisoft Montreal](#) (2014) que usó un sistema personalizado de Havok Cloth y *Batman:Arkham Knight* (2015) [Rocksteady Studios](#) (2015) con un sistema híbrido de físicas y rigging usando Apex Cloth⁶.

En esta sección se describe cómo se representa y simula una tela en tiempo real, el problema que supone y qué tipos de soluciones encontramos. Se indagará mayoritariamente en ejemplos de Unity3D, como referencia elegida de motor de videojuegos.

2.4.1. Cloth

Cloth⁷ es un componente que proporciona Unity3D que funciona junto al componente *Skinned Mesh Renderer* para simular telas. Está basado en Cloth de PhysX⁸ y fue incorporado con el objetivo de poder simular el comportamiento de la ropa de personajes dentro de un videojuego. Es altamente configurable, lo que le permite

⁵Página de Havok Cloth: <https://www.havok.com/havok-cloth/>

⁶Página web de Apex Clothing: <https://www.nvidia.com/en-us/drivers/apex-clothing/>

⁷Documentación de Cloth (Unity): <https://docs.unity3d.com/Manual/class-Cloth.html>

⁸Documentación de Cloth (Physx): <https://archive.docs.nvidia.com/gameworks/content/gameworkslibrary/physx/guide/3.3.4/Manual/Cloth.html>

adaptarse a multiples tipos de telas. Las caraterísticas parametrizables de la tela son:

- *Stretching stiffness* o rigidez del estiramiento: determina cuánta resistencia opone la tela a estirarse.
- *Bending stiffness* o rigidez de flexión: resistencia a la deformación de la tela. Un valor bajo provoca pliegues suaves y dinámicos en la tela. Junto a la rigidez de estiramiento, define la personalidad de la tela, permite recrear el material del que está formada, así como la técnica o estructura que la construye (hilos entrelazados (*knit*) o continuos (tejido)).
- Uso de *tethers*: aplica restricciones que ayudan a prevenir el movimiento de partículas de la tela de irse muy lejos de las que están fijas y reducir así el exceso de estiramiento.
- Uso de Gravedad sobre la tela.
- *Damping* o coeficiente de amortiguación del movimiento: define la rapidez con la que la tela retorna a su pose de reposo.
- Aceleración externa y aleatoria: permiten simular fuerzas como el viento de forma integrada, con movimientos más estables con aplicando la constante de aceleración y movimientos más erráticos (como podría ser un vendaval) aplicando el valor aleatorio.
- Escala de velocidad y aceleración del mundo: determinan cuánto afectará sobre los vértices de la tela la velocidad y aceleración del personaje en el espacio del mundo.
- Fricción: resistencia al deslizamiento que presenta la tela al colisionar con el personaje u otros colisionadores.
- Masa de colisión escalada: qué tanto aumentar la masa de las partículas en colisión.
- Uso de colisión continua: activado detecta colisiones con mayor precisión, contribuyendo a la mejora de estabilidad.
- Uso de partículas virtuales: agrega una partícula virtual por triángulo para mejorar también la estabilidad de colisión.
- Frecuencia del solver: número de iteraciones del solver de la tela por segundo. Un número alto de iteraciones mejora las colisiones, pero sobrecarga la CPU.
- Umbral de adormecimiento de la tela: valor que toma el solver de la tela para considerar las partículas como quitas o “adormecidas” y evitar sobrecargar los cálculos.
- Colisionadores: dos arrays de *CapsuleColliders* y *SphereColliders*.

Adicionalmente, tenemos las restricciones por vértice o *constraints*. Se pueden pintar a través de un mapa de calor los límites de movimiento:

- *Max Distance*: distancia máxima que un vértice de la tela puede moverse desde su posición original en la animación.
- *Surface Penetration*: cuánto puede hundirse el vértice dentro de la malla del personaje.

Physx trata la tela como una malla de partículas conectadas por restricciones. El *Skinned Renderer* calcula las transformaciones basándose en una malla de baja resolución sobre la que realiza los movimientos en los vértices, que dinámicamente se aplican en la malla real y se obtiene la simulación visual. Aquellos *constraints* no visibles o de distancia 0, fijos, no serán calculados. Cómo se ha podido apreciar en los puntos anteriores, la tela cuenta con capacidad de colisionar internamente y con dos tipos de *colliders* externos: cápsulas o esferas. Cualquier objeto externo o personaje con el que se quiera colisionar tendrá que ser un conjunto de estos *colliders*.

Los primeros solvers para telas se basan en algoritmos que emplean la fuerza bruta: realizan cálculos en masa para sistemas de muelles (MSS o Mass Spring Systems) basándose en la Ley de Hooke⁹. Los vértices de la tela tienen un peso y están unidos por tres tipos de muelle que aseguran que la tela mantenga su forma, no se distorsione o doble en exceso Provot (1995). Los solvers más actuales resultan en el PBD o *Position-Based Dynamics*, proceso iterativo que proyecta las posiciones de las partículas sobre un “espacio de restricciones” Müller et al. (2007), es decir, actualizando el desplazamiento generado por cada fuerza en cada vertice de la simulación Chaudhary et al. (2025).

El solver de PhysX se basa en PBD, es decir, trabaja directamente sobre las posiciones. Asimismo XPBD: Extended Position-Based Macklin et al. (2016), es una versión extendida que, con un coste ligeramente superior, incide en la alta dependencia sobre el paso del tiempo e iteraciones de la simulación de PBD. Unreal con Chaos integrado ya acepta *constraints* de tipo XPBD y también puede integrarse en Unity.

2.4.2. Optimizaciones en simulación de telas

Como se ha introducido antes, la simulación de telas en tiempo real supone una serie de desafíos conocidos, de los que se sigue buscando la optimización a día de hoy. El aumento de tamaño o complejidad de una tela, con su alta carga computacional, conlleva el decaimiento inmediato de frames. A parte de dificultar el realismo en juegos y demás simulaciones a tiempo real, resulta un gran impedimento en entornos donde se requieren tasas altas de fotogramas por segundo o una menor capacidad

⁹La ley de Hooke establece que la fuerza necesaria para deformar un cuerpo elástico, como un muelle o resorte, es directamente proporcional a la deformación producida, siempre que no se supere su límite elástico.

de cómputo, por ejemplo, en dispositivos móviles sujetos a batería.

Mientras que el Cloth de PhysX puede delegar la simulación a GPUs compatibles con CUDA, el Cloth integrado por defecto en Unity realiza todo su trabajo en la CPU, lo cual puede ralentizar mucho la ejecución. En el caso de Unreal, previamente al lanzamiento de ML Cloth Simulation, Chaos Physics delegaba su mayor fuerza de trabajo también en la CPU.

Existen varios tipos de soluciones para la optimización de la simulación de telas:

- **Optimización por CPU:** La extensión de *Obi Cloth* ¹⁰ aprovecha el sistema de Jobs de Unity para paralelizar la simulación y acelerar la simulación sin salir de la CPU. Es uno de los paquetes más populares para solucionar este problema.
- **Paralelización en GPU:** a través de *shaders* se delega la fuerza de cálculo del *skinning* en la GPU. Diferentes estudios e individuos aportan diferentes enfoques para la optimización, por ejemplo, [Jim Hugunin \(2016\)](#) realiza una investigación para alcanzar altas resoluciones y evitar colisiones en las mallas, mientras que otros se centran en la mejora de rendimiento pura para adaptar simulaciones a entornos VR [Va et al. \(2021\)](#).
- **Entrenamiento con IA:** El último enfoque es el del uso de ML para simular el comportamiento de Cloth. Esta solución ha ido cobrando fuerza en la actualidad debido a la popularización de los modelos de IA que se han aplicado con éxito en otros campos como se ha visto en la introducción 1. Se entrenan modelos de ML con los datos de las mallas animadas o poses, con el objetivo de que el modelo consiga simular el comportamiento de la tela utilizando menos cálculos al ejecutarlo que la simulación real. Se sacrifica memoria y tiempo de entrenamiento para obtener mejores y mucho más rápidas simulaciones de tela en escena. Actualmente la investigación se encuentra en el contexto de implementación para grandes empresas: Unreal ya proporciona para Chaos Cloth ¹¹ una simulación de tela a través de aprendizaje automático, en el que destaca su realismo. Aún así, cuenta con limitaciones al basarse en un *NearestNeighborSearch*: “el sistema es capaz de predecir detalles como arrugas pero no movimiento dinámico como ondulaciones o drapeados”. En la próxima sección se detallarán las numerosas investigaciones recientes que abarcan aspectos desde la reproducción de arrugas, el compromiso entre calidad, coste y rendimiento hasta colisiones y penetraciones en las mallas.

¹⁰Obi en la Unity Asset Store: <https://assetstore.unity.com/packages/tools/physics/obi-cloth-81333?aid=1011134eQ>

¹¹Documentación introductoria de Chaos Cloth: <https://dev.epicgames.com/documentation/unreal-engine/machine-learning-cloth-simulation-overview>

2.5. IA para optimización de telas

Aprovechando la comprobada capacidad de las redes neuronales profundas para aproximar cualquier función matemática, una aproximación que cada vez emerge con más fuerza es el uso de estos modelos de redes neuronales para ejecutar simulaciones físicas. En estas se destacan las aplicaciones sobre telas y cuerpos no rígidos similares.

2.5.1. Modelos de optimización de telas

Desde la introducción del PBD, la optimización de simulaciones con redes neuronales cuenta ya con un amplio recorrido. En este apartado se describen los estudios más destacados de los últimos años. Son también inspiración directa para la implementación de nuestros experimentos, con el objetivo de descubrir cuáles de estas técnicas son verdaderamente aplicables a menor escala, en desarrollo indie con recursos limitados en cuanto a hardware y especialización físico-matemática.

2.5.1.1. Subspace Neural Physics: Fast Data-Driven Interactive Simulation

Este desarrollo de la unidad de investigación Ubisoft La Forge [Holden et al. \(2019\)](#) implementa la primera técnica que incorpora reducción de modelo o el uso de subespacios con colisiones con objetos externos en la tela. El estudio se centra en conseguir un balance entre el rendimiento en tiempo real y el coste y memoria necesarios para realizar el precómputo.

El entrenamiento se realiza sobre las posiciones de una simulación realizada en Maya aplanados en un vector, al que se añade otro vector plano con los parámetros necesarios como posición del suelo, valor del viento, o collisionadores con la tela. Se aplica un PCA¹² sobre ambos denotando cuántos ejes de deformación de la tela se tienen en cuenta para representar la complejidad de la recreación: 64, 128, 256; siendo este último el que conserva casi el mismo nivel de detalle que la simulación original. La arquitectura del modelo se basa en una red neuronal estándar que opera sobre el subespacio.

Para evitar que la simulación colapse con el error que va produciendo, se aplican dos estrategias:

- Ventanas de frames superpuestas, con bloques de 32 frames con *mini-batches*¹³ para mantener la coherencia a largo plazo
- Ruido gaussiano, para que la red aprenda a corregirse.

¹²*Principal Component Analysis*, es una técnica que disminuye el número de variables de un dataset, preservando la mayor cantidad de información y varianza posible y reduciendo así su complejidad

¹³Un *batch* o lote en IA se refiere al conjunto de datos que recibe una red en su entrenamiento de forma simultánea. Su uso sirve para la optimización de recursos y memoria.

Además, los cálculos necesarios durante la ejecución se aceleran con shaders en GPU (*GPU decompression*) y se recalculan las normales de los vértices necesarias para el renderizado.

Sus principales limitaciones residen en la necesidad de quitar a mano errores producidos en la simulación, falta de pruebas en objetos plásticos y posibles colisiones internas fallidas. Además, se resalta como limitación realizar el entrenamiento con un objeto colisionador fijo en el espacio, sin habilitar situaciones más dinámicas como por ejemplo, un escenario en el que objetos caigan por el espacio. Finalmente se remarca la cantidad elevada de datos y tiempo empleados para los entrenamientos: se necesitaron hasta 10^6 frames de simulación como referencia para obtener buenos resultados, así como entre 10 y 48 horas de entrenamiento.

2.5.1.2. Cloth and Skin Deformation with a Triangle Mesh Based Convolutional Neural Network

Este estudio [Chentanez et al. \(2020\)](#) es un ejemplo de uso de CNN (redes convolucionales ¹⁴), para la simulación de telas. Reseña la dificultad de integrar una CNN debido a la construcción de la malla, incompatible antes de su modificación con una cuadrícula 2D. Resuelve el problema entrenando mallas "manifold" triangulares: es decir, mallas cuyos bordes están conectados por al menos dos caras (menos los extremos) dejando una separación entre exterior e interior. Mapear la malla a una imagen 2D es lo que permite realizar la convolución.

La solución planteada en este trabajo es el uso de una red encoder-decoder ¹⁵ formada por bloques “DownConv”, para la reducción, y “UpConv”, para la reconstrucción, que integra operadores nuevos de convolución ¹⁶. En el bloque de “DownConv”, utiliza una técnica de pooling destacable: colapasa los edges siguiendo un método en espiral. También señala la importancia de usar Leaky-CNN: para no dejar neuronas muertas, que resulta un problema en la simulación. Además de combinar funciones de pérdida L_2 y L_1 ¹⁷. para que no se quede el error acumulado en ciertos vértices.

Este estudio, a diferencia del anterior, incluye brazos y manos, y se rige en un marco de posiciones locales por cada triángulo. Afirma conseguir resultados muy

¹⁴Las redes neuronales convolucionales (CNN) son un tipo de arquitectura de DL diseñada para el procesamiento de datos estructurados en forma de cuadrícula, como imágenes, vídeos o secuencias temporales

¹⁵**Red encoder-decoder:** Arquitectura de red neuronal diseñada para mapear una secuencia de entrada a una secuencia de salida, donde ambas pueden tener longitudes diferentes. El *Encoder* comprime la información de entrada para operar con ella fácilmente, y el *Decoder* procesa esa representación para generar la salida con las dimensiones reales.

¹⁶**Convolución:** Operación matemática donde un filtro o *kernel* realiza multiplicaciones elemento a elemento, permitiendo extraer patrones estructurales.

¹⁷ **L_2 y L_1 :** Funciones que miden la diferencia entre el valor real y el predicho. La pérdida L_1 (Error Absoluto Medio) calcula la suma de las diferencias absolutas, siendo robusta frente a valores atípicos. La pérdida L_2 (Error Cuadrático Medio) calcula la suma de los cuadrados de las diferencias, penalizando fuertemente los errores grandes.

cercanos al *ground truth*¹⁸ usando la base de animaciones *Berkley animation base* y una gran capacidad de hardware disponible. No obstante, resaltan una vez más los largos tiempos de entrenamiento (entre 4 y 20 horas) y la necesidad de calidad y cantidad de datos de entrenamiento. Tampoco aporta simulaciones para topología dinámica¹⁹ y se ciñe mucho al entrenamiento. Debido a la arquitectura de CNN triangular, sumado al objetivo de alcanzar velocidad y detalle en assets específicos, se pierde la capacidad de generalización.

Otro ejemplo de estudio que usa una CNN para la simulación de telas es DeepSD: Real-time Cloth Simulation with Deep Learning Bertiche et al. (2021b); en la que proyecta la malla 3D en un plano utilizando sus coordenadas UV²⁰. Usa una CNN estándar, y no depende de una malla fija, pudiendo aceptar cambios en la topología de la malla, por lo que sirve para automatizar el proceso. El uso de SDF garantiza la generación de ropa que envuelva el cuerpo sin importar la conectividad de la malla durante los cálculos intermedios. No obstante, comparando con el estudio de Chentanez et al. este estudio no consigue capturar arrugas finas o superficiales con detalle y es menos eficiente debido a su enfoque volumétrico.

2.5.1.3. PBNS: Physically Based Neural Simulation for Unsupervised Garment Pose Space Deformation

PNBS Bertiche et al. (2021a) presenta una simulación neuronal DL no supervisada, como alternativa al enfoque clásico PBS. Integra principios físicos en el entrenamientos con funciones físicas de energía, entre ellas restricciones de fijación. La arquitectura consiste en un perceptron multicapa (MLP, por sus siglas en inglés *Multi-Layer Perceptron*) con funciones ReLU²¹ que genera deformaciones tipo PSD sobre modelos LBS, cuya aplicación en el mundo 3D garantiza la compatibilidad con los motores gráficos y su alta eficiencia. Esta metodología entrena sobre datasets públicos como *AMASS* Mahmood et al. (2019) y *CMU MoCap*, siendo capaz de manejar colisiones en poses extremas, así como colisiones cloth-to-cloth. Asimismo, permite la obtención de prendas que se ajustan a diferentes cuerpos (garment resizing). En comparación a otros métodos como TailorNet Patel et al. (2020), logra una mayor consistencia física y generalización, además de un coste computacional considerablemente menor, incluso sin GPU. Sin embargo, se ve limitado por su enfoque en poses estáticas.

¹⁸El *ground truth* es la información verdadera o correcta, a diferencia de los datos producidos por inferencia. En el caso de una recrear una simulación con ML podría consistir en el conjunto de animaciones creadas para entrenar o validar, es decir, los movimientos y comportamientos correctos".

¹⁹La topología dinámica aquí se refiere a la topología adaptativa en mallas, requeridas en aplicaciones de diseño y edición de mallas.

²⁰Las UVs son coordenadas bidimensionales que definen cómo se proyecta una textura 2D sobre la superficie de un modelo 3D. El mapeo UV consiste en aplanar o desplegar una malla 3D sobre una superficie plana.

²¹Función de activación *Rectified Linear Unit* se define matemáticamente como $f(x) = \max(0, x)$

2.5.1.4. SNUG

Siguiendo la tendencia hacia el aprendizaje no supervisado basado en físicas, la técnica SNUG [Santesteban et al. \(2022\)](#) va más allá de la deformación basada en poses mencionado en el estudio anterior. Si bien trabaja con 6,519 fotogramas de la misma base de datos, gracias a una red recurrente (cuya arquitectura no se explica con exactitud) consigue mejores tiempos de entrenamiento y resultados más detallados que la técnica anterior. Pone el foco del aprendizaje en crear una serie de funciones de loss basadas en las físicas reales de deformaciones dinámicas: “Membrane Strain Energy” (la energía transmitida entre dos puntos en base a la elasticidad del material), “Bending Energy” (el ángulo diédrico entre dos caras en relación a su propiedad de rigidez), “Gravity” (gravedad) y “Collision Penalty” (la distancia prudencial entre el modelo y el cuerpo).

2.5.1.5. Neural Cloth Simulation

Neural Cloth Simulation [Bertiche et al. \(2022\)](#) también propone una metodología no supervisada, unificando simulación y entrenamiento. Sigue el esquema clásico de este tipo de solvers, donde el estado de la tela depende de los instantes previos, gestionado por ventanas de frames cuyo tamaño y complejidad dependen del tipo de tela procesada. Su arquitectura consiste en un encoder-decoder recurrente que separa componentes estáticos y dinámicos, haciendo uso de modelos GRU en estos últimos y la cual permite mejorar la generalización y estabilidad del entrenamiento. Este se realiza mediante funciones de pérdida inspiradas en simulación física, incluyendo restricciones físicas en relación a deformaciones, colisiones e inercia. El dataset utilizado también es AMASS [Mahmood et al. \(2019\)](#), que recopila información de mas de 40.000 poses, y el modelo físico extiende la idea del modelo mass-spring [Provot et al. \(1995\)](#). En comparación con PBNS o SNUG, esta metodología consigue soluciones más robustas y simples que dan a simulaciones detalladas a costa de mayores tiempo de entrenamiento que sus predecesores, compensando, no obstante, la disminución de recursos al no realizar procesos de generación de datos. Esta perspectiva va de la mano con tendencias actuales en la industria, como la ya mencionada e implementada Chaos Cloth de Unreal Engine.

2.5.1.6. HOOD: Hierarchical Graphs for Generalized Modelling of Clothing Dynamics

En investigaciones más recientes, se aborda la cuestión de la posibilidad de abstraer también la topología de la tela del aprendizaje. En este caso, HOOD utiliza GNNs, una arquitectura de envío de mensajes jerárquico y por supuesto la función de pérdida basada en la física que puede verse en los previos estudios [Grigorev et al. \(2023\)](#). Los graph neural networks permiten crear un gráfico que incorpora los vértices del cuerpo colisionador. A través de este se propagan los mensajes de aceleración recursivamente, lo que permite ajustar la precisión de la inferencia y adaptarse a distintos materiales, topologías y modelos de colisión.

Este estudio sigue estando limitado en aspectos como la velocidad de simulación

o colisiones internas. Al fin y al cabo, este sigue siendo un campo de estudio en crecimiento, en el que todavía queda mucho por avanzar.

2.5.2. Librerías

Por último, en este apartado se describen las librerías que han resultado indispensables para entrenar los modelos de IA y conectarlos a la simulación en Unity.

2.5.2.1. Pytorch

Pytorch²² es una de las librerías de código abierto que permite implementar redes neuronales propias. Los tensores²³, matrices multi-dimensionales análogas a los NumPy arrays de Python, permiten optimizar las redes tanto para el uso de CPU como de GPU. Suele ser la más elegida en entornos académicos, ya que permite prototipado rápido y entrenamiento dinámico. Fue originalmente desarrollado por Meta, y todavía cuenta con una enorme comunidad de desarrolladores.

2.5.2.2. ONNX

ONNX (*Open Neural Network Exchange*)²⁴ es un formato creado para representar modelos de aprendizaje automático. Fue introducido por Facebook y Microsoft en 2017, con el objetivo de facilitar el cambio de entornos de trabajo en aprendizaje automático. Estandariza la estructura de redes neuronales y tipos de datos, definiendo un conjunto común de operadores y un formato de archivo estándar, permitiendo entrenar y desplegar modelos entrenados en distintos ecosistemas. Es un formato ampliamente aceptado por fabricantes de hardware como NVIDIA o Intel, que proporcionan proveedores de ejecución especializados para la conexión.

2.5.2.3. Sentis

Sentis (previamente Inference Engine)²⁵ es una librería de inferencia de redes neuronales para Unity, predecesora introducida en el 2023 de la librería Barracuda. Permite importar modelos de redes neuronales entrenados a Unity y ejecutarlos en tiempo real tanto con la CPU como con la GPU de forma local en el usuario, reduciendo latencia y costes de servidores en la nube.

Los modelos pueden ejecutarse localmente en las plataformas que soportan Unity, lo que permite que pueda adaptarse a diferentes tipos de hardware: tanto en PC, como en móviles, consolas o web. Su compatibilidad reside en los modelos importados en formato ONNX, cuyos grafos se optimizan después para la ejecución del juego.

²²Documentación de Pytorch: <https://docs.pytorch.org/docs/stable/index.html>

²³Documentación correspondiente a los tensores: <https://docs.pytorch.org/docs/2.12/tensors.html>

²⁴Página web de ONNX: <https://onnx.ai/>

²⁵Documentación del paquete Sentis: <https://docs.unity3d.com/Packages/com.unity.ai.inference@2.4/manual/index.html>

Algunos usos de Sentis son las estimaciones de poses en tiempo real o NPCs que reaccionen a texto o voz del jugador.

Capítulo 3

Arquitectura de la Solución

3.1. Arquitectura General

El desarrollo de las pruebas de este proyecto se divide en tres secciones; la de simulación, la de entrenamiento del modelo y la de inferencia. En este apartado se explican estas de manera general, para crear una base de entendimiento del pipeline. En los proximos apartados del capítulo se explica cada elemento de manera más exhaustiva, con las distintas iteraciones y mejoras conseguidas a raíz de la investigación.




Figura 3.1: Diagrama de la arquitectura General del proyecto

Como puede apreciarse en la figura 3.1, el pipeline del proyecto es circular, es decir, la plataforma en la que se genera la simulación y posteriormente se prueba la inferencia del modelo es la misma; en nuestro caso, Unity. Esto se debe a dos de nuestros objetivos: el de hacer un sistema accesible y fácil de utilizar y el de poder comparar verazmente la optimización de la simulación física.

- **Simulación:** Si bien se han llevado a cabo pruebas con distintas geometrías

y tiempos, colisionadores con distintos tipos de movimiento y aleatoriedad de los mismos, las bases de las escenas es equivalente. La simulación, en el que la tela actúa con componente Cloth de Unity, pasa por un sistema de registro con el que se crea un archivo CSV que recoge la información de la geometría simulada y las variables pertinentes.

- **Entrenamiento:** Estos archivos se recogen en una carpeta que pasa a procesarse en un entorno de python. Con las librerías explicadas en el estado del arte se han entrenado distintos modelos, realizando pruebas sobre diferentes técnicas e hiperparámetros. La efectividad de estos modelos se mide inicialmente dentro del entorno de python midiendo el error de distancia real de los vértices, visualizando la progresión a través de distintos frames.
- **Inferencia:** Posteriormente se exportan estos modelos ya entrenados en formato ONNX a la escena de Unity, en la que se hizo la simulación inicial y correspondiente recogida de datos. Haciendo uso de la arquitectura dirigida a objetos de Unity, se cambia la configuración de la geometría inicial y se incorpora el modelo entrenado y sus parámetros, consiguiendo así inferir el movimiento de la tela en tiempo real. Se confirma que la simulación es visualmente fiel a las físicas reales, tanto por sí misma como comparándola con la Cloth original de Unity.

3.2. La fase de simulación

Para lograr entrenar un modelo de Inteligencia Artificial que recree el movimiento de una tela se requiere de un dataset que represente el comportamiento de esta. En este apartado se explicará el proceso de obtención de datos, comenzando con qué tipo de simulación se elige para el estudio, continuando con las características o parámetros que mejor definen la tela y finalizando con la recogida de valores y creación del dataset a emplear en el entrenamiento. Todos los datos son generados de forma interna, creándose a partir de simulaciones de telas grabadas en Unity, por lo que se explicarán los componentes en la escena que permiten llevar esto a cabo.

3.2.1. La simulación

La simulación base que se emplea para entrenar y ajustar los modelos se lleva a cabo en un escenario formado por un plano-tela de 25 vértices con la parte superior fija en el espacio y una esfera que colisiona con la tela para generar movimiento en ella.




Figura 3.2: Malla de 25 vértices con parte superior fija.

El movimiento de la bola que colisiona con la tela está descrito por un componente *BallMovement*. Este puede ser automático o generado a través de entrada con el teclado. El movimiento automático tiene dos movimientos descritos:

- **Movimiento lineal:** ideado para provocar un movimiento sencillo que entienda el modelo fácilmente, sin deformaciones extremas o erráticas, y utilizado para poder llevar a cabo overfitting. Se emplea durante fases iniciales del desarrollo para estabilizar el modelo sobre un movimiento simple. El movimiento consiste en oscilar entre dos posiciones fijas en el espacio a lo largo del eje x.
- **Movimiento aleatorio:** pretende facilitar la generación de un dataset con diversidad de movimientos de forma automática, así como introducir a la tela más dinamismo y movimientos erráticos. Este desplazamiento en tres ejes aleatorio se consigue a través del uso de splines. En la escena se encuentra un objeto con el componente creado *PathGenerator* que delimita una zona de generación y aporta la creación de splines en *SplineContainers* a partir de una posición concreta. El componente de Unity *SplineAnimate* se encargará de mover la esfera por el camino hasta llegar al final del mismo; y en ese instante se generará un nuevo camino aleatorio para continuar con su recorrido.




Figura 3.3: Movimiento aleatorio basado en splines.

El movimiento aleatorio es el empleado para generar datasets para los experimentos y mayor parte del desarrollo del proyecto, pues aporta mayor número de deformaciones e información de la tela, dando capacidad de generalización al modelo. La zona de generación de movimientos de la bola está ajustada de tal forma que se aumente el número de colisiones con la tela en el tiempo de la simulación sin realizar deformaciones exageradas.

3.2.2. Otras simulaciones

También cabe mencionar brevemente que durante el desarrollo del proyecto se han realizado pruebas con simulaciones más complejas con objeto de probar la efectividad de nuestro método y diferencias entre simulaciones más dinámicas y estáticas, más frecuentadas en PBD. Realizar estas pruebas más complejas resultó incompatible con nuestra plataforma elegida y capacidad de cómputo.

Para probar el enfoque más estático y pegado al cuerpo se creó una simulación de un personaje con una camiseta. Tras múltiples pruebas tomando diferente número de iteraciones en el solver de Cloth, valores en las propiedades de la tela y extendido el tamaño hasta 4000 vértices, la simulación fue finalmente descartada debido a la inestabilidad de la tela y difícil generación de animaciones visualmente coherentes. Realizar animaciones de tela complejas en Unity sin combinar otras técnicas, implementar soluciones híbridas (como el Weight Mapping¹) o incorporar paquetes de pago de la Unity Asset Store como Magica Cloth ² u Obi Cloth no es trivial. Otras investigaciones, como Holden et al. (2019) producen su material de entrenamiento en herramientas especializadas como Maya ³ o Blender ⁴ para conseguir simulaciones de prendas complejas. Pese a que esto limita el alcance de las simulaciones a generar en esta investigación, el nivel de complejidad potencial sigue siendo más que suficiente para probar nuestra implementación a pequeña escala, manteniendo el proyecto alienado a los objetivos previamente declarado y siguiendo la tendencia de juegos implementados en Unity.

¹Técnica de animación 3D y rigging que permite controlar cómo se deforman los vértices de una malla o prenda al mover las articulaciones de un esqueleto.

²Paquete de Magica Cloth en el Asset Store de Unity: <https://assetstore.unity.com/packages/tools/physics/magica-cloth-2-242307>

³Autodesk Maya es un software profesional de animación y efectos visuales 3D <https://www.autodesk.com/es/products/maya/overview>

⁴Blender es un software de código abierto de animación y efectos visuales 3D <https://www.blender.org/>



Figura 3.4: Simulación de una camiseta con componente Cloth.




Figura 3.5: Simulación de una falda con componente Cloth.

3.2.3. Los parámetros

Las telas que usamos para generar las simulaciones en las que se basan nuestros modelos son objetos formados por mallas con un componente Cloth (y su correspondiente *Skinned Mesh Renderer*) y un componente de grabación propio *ClothDatasetRecorder*, encargado de guardar los datos de la simulación. Se plantea recoger diferentes parámetros que representen las características más importantes de la tela durante la simulación:

- **Posición:** Las posiciones de los vértices de la tela son los parámetros básicos de las investigaciones en este campo.
- **SDF:** El Signed Distance Field es una magnitud que representa la distancia de cada vértice al objeto colisionador, llegando a ser 0 si toca la superficie, y un valor negativo si alcanza a traspasar. Se ha creado la clase estática *SDFUtil* para habilitar los cálculos del SDF para conjuntos de *colliders* en escenarios más complejos. El script *SDFUtil* contiene métodos que proporcionan el SDF de un punto a una esfera, una cápsula o dos listas de los dos tipos. También acepta un *Transform* de un objeto de referencia si la posición del punto de origen no es global.

Las fórmulas de SDF, así como la obtención de un único SDF respecto a varios objetos, que se ha decidido representar con el *Smooth Minimum* (*smin*), se han adquirido del blog de Inigo Quilez⁵ y adaptado para el funcionamiento esperado en Unity. La función *smin* permite fusionar dos objetos de geométricamente con una transición que puede ser suave o limitarse al espacio real ocupado por los objetos.

- **Velocidad:** Planteamos que las velocidades de los vértices pueden ayudar a que el modelo sea capaz de replicar el dinamismo del movimiento.

⁵Apartado del blog de Inigo Quilez sobre SDFs para objetos 3Ds: <https://iquilezles.org/articles/distfunctions/>

- **Normales:** Refiriéndose a las normales de la superficie del objeto colisionador, es decir, el gradiente del SDF. Este se puede usar para complementar la magnitud del SDF, ya que apunta en la dirección en la que la distancia aumenta más rápido, cómo alejarse de la colisión.
- **UVs:** Conservar la geometría de la tela se plantea como uno de los mayores retos para nuestra simulación. Se necesita que el modelo comprenda cómo están relacionados los vértices espacialmente para que no se lleven a cabo deformaciones erróneas. Ya que no comenzamos con geometrías complejas en tela o cuerpos blandos, se usan las coordenadas de textura bidimensionales, *UVs*, para representar la superficie.
- **Máxima Distancia:** Cada vértice tiene una distancia máxima a la que un vértice se puede mover desde su posición en la malla *skinned*⁶. Se quiere conseguir que los vértices no se pasen de su rango hábil de movimiento. Si no se toma como parámetro, esto puede corregirse también en post-procesamiento.

3.2.3.1. Sistema de coordenadas

Cabe recalcar que el registro de las posiciones se realiza de forma local respecto al pivote de la tela. Pese a que tanto utilizando posiciones globales (reales en el mundo) como locales se mantiene la consistencia y un origen único de coordenadas, las posiciones locales son más relevantes para los modelos y los resultados no son dependientes de las traslaciones en el espacio. Se ha confirmado la relevancia de emplear un **sistema de coordenadas local** tras evaluar el desempeño del modelo con datasets relativos a ambos sistemas.

En Cloth, las posiciones de los vértices de la tela ya se obtienen de forma relativa a su pivote. Unity proporciona los métodos *TransformPoint(Vector3 position)* y *InverseTransformPoint(Vector3 position)* para obtener coordenadas de mundo a partir de coordenadas locales de un objeto y para pasarlas a coordenadas locales a partir de un transform respectivamente. Se utilizan estos métodos para realizar todos los cálculos y proporcionar al modelo los datos en el mismo sistema de coordenadas.

3.2.3.2. Elección de parámetros finales

Ante la gran cantidad de datos recogidos, se investigan maneras de seleccionar las características más esenciales para el entrenamiento. Tras confirmar con estudios como [Chen et al. \(2020\)](#) o [Iranzad y Liu \(2025\)](#) que el uso de modelos *Random Forest* para la reducción de features puede ser interesante, se implementa uno de estos modelos para ver cuáles son los parámetros más importantes para la inferencia. Se mide la importancia de Gini, esta métrica mide la reducción media de la impureza (MDI por sus siglas en inglés: Mean Decrease in Impurity), es decir, cuánta varianza o error reduce cada variable a lo largo de las divisiones en los nodos de todos los

⁶Una *skinned mesh* es una malla poligonal 3D cuyos vértices están unidos a un esqueleto jerárquico de huesos, que permite la deformación dinámica de sus vértices.

árboles. Sumando la importancia acumulada sobre los ejes temporales y espaciales (vértices de la malla), se consigue obtener la importancia de cada una de las 13 propiedades del dataset. Como se ve en la figura, los parámetros U, V y MD resultan no ser importantes para generar la predicción. Sin embargo, se aprecia la importancia de los parámetros de velocidad. En este caso es más notable en el eje x, debido a la configuración de la simulación con la que se ha generado el dataset analizado para el gráfico (3.6).




Figura 3.6: Parámetros valorados por el random forest.

3.2.4. Generación del dataset

A través del componente *ClothDatasetRecorder* realizamos un “snapshot” o captura de la tela cada intervalo de tiempo *recordTime*, que se declara en el inicio del desarrollo como 3.5 segundos. Estos datos del frame se guardan en una estructura *SnapInfo*, que representa la información de los vértices de la tela en un instante de tiempo determinado, y se añade a una lista de capturas de la simulación. Al final de la ejecución todas estas capturas se transforman en texto y se vuelcan en un CSV, por lo que cada línea del archivo corresponde a un frame capturado.

Algorithm 1 Struct *SnapInfo*: representación de un frame

```

Data: SnapInfo {
    pos: array de Vector3 ;                                ▷ posiciones
    vel: array de Vector3 ;                                ▷ velocidades
    normal: array de Vector3 ;                              ▷ normales
    sdf: array de float ;                                  ▷ signed distance field
    maxDist: array de float ;                              ▷ distancia máxima
    uv: array de Vector2 ;                                  ▷ coordenadas UV
}

```

Durante el inicio del estudio se probaron distintas frecuencias de muestreo (0.1f,

0.02f, la frecuencia por defecto del *FixedUpdate()* en Unity); pero más tarde se llegaría a la conclusión de que la frecuencia de muestreo debe ser la misma en la etapa de guardado de datos y ejecución del modelo. De la misma forma, el número de snapshots debe ser el máximo posible para garantizar la estabilidad de la simulación. Al tratarse de una simulación con inercia y no basada en poses, la frecuencia no admite reducciones.

3.3. La fase de entrenamiento

En este apartado se describen las fases de entrenamiento de los modelos, así como la evolución de los mismos y la serie de decisiones tomadas para conseguir esas adaptaciones. El código al que se hace referencia puede encontrarse en el directorio /Entrenamiento del repositorio de GitHub del proyecto ⁷.

3.3.1. El entorno de trabajo

Para crear un entorno de trabajo adaptable, y asegurar la consistencia entre los distintos equipos utilizados por las integrantes de este proyecto, se ha decidido crear en el repositorio un archivo *dl2024_gpu.yml* en el que concretar las dependencias del proyecto y las versiones a utilizar de estas librerías. Este es un tipo de archivo de configuración que permite, entre otras cosas, crear fácilmente Conda Environments. Estos entornos virtuales se generan en un directorio con todas las dependencias especificadas. Se ha utilizado como base el entorno propocionado por la Universidad de Amsterdam en sus cursos introductorios de Deep Learning con Pytorch.

Librerías utilizadas	Versiones
python	3.12.7
cmake	-
notebook	7.2.2
jupyterlab	4.2.5
matplotlib	3.9.2
scikit-learn	-
pytorch-cuda	11.8
pytorch	2.5.0
onnx	1.21.0
onnxruntime	1.24.2
onnxscript	0.5.6
skl2onnx	1.20.0

Tabla 3.1: Librerías y versiones del entorno de desarrollo.

⁷Enlace a la carpeta de entrenamiento: https://github.com/mikeletzu/TFG_FisicaOptim/tree/23105b6733caca9c708593f2d77a12faa2eb884/Entrenamiento

3.3.2. Apartados de la ejecución del entrenamiento

Se ha empleado una combinación de IPython Notebook (.ipynb) para visualizar los resultados y segmentar el proceso, y archivos .py con los modelos y funcionalidades comunes para llevar a cabo los entrenamientos. Los entrenamientos tienen la siguiente forma:

1. **Carga y procesamiento de datos:** Los datos se leen del archivo .csv utilizando la librería pandas, que permite llevar a cabo la limpieza fácilmente. Aunque es el dataset del modelo quien gestiona detalles como la coherencia de frames otorgados, intentar acceder al predecesor de un primer frame, se realiza una limpieza común previa del csv:
 - Se elimina la columna "frame" de la tabla, ya que no aporta información pertinente para el aprendizaje. Su función es meramente auxiliar para depurar.
 - Asimismo, en los casos que se explicarán más adelante, muchos de los parámetros registrados no son necesarios, se filtran esas columnas para no sobrecargar innecesariamente el dataset.

Tras hacer la limpieza de los datos estos se transforman al formato de tensores de Pytorch.

2. **Dataset de Pytorch:** Pytorch ofrece dos clases base con las que ordenar y gestionar los datos que requiere el modelo. *Torch.utils.data.Dataset* almacena las muestras y sus etiquetas correspondientes, y *torch.utils.data.DataLoader* permite un fácil acceso a las muestras. En este bloque se definen las características del Dataset en base a las necesidades del modelo; este recibe en su constructora el tensor con la información filtrada y el tamaño de los lotes en los que dividirlo.
3. **Normalización:** Se dividen los datos siguiendo un split temporal, donde el primer 80 % de los frames se utilizan para el entrenamiento y el 20 % restante para las pruebas. Se itera sobre los datos de entrenamiento para calcular los deltas⁸ y se normaliza tanto el input completo como los deltas generados para los datos de entrenamiento. La normal y la desviación típica tanto del input como del target se guardan en un archivo de formato JSON *cloth_norm_params.json*. Posteriormente, estos datos se utilizan para generar el input del modelo en la ejecución de Unity, ya que este requiere que la estandarización de los datos con los que se entrenó la red sea la misma que la de los datos en ejecución.
4. **Modelo de Pytorch:** Pytorch ofrece también una clase base a partir de la cual implementar modelos de redes neuronales, *torch.nn.Module*. En este apartado se extiende esta clase a las especificaciones deseadas y se genera utilizando el DataLoader mencionado un primer batch de prueba.

⁸**Deltas:** Hace referencia al desplazamiento de cada vértice en cada frame en los ejes X, Y y Z.

5. **Entrenamiento:** En este apartado se determinan los parámetros del entrenamiento: *learning rate*, iteraciones, porcentaje de ruido y etc. El entrenamiento consiste en una fase de entrenamiento y otra de testing, en la que se observa el aprendizaje del modelo a través de la caída del error medio de la posición de cada vértice.
6. **Visualización de resultados:** Al trabajar con una simulación física en un entorno 3D, la visualización en gráficos de las predicciones de los modelos ha resultado notablemente útil. En las figuras 3.7, 3.8 y 3.9 pueden apreciarse los gráficos más destacados que más han contribuido al desarrollo.




Figura 3.7: Visualización de los puntos de la tela simulada e inferida a lo largo del tiempo.




Figura 3.8: Visualización del error medio a lo largo del tiempo




Figura 3.9: Visualización de error de normalización

7. **Exportación:** Por último, tras considerar los resultados generados como adecuados con la guía de los valores y gráficas generadas, se procede a exportar la red neuronal a formato ONNX.

3.3.3. Modelos

Para lograr simular el comportamiento de la tela, los modelos entrenados infieren la diferencia de desplazamiento de cada vértice entre un frame y el siguiente. El

funcionamiento base de todos los modelos entrenados consiste en recibir una entrada construida a partir de la posición, velocidad y SDF normalizados de los vértices aplanados en un vector, y obtener como output los deltas de desplazamiento normalizados. Para el aprendizaje, los modelos emplean como función de pérdida *L1Loss*, esta es una función proporcionada por Pytorch que calcula el error absoluto medio entre dos valores, generalmente el valor inferido por el modelo y su análogo real del dataset.

$$\mathbf{x}_t = [\hat{x}_1, \hat{y}_1, \hat{z}_1, \hat{v}_1^x, \hat{v}_1^y, \hat{v}_1^z, \hat{s}_1, \dots, \hat{x}_n, \hat{y}_n, \hat{z}_n, \hat{v}_n^x, \hat{v}_n^y, \hat{v}_n^z, \hat{s}_n] \quad (3.1)$$

$$\hat{\boldsymbol{\delta}}_{t+1} = f_{\theta}(\mathbf{x}_t) \in \mathbb{R}^{3n} \quad (3.2)$$

$$\mathbf{p}_{t+1} = \mathbf{p}_t + \hat{\boldsymbol{\delta}}_{t+1} \quad (3.3)$$

Donde $\hat{\cdot}$ denota normalización, n el número de vértices, s_i el SDF del vértice i .

Partiendo de esta idea principal del entrenamiento, en los próximos apartados se explicarán las diferentes técnicas y tipos de redes implementadas para la optimización del mismo. Estas se eligen a partir de las dos nociones principales que guían el desarrollo de este proyecto: por un lado, combinar las técnicas óptimas y prometedoras de las investigaciones citadas en el estado del arte; y por otro, priorizar la simplicidad y accesibilidad de nuestro modelo en la plataforma elegida. Se han seleccionado redes específicas y características que permiten llegar a un movimiento de tela coherente, y sobre ellas se realizará posteriormente, en los capítulos 4 y 5, una serie de experimentos y comparativas para medir su desempeño, así como una discusión y evaluación final respectivamente. Separamos las características que conforman los modelos en los siguientes campos:

3.3.3.1. Tipos de redes y recurrencia

Este estudio se ha enfocado en dos tipos de redes neuronales que se alienan con el objetivo de emplear modelos sencillos: los **perceptrones multicapa (MLP)** y las **redes neuronales recurrentes (RNN)**. Otras redes como las CNN o las GNNs han sido descartadas debido a la alta complejidad para representar y proporcionar los datos al modelo.

- [Holden et al. \(2019\)](#) resalta el MLP como una red sencilla, computacionalmente más accesible que las CNNs empleadas en otros estudios, y que mantiene la capacidad de proporcionar resultados adecuados mediante técnicas adicionales, como hemos visto anteriormente, subespacios y correcciones en post-procesamiento. En este estudio se opta por incorporar una MLP con cuatro capas ocultas ReLU y una lineal para producir la salida (cinco capas densas).
- Por otra parte, empleamos una RNN para comprobar si la memoria recurrente proporciona una mejoría respecto a la gestión del movimiento dinámico y la

conservación de la geometría a través del tiempo. Varias de las investigaciones del estado del arte, como por ejemplo [Santesteban et al. \(2022\)](#), mencionan como limitación las telas más dinámicas, ya que, al tener muchas menos restricciones, las mallas que no van pegadas a un cuerpo de colisión son mucho más susceptibles a la inercia. La recurrencia permite al modelo tener una memoria a corto plazo del movimiento en cada vértice, haciendo su entrenamiento mucho más eficaz. Sigue la arquitectura de tipo *many to one*, donde una cantidad determinada de frames se utilizan como input para generar el delta de desplazamiento entre el último frame de la secuencia y el que sería el siguiente.

La diferencia entre ambos modelos se resalta por tanto en la falta de un estado oculto que sea capaz de capturar progresiones temporales. La recurrencia y el *many to one*, que vemos en redes como las RNNS, GRUs o LSTMs conllevan altos tiempos de entrenamiento, así como un incremento en el tiempo de inferencia y memoria, al tener que procesar constantemente más de un frame. Se quiere comprobar en el experimento correspondiente si, empleando técnicas equivalentes, la recurrencia aporta a la simulación de tela altamente dinámica una calidad que compense el coste de tiempo tanto en el entrenamiento como en la ejecución.

3.3.3.2. Gestión de error acumulado




Figura 3.10: Error acumulado

Una simulación sin restricciones específicas tiende a la acumulación de error a través del tiempo, lo que implica que pequeños desplazamientos se convierten rápidamente en movimientos erráticos y de gran magnitud. Las altas tasas de frames, como serían los estándar 60 frames por segundo en videojuegos a tiempo real, aceleran lo rápido que una simulación se desestabiliza. Como se explicará en el siguiente apartado, varios estudios del estado del arte lidian con esto a través de métodos de post-procesado en la fase de inferencia, como límites físicos o modelos que pueden funcionar tanto de correctores como para refinar los detalles (arrugas, intersecciones con el colisionador, etc.) como en TailorNet [Patel et al. \(2020\)](#). No obstante, existen maneras de evitar el error de antemano, reforzándolo en el entrenamiento a través de la función de pérdida, de esta manera el modelo aprende a autocorregirse y

conservar la geometría original de la tela, así como a evitar movimientos extremos a medida que avanza la simulación.

Las técnicas más favorables que se han seleccionado para este estudio son las siguientes:

- **Ruido en el input:** Una de las técnicas más sencillas para mejorar la capacidad del modelo de corregir sus errores es entrenarlo creando pequeños errores de forma artificial. Esto se consigue añadiéndole ruido a los datos de entrada, en este caso se añade un ruido gaussiano de entre un 1 y un 3 % de magnitud respecto a los datos de entrada antes de normalizar. De esta manera, el modelo aprende a corregir estos errores para corregir los suyos propios en un futuro.
- **Unrolling for training:** Esta técnica consiste en crear una secuencia de predicciones, esto permite al modelo tener una noción sobre el cambio de velocidad y aceleración provocados con sus predicciones de desplazamiento. Tomando como ejemplo el RNN, que como se ha explicado previamente sigue la arquitectura *many to one*, el unrolling permite que esta ventana se deslice, avanzando a lo largo del tiempo. Los deltas inferidos en el primer paso se utilizan para calcular la nueva posición de los vértices en el siguiente frame; esta posición predicha sumada al resto de características reales del frame se añaden al final de la ventana. Este proceso se repite sucesivamente, como puede verse a continuación.
 - **Ventana inicial:** $V_0 = [y_{t-n+1}, \dots, y_t]$
 - **Bucle de predicción:** Para $i = 1, 2, \dots, W$:
 1. Calcular predicción: $\hat{y}_{t+i} = f(V_{i-1})$
 2. Actualizar ventana: $V_i = [V_{i-1} \setminus \{y_{primero}\}] \cup \{\hat{y}_{t+i}\}$

La implementación que se incorpora en este proyecto se inspira en la investigación de [Holden et al. \(2019\)](#) para añadir la técnica BPTT (*Backpropagation Through Time*). Además de retroalimentar los frames generados a la secuencia de input, se retropropaga el error a lo largo de la secuencia temporal, es decir, el loss de la predicción inicial contará con el error generado para todos los siguientes frames del unfolding. Para conseguir esto, se mantiene una variable de pérdida total a lo largo del bucle de predicciones y el loss final será la media del error en cada paso.

- **Función de pérdida (Loss):**

$$\mathcal{L} = \frac{1}{W} \sum_{i=1}^W (y_{t+i} - \hat{y}_{t+i})^2$$

En referencia al cálculo del loss de cada paso, se encuentran distintas maneras de abordarlo. El valor de desplazamiento inferido puede compararse con el real en crudo, utilizarse para calcular la posición absoluta y comparar esta o sumar a cualquiera de ellas otros criterios de rectificación. En los estudios más recientes en particular, se utilizan funciones de pérdida basadas en reglas físicas. [Santesteban et](#)

al. (2022) o Bertiche et al. (2021a) juzgan la conformidad de las predicciones con la elasticidad, rigidez, distancia a los colisionadores y demás propiedades de la tela. De manera similar, Chen et al. (2025) aplica el concepto de una función de pérdida *force-impulse* que penaliza tanto el error en la fuerza predicha como el impulso que esta genera para las siguientes inferencias.

No obstante, en el caso de esta investigación se estudiará una loss basada en la comparación de datos, combinando los siguientes valores.

- *LossPos*: Compara la posición absoluta inferida para el frame con la posición real. El unfolding hace que los errores de inferencia al calcular el desplazamiento se vayan sumando a la posición del primer frame del bucle de predicciones, por lo que el modelo puede tener en cuenta sus errores.
- *LossVel*: Compara la velocidad predicha con la real, entendiendola como desplazamiento por frame.

Sin embargo, el objetivo de aplicar esta técnica no se trata únicamente de afinar las predicciones del modelo, sino también de hacer que el modelo aprenda a corregirse. Para ello se altera el calculo de *LossPos*. En vez de calcular las posiciones absolutas, se compara el desplazamiento inferido con el desplazamiento necesario para llegar a la posición real tras los pasos de unfolding. Aunando los valores reales con los predichos, se consigue reforzar en esa comparación la capacidad de corregirse en el mismo paso.




Figura 3.11: Comparación de métodos para el cálculo de *LossPos*. A la izquierda se encuentra el primero mencionado, comparando la posición absoluta inferida para el frame con la posición real. A la derecha está el siguiente mencionado, el desplazamiento inferido con el desplazamiento necesario para llegar a la posición real tras los pasos de unfolding.

Ambas técnicas pueden verse reflejadas en la siguiente función, *RunRollout()*, que lleva a cabo el cálculo de las predicciones y la pérdida de las mismas para cada lote de datos del dataset. Por simplicidad el modelo que se ha decidido representar por pseudocódigo recoge únicamente la posición y sdf como parámetros de entrada.

Algorithm 2 Función de *Unrolling* sobre RNN

```

function RUNROLLOUT(batch_seq, batch_future)
  batch_seq  $\leftarrow$  Secuencia de entrada real: tamaño windowSize
  batch_future  $\leftarrow$  Secuencia de unrolling real: tamaño rolloutSteps (W)
  window  $\leftarrow$  copia(batch_seq)  $\triangleright$  Copia para no alterar el tensor original
  noise  $\leftarrow \mathcal{N}(0, \sigma_{\text{noise}})$ 
  window[:, -N :]  $\leftarrow$  window[:, -N :] + noise  $\triangleright$  Inyección de ruido inicial
  total_loss  $\leftarrow$  0
  for k  $\leftarrow$  0 to W - 1 do
    prev_pred_pos  $\leftarrow$  window[:, -1, :, 0 : 3]  $\triangleright$  Posición inferida (t - 1)

    Inferencia:
    window_norm  $\leftarrow$  NormEntrada(window)
    pred_delta_norm  $\leftarrow$  Modelo(window_norm)  $\triangleright$  Delta inferido (t)
    pred_delta  $\leftarrow$  DesnormDelta(pred_delta_norm)
    pred_pos  $\leftarrow$  prev_pred_pos + pred_delta  $\triangleright$  Posición inferida (t)

    Comparación posición:
    real_pos  $\leftarrow$  batch_future[:, k, :, 0 : 3]  $\triangleright$  Posición real (t)
    real_delta_norm  $\leftarrow$  NormDelta(real_pos - prev_pred_pos)  $\triangleright$  Diferencia
    para corrección
    loss_pos  $\leftarrow \mathcal{L}_{L1}$ (pred_delta_norm, real_delta_norm)  $\triangleright$  Loss de posición

    Comparación velocidad:
    pred_vel_norm  $\leftarrow$  NormVel(pred_pos - prev_pred_pos)
    if k > 0 then  $\triangleright$  Velocidad real
      real_prev_pos  $\leftarrow$  batch_future[:, k - 1, :, 0 : 3]
    else
      real_prev_pos  $\leftarrow$  batch_seq[:, -1, :, 0 : 3]
    real_vel_norm  $\leftarrow$  NormVel(real_pos - real_prev_pos)  $\triangleright$  Delta real (t)
    loss_vel  $\leftarrow \mathcal{L}_{L1}$ (pred_vel_norm, real_vel_norm)  $\triangleright$  Loss de velocidad

    Feedback:
    new_frame  $\leftarrow$  ConstruirFrame(pred_pos, resto de propiedades reales)
    window  $\leftarrow$  [window[:, 1 :], new_frame]  $\triangleright$  Desplazar ventana temporal

    total_loss  $\leftarrow$  total_loss + loss_pos + ( $\gamma_{\text{vel}} \times \textit{loss\_vel}$ )
  return total_loss / W
end function

```

3.3.3.3. Reducción de dimensionalidad

Para conseguir alcanzar una mejora de rendimiento y complejidad en los modelos, se necesita reducir la dimensionalidad de las entradas y salidas del modelo. Se elige el **PCA** como método de reducción pues este se usa ampliamente para conservar las deformaciones principales en simulaciones complejas, pudiendo compactar la

información y reducir la complejidad, como se observa en estudios como [Holden et al. \(2019\)](#) o [Chentanez et al. \(2020\)](#). El movimiento físico de una tela no se rige únicamente por los vértices de su malla, sino que las deformaciones y restricciones físicas internas corresponden al movimiento de una estructura de menor dimensionalidad. Esto implica que se pueden extraer ejes de deformación que definen el movimiento, acelerando la obtención de las posiciones de la tela. La posición se reconstruye más tarde haciendo el proceso de PCA inverso, tanto en el entorno de entrenamiento como en el propio Unity. Una técnica adicional que se aplica y también se aprecia en el estudio de Holden consiste en el *clipping*, o en otras palabras, acotar las salidas PCA a los extremos encontrados en el training. Esto evita comportamientos extraños ante errores o situaciones no previstas. Cabe recalcar que en este estudio no se realiza el PCA sobre una posición ya calculada (como la integración de Verlet de Holden) o sobre ejes de rotación, sino sobre los propios deltas de posiciones. Esto se verá con más profundidad en el experimento y posterior discusión.

No obstante, cabe recalcar que la reducción conlleva un coste. Pese a aportar mejor rendimiento, un menor número de componentes compromete el nivel de detalle o la deformación en la simulación, y supone una mayor restricción geométrica para la tela. Para encontrar el punto intermedio entre coste de la inferencia y un movimiento más detallado, menos restrictivo, se elige un número de componentes que explican un umbral de varianza. En este estudio se emplea una varianza del 95 %.

El PCA empleado en el entrenamiento pertenece a la librería de sklearn. El cálculo del número óptimo de componentes se obtiene mediante a través del proporcionado `pca.explained_variance_ratio_.cumsum()`. Una vez obtenido, se aplica y ajusta el PCA sobre el dataset.




Figura 3.12: Ejemplo de componentes óptimos para PCA

Podemos definir la reducción de la siguiente forma:

Tanto en el entorno de entrenamiento como en la plataforma de simulación, Unity, se encuentran funciones que facilitan el cálculo de PCA sobre un conjunto de datos de vértices y su cálculo inverso, es decir, la obtención de la coordenada local xyz de los vértices.

Es importante resalta que el uso de PCA modifica en el modelo qué se entrena; la pérdida ya no consiste en el delta de posiciones, sino en el delta de PCA entre frames. Y quizá es la razón por la que es inestable...? Quién sabe. Pero va muy rápido.

Algorithm 3 Reducción de dimensionalidad mediante PCA**Entrenamiento**

Recopilar F frames de simulación: $\mathbf{D} \in \mathbb{R}^{F \times 3n}$

Ajustar StandardScaler: $\boldsymbol{\mu}_s, \boldsymbol{\sigma}_s \leftarrow \text{mean}(\mathbf{D}), \text{std}(\mathbf{D})$

$\hat{\mathbf{D}} \leftarrow (\mathbf{D} - \boldsymbol{\mu}_s) / \boldsymbol{\sigma}_s$

Ajustar PCA sobre $\hat{\mathbf{D}}$: obtener $\boldsymbol{\mu}_p, \mathbf{U}_k \in \mathbb{R}^{3n \times k}$

donde k es el número de componentes que explican $\geq 95\%$ de varianza

Codificación (frame $\mathbf{p}_t \rightarrow \mathbf{z}_t$)

$\hat{\mathbf{p}}_t \leftarrow (\mathbf{p}_t - \boldsymbol{\mu}_s) / \boldsymbol{\sigma}_s$

$\mathbf{z}_t \leftarrow (\hat{\mathbf{p}}_t - \boldsymbol{\mu}_p) \mathbf{U}_k \in \mathbb{R}^k$

Decodificación (coordenadas PCA $\mathbf{z}_t \rightarrow \mathbf{p}_t$)

$\hat{\mathbf{p}}_t \leftarrow \mathbf{z}_t \mathbf{U}_k^\top + \boldsymbol{\mu}_p$

$\mathbf{p}_t \leftarrow \hat{\mathbf{p}}_t \cdot \boldsymbol{\sigma}_s + \boldsymbol{\mu}_s$

Recortar $\mathbf{z}_t$ al rango $[\mathbf{z}_{\text{mín}}, \mathbf{z}_{\text{máx}}]$ observado en training

3.3.4. Bucle de entrenamiento

La siguiente sección de pseudocódigo describe el bucle para llevar a cabo el entrenamiento completo del modelo. Inicialmente, se dividen los datos de entrenamiento en lotes, estos contienen una secuencia de entrada para el modelo y la secuencia de frames inmediatamente posterior. Con estos datos y la función descrita anteriormente, se obtiene la pérdida del modelo para la retropropagación y se actualizan sus pesos. La fase de evaluación también utiliza la función anterior para analizar la calidad del modelo ante situaciones nuevas, y calcula el primer frame de cada lote para obtener una aproximación de la media de error en la predicción de los deltas.

Algorithm 4 Bucle de Entrenamiento y Validación

```

for  $epoch \leftarrow 1$  to  $EPOCHS$  do
  Fase de Entrenamiento (Train):
  Establecer modelo en modo entrenamiento
   $train\_loss \leftarrow 0,0$ 
  for cada ( $batch\_seq, batch\_future$ ) en  $train\_loader$  do
     $loss \leftarrow RUNROLLOUT(batch\_seq, batch\_future)$ 
    Optimizador.zero_grad()
     $loss.backward()$ 
    RecortarGradientes( $model.parameters$ , umbral = 1,0)
    Optimizador.step()
     $train\_loss \leftarrow train\_loss + loss.item()$ 
  Planificador.step() ▷ Actualizar tasa de aprendizaje

  Fase de Evaluación (Test):
  Establecer modelo en modo evaluación y desactivar gradientes
   $test\_loss \leftarrow 0,0, total\_err \leftarrow 0,0, total\_verts \leftarrow 0$ 
  for cada ( $batch\_seq, batch\_future$ ) en  $test\_loader$  do
     $loss \leftarrow RUNROLLOUT(batch\_seq, batch\_future)$ 
     $test\_loss \leftarrow test\_loss + loss.item()$ 
    ▷ Métricas de error en el primer paso ( $k = 0$ )

     $pred\_pos \leftarrow PredecirSiguientePaso(batch\_seq)$ 
     $target\_pos \leftarrow batch\_future[:, 0, :, 0 : 3]$ 
     $distancias \leftarrow \|pred\_pos - target\_pos\|_2$ 
     $total\_err \leftarrow total\_err + \sum(distancias)$ 
     $total\_verts \leftarrow total\_verts + \text{NúmeroDeElementos}(distancias)$ 
  ErrorVértice  $\leftarrow total\_err / total\_verts$ 
  Almacenar métricas medias del  $epoch$  en el historial
  Imprimir en consola:  $epoch, train\_loss, test\_loss, \text{ErrorVértice}$ 

```

Para acabar de ajustar el modelo se itera sobre los mismos datasets modificando los parámetros variables.

- **Windows size:** Cantidad de frames de la secuencia de input, esta actuará como ventana deslizante conforme se añadan los frames predichos.
- **Rollout steps:** Cantidad de frames que el modelo produce en el unroll.
- **Noise:** Se varía en la cantidad proporcional de ruido en el input normalizado (entre un 1 y un 3 %) y este se aplica a los últimos n frames de la ventana del input.
- **Learning rate:** Se emplea el optimizador Adam, frecuentemente empleado en redes neuronales físicas por su rapidez de convergencia en grandes datasets, adaptabilidad a diferentes escalas de rigidez (como podrían ser en este estudio el *bending* o *stiffness* mencionados) o amortiguación de picos de gradientes generados por colisiones, entre otros. Empleamos el Adam por defecto, empleado por otros estudios como Bertiche et al. (2021a) o Chentanez et al. (2020).

- **Tamaño dataset:** Se varía entre datasets desde 25000 a 100000 frames para determinar el tamaño mínimo con el que se consigue un resultado apropiado.
- **Batch size:** Este depende del tamaño del dataset y el detalle que se esté dispuesto a sacrificar para reducir el tiempo de entrenamiento.

3.4. La fase de inferencia

Como se ha explicado en el último apartado, el entrenamiento genera dos archivos indispensables para la ejecución del modelo en Unity. El archivo ONNX que contiene el modelo entrenado, y el archivo JSON con los datos de normalización de los inputs y outputs del modelo. Estos archivos serán recogidos por los componentes de tipo ClothML que se han generado para remplazar el componente Cloth del objeto-tela en Unity. En este apartado se explica este proceso y sus elementos con detalle.

3.4.1. Alteraciones en la escena

Al inicio del capítulo se describe este pipeline como circular, pues se utiliza la misma escena de la simulación en Unity para recoger datos y probar posteriormente el funcionamiento del modelo entrenado. Esto requiere de ciertos cambios de configuración descritos a continuación.

- Se marcan los vértices del *Mesh Filter* como dinámicos, ya que por defecto Unity guarda las mallas en buffers estáticos. Este cambio activa una flag interna de Unity para obligar a la GPU a utilizar una estrategia de guardado más óptima para el acceso en cada frame.
- Se reemplaza el componente de simulación Cloth por el componente creado ClothML que recreará el movimiento a través del modelo cargado.
- Como se ha descrito en el estado de la cuestión, las geometrías simuladas por Cloth utilizan el *Skinned Mesh Renderer* para su renderizado. Al reemplazarlo la malla no puede ser renderizada con esta técnica, por lo que se añade un componente *Mesh Renderer* general.

3.4.2. Componente ClothML

En este apartado se profundiza en el componente mencionado, que se añade en el anexo de esta memoria.

3.4.2.1. Funcionamiento de Sentis

Sentis permite importar modelos de redes neuronales entrenados a Unity y ejecutarlos en tiempo real tanto en CPU como en GPU. Para utilizar Sentis se crea un motor o *worker* que se encarga de planear las operaciones del tensor de forma paralela. El ejecutarlo, se obtienen los resultados del modelo. En muchos aspectos la arquitectura es análoga a Pytorch, por ejemplo, en Sentis la entrada y salida de

los modelos también se gestiona con tensores. Estos pueden llegar a tener hasta 8 dimensiones, pero en memoria se almacenan los tensores como un array en el que los valores de la última dimensión son adyacentes⁹.

3.4.2.2. Estructura del componente

Habiendo descrito el funcionamiento interno de la herramienta, en este apartado se explica el uso que se le ha dado para adaptarla a las necesidades del proyecto. Los componentes ClothML han sido generados a partir del *Mono Behaviour* de Unity, esta clase engloba los comportamientos de un *Game Object*, la unidad básica de entidad que funciona como contenedor de componentes. Proporciona métodos como *Start()* o *FixedUpdate()* que representan el ciclo de vida del objeto.

Start() se ejecuta una sola vez al inicio del programa, por lo que se utiliza para crear el worker, el tensor de entrada e inicializar los parámetros necesarios. Los parámetros que el componente recibe son los siguientes:

- **JSON:** Contiene los parámetros de normalización. Estos se utilizarán para normalizar los datos de entrada del tensor y desnormalizar los deltas resultantes.
- **ONNX:** El modelo entrenado en formato ONNX se utiliza para inicializar el modelo de Sentis.
- **Procesador:** Se elige si el modelo va a ser ejecutado en CPU o GPU. El worker de Sentis será creado con un *BackendType* del tipo seleccionado. Se utiliza esta opción para hacer medidas de rendimiento.
- **MeshFilter:** Se accede a la malla a través de este componente.
- **Collisionador/es:** Los colliders que representan el objeto que la tela debe tener en cuenta para su colisión. Al igual que en el componente de Cloth de Unity, puede estar formado por una o más esferas y cápsulas.

Asimismo, se establece el parámetro *max distance* para la lista de vértices, determinando así los constraints de los puntos. También se crea el history buffer como un array de floats y se llena con el estado de la tela quieta en su posición inicial. Imitar el formato previamente explicado que Sentis utiliza como entrada de los modelos, permite construir el tensor de entrada con una referencia directa a este array, ahorrando así mucho trasiego de memoria. En la siguiente figura (3.13) puede visualizarse la organización de nuestras variables de entrada en este formato.

⁹Manual de Unity que describe las bases de los tensores: <https://docs.unity3d.com/Packages/com.unity.sentis@1.1/manual/tensor-fundamentals.html>




Figura 3.13: Array del tamaño $[window\ size * vrtices * features]$ de las dimensiones necesarias (1 x secuencia de frames del historial x cantidad de vértices x cantidad de características)

FixedUpdate() es el método que Unity utiliza por defecto para la ejecución de las físicas. En él iteramos sobre los puntos de la geometría para inferir las nuevas posiciones. En la siguiente figura se visualiza una iteración para un modelo recurrente. Se accede a la malla para calcular los parámetros del frame de input, como la posición local o el SDF. Estos parámetros son normalizados con la media y la desviación típica calculados previamente en la normalización de los modelos en python. Se introducen al historial de estados, que previamente habrá liberado su primera posición, manteniendo así un tamaño constante. Se ejecuta el modelo con el tensor de entrada, que se habrá actualizado automáticamente, y se recogen los resultados del mismo. Estos serán desnormalizados con los parám calculados en el entrenamiento en python. Finalmente se suman los deltas a la posición de los vértices en el estado del input, estableciendo así la nueva posición.




Figura 3.14: Esquema del contenido de *FixedUpdate()* de ClothML.

Existen distintas versiones de este componente en función del modelo entrenado. Todos los modelos coinciden en las variables de salida, sin embargo, la forma y el contenido de la entrada cambian según el entrenamiento del modelo. En el caso de los modelos MLP, por ejemplo, el historial se reduciría a un solo frame, el script básico se adapta automáticamente a este tipo de variaciones, como número de frames de input o cantidad de vértices. Para otros modelos en cambio, es necesario cambiar el registro del estado. Este se lleva acabo en el método *saveStateAt(offset)*, este recoge las features que el modelo necesita y las guarda en el formato adecuado en la posición del historial determinanda por la variable *offset*, que típicamente corresponderá a la posición del último frame del historial. Del mismo modo, los modelos PCA que se implementaron requieren de un procesamiento específico, descrito en la siguiente sección de pseudocódigo. Esencialmente se aplanan el vector de entrada para estandarizarlo y proyectar los datos en el espacio de componentes que se generó al entrenar el dataset, los componentes pasan a guardarse en la posición pertinente del buffer.

3.4.3. Post-procesamiento

En las investigaciones más visualmente convincentes del estado del arte, se consigue llegar a ese nivel de credibilidad en la simulación gracias a estrategias de post-procesamiento que refinan la apariencia de la geometría tras ser inferida. Entre ellas destacan la corrección de intercolisiones o intersecciones con los objetos colisionadores, la reconstrucción de las normales de los vértices, la conservación de la integridad física de la tela mediante medidas de separación entre vértices o el suavizado de temblores. Al tener en este proyecto como objetivos comparar resultados de la inferencia y observar la capacidad de los modelos de replicar estas simulaciones por sí mismos, se ha querido afinar la predicción de la simulación de la manera más precisa posible fuera del motor de videojuegos. Es decir, se apreciaba medir visualmente el resultado directo del modelo sin correcciones adicionales. Esto supone resultados menos pulidos pero más significativos respecto a la capacidad de los modelos.

La única técnica de post-procesado aplicada en este estudio es la conservación de los constraints de la tela, es decir, se tienen en cuenta los valores de *max distance* para fijar los vértices anclados y no aplicar sobre ellos ningún desplazamiento.

Capítulo 4

Experimentos

Como se ha comentado en el apartado del estado del arte, la investigación acerca de este tema sigue en curso y todavía no hay una solución generalista para reemplazar los solvers físicos con modelos de Machine Learning. Utilizando la infraestructura descrita en el capítulo anterior, se ha comparado la efectividad de modelos con diferentes características, con el fin de analizar las limitaciones de esta alternativa y descubrir que técnicas resultan ser más prometedoras.

A la hora de valorar la calidad de un sistema de inferencia en tiempo de ejecución, hay dos criterios fundamentales:

- *Rendimiento*: Los modelos deben ser capaces de competir con los reducidos tiempos de cómputo de los solvers. Para ello, tanto los modelos como los datos de input han de ser lo más ligeros posibles. Las métricas que se emplean para medir la calidad del rendimiento son las siguientes:
 - *Tiempo de entrenamiento*: medido en minutos/horas (m, h), el tiempo necesario transcurrido para entrenar un modelo a partir de un dataset. Incluye tanto el entrenamiento como el testing que nos proporciona las métricas.
 - *Tiempo de inferencia*: medido en milisegundos (ms), es el tiempo medio de inferencia de un modelo en ejecución en el entorno de simulación. Abarca desde que se pide una respuesta al modelo hasta que se obtienen los datos. ¹
 - *Error medio por vértice*: medido en metros (m), es el error medio de predicción de un batch, es decir la diferencia media que se encuentra entre las posiciones predichas y reales de los vértices. Se calcula en la fase de prueba del entrenamiento para cada primer frame de un batch ².
 - *Frames por segundo*: (FPS) la media calculada durante la simulación.

¹No se ve reflejado en él procesos adicionales que se llevan a cabo en Unity como podría ser el cálculo del PCA para un frame.

²Para calcular el error de vértice del primer frame de un batch, se compara el último predicho de *batch_seq* con el primero de *batch_future*.

Las métricas que se calculan durante la simulación en Unity, el tiempo de inferencia y las FPS, se medirán en el mismo ordenador con las siguientes características: i7 13650HX, y una gráfica GTX 5060.

- *Resultado visual*: El movimiento inferido por el modelo ha de respetar las reglas físicas suficientes para tener credibilidad. Además, es importante que la simulación se mantenga estable y la tela mantenga su estructura a lo largo de la ejecución. La evaluación de este aspecto es más subjetiva, por lo que se le ha dado una puntuación del 0 al 3 a diferentes características basada en la observación, estas quedan expuestas en la rubrica 4.1. Estos aspectos serán los mismos que se tendrán en cuenta a la hora de pedir la opinión de los usuarios en el apartado 5.3.
- *Reactividad al colisionador*: cuánta sensibilidad muestra la tela frente a colisiones, si tiende al reposo y a ser atravesada, o reacciona a tiempo.
- *Conservación de la estructura*: si consigue volver a la pose no deformada de la tela tras las colisiones, o los vértices pierden progresivamente sus relaciones originales en el espacio. Se tiene en cuenta si los vértices forman picos en la tela, crean efectos de compresión en ella, o hacen que adpote poses antinaturales.
- *Estabilidad a largo plazo*: se refiere a si la simulación se mantiene en el tiempo, ninguna colisión ocasiona movimientos erráticos o propulsiones hacia el infinito y continua reaccionando como en el inicio.
- *Credibilidad del movimiento*: cómo de verosímiles son los movimientos e inercia generada en la tela. La tela puede reaccionar al colisionador correctamente, pero puede optar por evitarlo, encogerse, moverse en sentido contrario o adoptar otras deformaciones y velocidades poco naturales.

Pt.	Reactividad	Conservación	Estabilidad	Credibilidad
0	No reacciona.	Se corrompe por completo.	Los puntos estallan desde el inicio hacia el infinito.	No se distingue lo que ocurre.
1	Reacciona a veces, generalmente no es fiel a los movimientos del colisionador.	Genera picos y se estira o comprime en exceso, no es capaz de recuperar la forma.	Los errores se acumulan paulatinamente, hasta perder su funcionalidad.	Se discierne la tela, pero no actúa de forma natural.
2	Suele reaccionar, puede no ser fiel a los movimientos del colisionador.	Genera picos y se estira o comprime, pero es capaz de recuperar la forma.	Puede haber movimientos erráticos que acaben afectando su desempeño.	Se mueve de manera convincente.
3	Suele reaccionar fielmente.	No se altera excesivamente y recupera prácticamente la forma inicial.	Mantiene su desempeño correctamente.	Se mueve e interacciona de manera convincente.

Tabla 4.1: Resultados del entrenamiento en base a la percepción.

A lo largo del proyecto se han llevado a cabo numerosas pruebas, a continuación se describen los experimentos con los resultados más interesantes. Pueden verse de forma interactiva en la aplicación del repositorio, explicada en el apartado [4.5](#).

4.1. Recurrencia

Para analizar la importancia de la memoria recurrente de los modelos, en los casos en los que la simulación cuenta con inercia, se han comparado los dos tipos de modelos definidos anteriormente, el MLP y el RNN. Los siguientes parámetros son compartidos entre ambas pruebas, con la intención de aislar únicamente la recurrencia y analizar su efecto.

Windows size	Rollout steps	Noise	Learning rate	Tamaño dataset	Batch size
16	24	3 %	0.001	25000	32

Tabla 4.2: Hiperparámetros y configuración del entrenamiento.

Las métricas obtenidas son las siguientes:

Prueba	T entrena- miento	T inferencia	Error medio por vertice	FPS
MLP	8h(gpu)	2.25952ms	0.001929	0
RNN	18h(gpu)	2.58243ms	0.002	0

Tabla 4.3: Resultados del entrenamiento en base al rendimiento.

Si ambos modelos emplean una ventana de frames histórica y llevan a cabo unrolling, podemos observar que ambos obtienen errores de vértice similares. En cuanto a tiempo de entrenamiento, el MLP tarda menos de la mitad (10 horas de diferencia), y obtiene un tiempo de inferencia ligeramente inferior (0,3 ms de diferencia).

Donde realmente se aprecia una diferencia es a nivel visual, particularmente en cuanto la conservación de la tela. En este experimento el estado oculto propio de la RNN mantiene casi intacta la estructura de la tela, mientras que con el MLP se rompe la forma a medida que recibe colisiones. De la misma forma que el RNN, realiza los movimientos con mucha fluidez y es reactiva, pero no es capaz de mantenerse a través del tiempo.




Figura 4.1: Tela simulada a través de RNN.




Figura 4.2: Tela simulada a través de MLP.

Se concluyen las siguientes puntuaciones de calidad visual:

Prueba	Reactividad	Conservación	Estabilidad	Credibilidad
MLP	8/10	4/10	10/10	3/10
RNN	8/10	8/10	10/10	4/10

Tabla 4.4: Resultados del entrenamiento en base a la percepción.

Con esta metodología y técnicas concretas, compensa mantener la recurrencia para evitar la pérdida de estructura de la tela. No obstante, se planteará encontrar posteriormente una técnica más restrictiva en cuanto a estructura que permita aprovechar los bajos tiempos de entrenamiento e inferencia del MLP.

4.2. Unrolling

Como se ha expuesto anteriormente, esta es una técnica que resulta ser muy útil en la autocorrección del modelo; en este experimento quieren observarse su repercusión en la práctica. Se realiza el experimento modificando la secuencia de entrada del RNN entre 1 y 24 frames futuras, de tal modo, pueden compararse los efectos del unrolling con un modelo análogo que solo infiere un frame, es decir, un modelo sin unrolling. El resto de parámetros se mantienen consistentes con los de la prueba anterior.

En la siguiente tabla, [4.5](#), pueden verse los resultados en cuanto al rendimiento:

Rolling steps	T entrena- miento	T inferencia	Error medio por vertice	FPS
1	1.5h(gpu)	0.0ms	0.0008	0
24	18h(gpu)	2.58243ms	0.002	0

Tabla 4.5: Resultados de los entrenamientos en base al rendimiento.

Contemplando ambas simulaciones en ejecución, es clara la diferencia en la conservación de la estructura de la geometría. Si bien, al contar con el resto de técnicas implementadas, la corrupción de la forma de la tela no es tan exagerada. Estos resultados visual pueden compararse en la figura [4.3](#).




Figura 4.3: Estado de la geometría tras 100 segundos de ejecución. En la izquierda, en verde, la tela entrenada con 24 frames de unrolling y en la derecha, en morado, la entrenada sin emplear esta técnica.

Por otro lado, es interesante recalcar que el modelo sin unrolling permite más reactividad a la tela. Al contrario, utilizando la técnica, la inferencia tiene en cuenta el cambio de velocidad y aceleración provocados, por lo que las predicciones tienden a ser más cautelosas y se reduce el movimiento total.

Rolling steps	Reactividad	Conservación	Estabilidad	Credibilidad
1	0/3	0/3	0/3	0/3
24	0/3	0/3	0/3	0/3

Tabla 4.6: Resultados de los entrenamientos en base a la percepción.

4.3. Velocidad

Al utilizar secuencias de frames para el entrenamiento, teniendo las posiciones de cada vértice, la velocidad puede ser inferida. Sin embargo, la secuencia de las velocidades aporta al modelo de una conciencia acerca de la aceleración y deceleración de los vértices, por lo que se considera importante medir el impacto en este experimento. En el momento de medir los parámetros mediante el random forest en el apartado 3.2 se resalta la velocidad en el eje X como la información de la simulación más relevante, y podría resultar la información clave para aprender a gestionar la inercia.

No obstante, de forma previa al experimento se pueden intuir dos implicaciones arriesgadas de emplear la velocidad como parámetro. En primer lugar, para generar el tensor de entrada es necesario calcular primero la velocidad de cada punto de la tela en cada frame, lo cual supone un aumento en el coste computacional en la simulación. Pero sobre todo, la velocidad otorga una mayor sensibilidad al error en el modelo, por lo que se puede intuir que sufrirá una mayor cantidad de desplazamientos erráticos.

Se quiere comprobar si la información que aporta la velocidad compensa los márgenes de error elevados. Ambas pruebas siguen los parámetros:

Windows size	Rollout steps	Noise	Learning rate	Tamaño dataset	Batch size
16	24	3 %	0.001	25000	32

Tabla 4.7: Hiperparámetros y configuración del entrenamiento.

El cálculo del loss y unrolling en ambas pruebas es equivalente, únicamente difieren por el nuevo parámetro recibido, la velocidad de cada vértice de la tela. Los resultados son los siguientes:

Prueba	T entrena- miento	T inferencia	Error medio por vertice	FPS
Pos	18h(gpu)	2.25952ms	0.001929m	417
Pos + Vel	18h(gpu)	0.0ms	0.000942m	407

Tabla 4.8: Resultados del entrenamiento en base al rendimiento.

En este experimento, podemos observar que el error de vértice observado en el entrenamiento y testing con la velocidad como parámetro es bastante inferior. El tiempo de entrenamiento prácticamente no sube, ambos rozan las 18h (a causa de la técnica de unrolling), y el tiempo de inferencia se mantiene. Las FPS y tiempo de inferencia caen ligeramente al contar con tres parámetros más de entrada (v_x , v_y , v_z).

Pese a que el error de vértice de la prueba con velocidad parece bajo, esto no se transmite en la simulación final. La simulación muestra reacción adecuada, pero coge inercia con mucha más rapidez, y realiza movimientos exagerados. Esto perjudica la simulación, y provoca que la tela pierda la estructura a medida que avanza. En la figura 4.4 podemos apreciar como reacciona a tiempo a la colisión, pero realiza un movimiento más grande de lo necesario para dejar la bola pasar. En la siguiente imagen 4.5 se aprecia como ha quedado deformada la tela por este movimiento y posteriores. Aunque la tela se mantiene estable y no se dispara al infinito, las deformaciones se acumulan y deforman la tela permanentemente a medida que avanza el tiempo. Adicionalmente, es interesante mencionar como varía mucho más la velocidad (de forma no natural) a la que reacciona y vuelve al reposo la tela en comparación con la RNN basada en posiciones.




Figura 4.4: Movimientos exagerados al comienzo de la simulación con velocidad.




Figura 4.5: Ejemplo de deformación de la tela pasado un minuto en la simulación con velocidad.

Visto esto, se concluyen las siguientes puntuaciones a nivel visual:

Prueba	Reactividad	Conservación	Estabilidad	Credibilidad
Pos	0/10	0/10	0/10	0/10
Pos + Vel	0/10	0/10	0/10	0/10

Tabla 4.9: Resultados del entrenamiento en base a la percepción.

Se concluye que con este contexto, emplear la velocidad como parámetro no produce mejoras frente a usar únicamente las posiciones y sdfs. Los movimientos exagerados y un tanto erráticos perjudican notablemente la naturalidad de la tela.

4.4. PCA

Resulta interesante introducir un modelo que se valga de un PCA para reducir la dimensión de los parámetros de entrada, que ayude a optimizar y facilite la escalada a mallas de gran tamaño. Esta técnica permanece como una de las más utilizadas para alcanzar mejoras de rendimiento. En este experimento, utilizando el método del umbral de varianza, se calcula el mínimo de características necesarias para alcanzar un gran porcentaje de la variabilidad de los datos con un umbral de varianza del 95 %, reduciendo drásticamente el número de componentes.

Se aplica el PCA sobre una la misma versión de RNN que incorpora unrolling empleada en los experimentos anteriores. Esta combinación resulta similar a lo propuesto por [Holden et al. \(2019\)](#), a excepción de la incorporación de la recurrencia como método de contención de la inercia de la simulación. Como se explica anteriormente en la descripción del PCA [3](#), la diferencia de ambos elementos reside en qué el modelo opera sobre deltas de posiciones o deltas de las posiciones en el subespacio.

Ambas pruebas comparten los parámetros:

Windows size	Rollout steps	Noise	Learning rate	Tamaño dataset	Batch size
16	24	3 %	0.001	25000	32

Tabla 4.10: Hiperparámetros y configuración del entrenamiento.

Los resultados son los siguientes:

Prueba	T entrena- miento	T inferencia	Error medio por vertice	FPS
RNN	18h(gpu)	0.0ms	0.001929m	444
RNN + PCA	19h(gpu)	0.0ms	0.005298m	472

Tabla 4.11: Resultados del entrenamiento en base al rendimiento.

El entrenamiento que incorpora PCA tarda un poco más que el básico, pero este coste de entrenamiento se puede decrementar fácilmente si se realiza el cómputo de frames PCA a la hora de guardar el dataset para reducirlo. El PCA aporta al modelo una inferencia más rápida y aporta un incremento de tasa de frames de un 6,3 %. Como era de esperar, al reducir los datos, el error de vértice aumenta levemente.

La mejor característica que aporta el PCA sobre el RNN básico es la capacidad total de mantener la estructura de la tela. Es elástica, cuando el colisionador

está suficientemente alejado sabe volver a la posición de reposo de forma natural, y no padece deformaciones permanentes. No obstante, la actitud que adopta en las colisiones y los momentos inmediatos a ellas es errática. Se observa temblor en los movimientos, elección errónea de la dirección al choque y adopción de poses encogidas para dejar pasar el colisionador. De forma similar a lo visto en el experimento de la velocidad, esta tela con PCA adopta velocidades aleatorias, particularmente durante el cambio de colisionar y volver su fase de reposo (en la que en el dataset original siempre mantiene inercia y no llega a parar del todo). En la siguiente figura se puede apreciar como la tela se comprime hacia un lado para dejar pasar el colisionador (que avanza desde el fondo de la escena), y se recupera sin problema más tarde.




Figura 4.6: La tela con PCA se hace a un lado para dejar pasar al colisionador, que viene del fondo.




Figura 4.7: Tras lo ocurrido en 4.6, la tela con PCA recupera su estructura de reposo y su movimiento con inercia entre colisiones.

Adicionalmente a este experimento, se han realizado pequeñas pruebas que han confirmado que la gestión de colisiones mejora notablemente con el aumento de tamaño del dataset, como es de esperar. Se califican los resultados obtenidos de la siguiente forma:

Prueba	Reactividad	Conservación	Estabilidad	Credibilidad
Basic	0/10	0/10	0/10	0/10
PCA	0/10	0/10	0/10	0/10

Tabla 4.12: Resultados del entrenamiento en base a la percepción.

En conclusión, se observa una mejora de rendimiento en la versión que incorpora PCA, aunque esta también presenta un mayor error de vértice y movimientos aleatorios. La estabilidad y buena recuperación a la pose de reposo son destacables, y merecen más investigación al respecto, pero las colisiones como tal hacen que no sea una tela creíble y natural usable.

4.5. Aplicacion para la visualización de los experimentos

Para poder visualizar los resultados, se ha implementado una aplicación disponible en el repositorio del proyecto. La interfaz permite acceder a los distintos experimentos llevados a cabo a través de un menu principal, que puede verse en la figura 4.8.



Figura 4.8: Menu principal de la aplicación.

En cada experimento pueden activarse distintas versiones de los modelos entrenados, así como la simulación de cloth de Unity. Además de la comparación visual que esto permite, se generan diferentes métricas del rendimiento en tiempo de ejecución de cada simulación: La media de frames por segundo y la máxima y mínima tasas alcanzadas en el tiempo especificado. Las ejecuciones pueden pararse en cualquier momento con el botón de "Stop" pero se recomienda mantener cada simulación en curso durante al menos un minuto para obtener metricas más veraces.




Figura 4.9: Ejemplo de la ejecución de una simulación de un experimento

Evaluación y Discusión de los resultados

5.1. Análisis del Rendimiento

Uno de los objetivos principales de este proyecto es replicar la simulación de un solver de telas con baja latencia, haciéndolo accesible para el desarrollo indie en un motor como es Unity. Como se ha visto en el estado del arte, esa optimización se ha conseguido desde distintos enfoques a nivel académico y está en las primeras fases de implementación a nivel de industria, como herramienta para artistas o reducción de la carga de simulación de ropa (Chaos Cloth). Lamentablemente, el enfoque y la escala propias de esta investigación no han permitido reproducir resultados similares, es decir, una inferencia notable respecto a la propia de los solvers.

El modelo que mejor rendimiento obtiene es la RNN sobre la que se aplica un PCA. Esta supera ligeramente la tasa de frames alcanzada por el solver de Cloth de Unity, con una inferencia de xms. El resto de modelos, sin reducciones aplicadas, no han conseguido alcanzar inferencias adecuadas.

La pérdida de enfoque en la optimización durante la investigación ha sido ocasionada por la simulación escogida como principal, que como se ha mencionado anteriormente, es altamente dinámica. La inercia presenta desafíos distintos que los tratados por estudios que se enfocan más en la creación de deformaciones y arrugas correctas a baja latencia. Debido a esto, ha tenido lugar la priorización de técnicas y características que permitían llegar a resultados con sentido visual y manejar la inercia, frente a las características de reducción necesarias para mantener la inferencia baja y completamente escalable. La RNN sin reducción de espacio consigue inferir la inercia pero no es óptima. El sistema de many to one resulta un impedimento frente a la cantidad de datos necesaria. Pese a que la optimización y los resultados visualmente atractivos son dos conceptos que siempre se encuentran en conflicto, ha de encontrarse un punto más cercano a la reducción.

5.2. Resultados visuales de la inferencia

Dada la combinatoria posible de las características contempladas en el estudio, los resultados visuales de las simulaciones generadas por los modelos han sido muy diversos. La aleatoriedad deseada supone la necesidad de datasets y entrenamientos mayores, por lo que si bien los modelos conseguidos no son capaces de reaccionar consistentemente frente a todos los movimientos del colisionador posibles, demuestran potencial en lo que respecta a la capacidad de generalización.

Los mejores resultados visuales de la investigación se consiguen con el modelo RNN con la combinación de las técnicas de noise y unrolling. Presenta sobretodo una ventaja en la conservación de la estructura de la geometría de la tela, sin comprometer la naturalidad del movimiento. A pesar de que haya otros modelos más reactivos, la estabilidad de este ante el dinamismo de la simulación lo favorece a la hora de evaluar la credibilidad del resultado. Este modelo será el elegido para llevar a cabo las pruebas a usuarios vistas en el siguiente apartado [5.3](#).

Analizando el conjunto de experimentos realizados, se pueden observar distintos aspectos compartidos en los resultados visuales de los modelos:

- Como se ha observado, los modelos que tienen más capacidad de mantener un movimiento fluido y natural (y que a veces puede llegar a ser menos reactivo), son el RNN y MLP. Al contrario, la velocidad y reducción de entrada parecen romper la naturalidad de los desplazamientos. Ambos respetan menos la consistencia temporal, produciendo movimientos erráticos a velocidades inconsistentes.
- Por otra parte, los únicos modelos capaces de mantener la estructura de la tela son el RNN y el PCA, ambos con unfolding. El segundo consigue recuperar al completo la estructura de reposo tras interactuar con el colisionador, aunque en ambos casos esta recuperación puede tener un efecto visual interpolado.
- Los beneficios del unrolling suponen a veces un exceso en la prevención de los posibles errores. Llegando, en algunos casos de interacción, a producir el movimiento contrario al esperado con el fin de evitar movimientos de inercia desproporcionados.
- Ocasionalmente, los impactos contra el colisionador atraviesan la tela. Si bien, su reactividad no es infalible, este problema ya se encuentra en la simulación de Cloth propia de Unity, por lo que el entrenamiento reproduce o incluso potencia estos errores de base.

5.3. Pruebas de usuario

Habiendo obtenido los resultados visuales de la inferencia, se opta por llevar a cabo unas pruebas de usuario en las que presentarlos, comparándolos con la simula-

ción generada por el solver físico. En este capítulo se describen estas pruebas y los resultados obtenidos.

5.3.1. Objetivos

La motivación de las pruebas no reside tanto en averiguar si se ha logrado reemplazar la simulación generada por el solver de Cloth, sino más bien en evaluar la naturalidad de los resultados obtenidos con el modelo. Los objetivos principales de las pruebas son: obtener feedback externo sobre la percepción de la tela simulada, detectar qué aspectos destacan y se han conseguido replicar, y aquellos que rompen la credibilidad, en los que se tiene que priorizar la mejoría.

Es crucial obtener una opinión por parte de usuarios ajenos al ámbito de físicas generadas por IA para poder evaluar con certeza el alcance del modelo actual y los siguientes pasos a realizar.

5.3.2. Diseño de las pruebas

Se elige realizar un cuestionario rápido y no exhaustivo, con objeto de abarcar un mayor número de encuestados y obtener su percepción inicial pura. Para la prueba se utiliza Google Forms ¹ por su accesibilidad para los usuarios y la facilidad para añadir contenido audiovisual, de modo que el formulario cuenta con un video en el que se visualizan las dos telas paralelamente. El cuestionario puede encontrarse en el anexo, y en rasgos generales consiste en los siguientes apartados:

- *Perfil del usuario*: Con la idea de relacionar las percepciones de los usuarios con su perfil se les pregunta a cerca de su edad, agrupada en tramos ², y sus hábitos de consumo de distintos medios o contenidos audiovisuales ³.
- *Identificación*: El video mencionado enseña el funcionamiento de dos telas durante 50 segundos, refiriéndose a ellas como “Una ha sido simulada siguiendo leyes físicas reales, otra ha sido simulada con IA”. En este apartado únicamente se les pide a los usuarios identificar cada una y se les pregunta por su preferencia en base al realismo.
- *Opiniones*: Finalmente se revela la tela generada con nuestro modelo y se recogen las opiniones de los usuarios acerca de ella. Se les pide valorar su realismo en una escala del 1 al 10 y ordenar las características visuales mencionadas en los experimentos en base a la calidad. Adicionalmente, se añade una sección para observaciones y comentarios.

¹Software desarrollado por Google para la creación y gestión de encuestas a través de formularios digitales: <https://docs.google.com/forms>

²Los tramos de edad contemplados son: «Menos de 20», «Entre 21 y 30», «Entre 31 y 40», «Entre 41 y 50» y «Más de 51».

³Los medios contemplados son: «Televisión/Películas», «Videojuegos» y «Contenido generado por IA».

5.3.3. Resultados

Tras recoger 49 respuestas se concluyen los siguientes resultados. Las respuestas en la sección de identificación revelan que la inferencia no llega a imitar idealmente la simulación en una comparación lado a lado. Como se ve en el gráfico 5.1, la mayoría de los encuestados son capaces de identificar la tela simulada con el solver físico. Asimismo, ante la pregunta "¿Cuál te parece más realista?" la mayoría elige esta. La correlación entre la identificación y la percepción del realismo es alta, véase en el gráfico 5.2.




Figura 5.1: Distribución de la capacidad de los usuarios de identificar correctamente la simulación física y la generada con IA.




Figura 5.2: Elección de los usuarios en base al realismo de las telas. Incluye la métrica anterior, colocando los dos subgrupos de usuarios en esta división.

En referencia a los perfiles de usuario, la edad o la frecuencia con la que consumen contenido generado por IA o televisión y cine, la correlación con la identificación de la tela no ha sido clara. Sin embargo, es interesante recalcar la tendencia entre los jugadores de videojuegos. Se infiere que, al contrario que en otros medios audiovisuales, los jugadores de videojuegos están más acostumbrados a ver este tipo de simulaciones y entienden mejor las interacciones físicas.




Figura 5.3: Identificación de la tela simulada con el modelo de ML de cada subgrupo en base a su frecuencia de uso de videojuegos.

A propósito de esto, se ha podido identificar que la característica que más evidencia el modelo de ML es en efecto la interacción con colisionadores. 10 de las 22 observaciones recibidas por los encuestados mencionan explícitamente este aspecto: «...cuando la pelota se junta con la tela la traspasa en vez de moverla y eso le quita realismo...», «Los colisionadores de la tela fallan a la hora de interactuar con la esfera.», «La pelota ha atravesado la tela.» o «El colisionador literalmente atraviesa la tela en varios momentos sin reacción.» son algunos de los más significativos.

Los otros rasgos pasan más desapercibidos, siendo el movimiento por inercia el mejor conseguido con comentarios como «Le falta algo de dinamismo para llegar a ser mas realista, un poco mas de fluidez y naturalidad en los movimientos aunque está bastante conseguido.». En lo que a la geometría se refiere, algunos usuarios señalan algunos defectos como «Tras interactuar con esta [la bola], [la tela] parece mucho más "geométrica".» o «arriba a la derecha hace una esquina rara, en algún momento el colisionador parece desplazar las esquinas de la tela de forma anormal».

En la siguiente figura, 5.4, puede verse la media de las posiciones en el orden de cada factor y su desviación típica.




Figura 5.4: Características de la simulación ordenadas en base a la media de posición en la que los encuestados las posicionan. Agregadas en negro, las desviaciones típicas de cada media.

Si bien una comparación lado a lado es una prueba exigente para valorar la naturalidad de la tela conseguida en este estudio, en el apartado de los comentarios adicionales se recibe retroalimentación muy positiva: «Me ha sorprendido lo poco que se llega a diferenciar la IA.», «No perquè la veritat que sassembla moltíssim a l'altra i és difícil de veure alguna cosa que m'hagi cridat l'atenció a diferència de laltre. / No porque la verdad que se parece muchísimo a la otra y es difícil ver algo que me haya llamado la atención al compararla.» o «Por lo demás, diré que me ha costado ver el primer video unas tres veces para decidir que tela usaba físicas y cual usaba IA así que en mi opinión está bastante bien conseguido.» destacan entre ellos.

Al pedir a los usuarios valorar el realismo de la tela del estudio en una escala del 1 al 10, se recogen puntuaciones diversas, con una media de 5.53. Se puede concluir que aunque la simulación del modelo no se percibe como algo completamente antinatural,

aún le queda mucho camino por recorrer para ser percibida como una tela ordinaria, comenzando por mejorar la interacción con las colisiones.




Figura 5.5: Evaluación de los usuarios del realismo de la tela inferida.

Conclusiones y Trabajo Futuro

6.1. Conclusiones

El objetivo de esta investigación era conseguir una infraestructura en la que a través de modelos de ML poder replicar el movimiento de una tela en un motor de videojuegos a tiempo real con baja latencia. Se buscaba identificar las limitaciones al traer técnicas que todavía están en el ámbito académico al desarrollo indie.

Se crearon simulaciones de telas con geometrías simples y movimientos dinámicos provocados por un objeto colisionador en Unity. Durante la ejecución se extrajeron los datos de interés de la tela y se convirtieron a formato CSV. A partir de estos datasets se configuró un modelo que fuera capaz de aprender el comportamiento de la tela, adoptando poses de reposo y deformaciones realizadas por el colisionador sin colapsar. En el comienzo de la investigación se plantearon seis características (que conformarían 13 features) sobre los vértices, que podían ser relevantes para capturar la esencia de la tela en la simulación: la posición, el SDF (distancia a superficie colisionadora más cercana), la velocidad, el gradiente de SDF o normales respecto al colisionador, las coordenadas UVs y la máxima distancia de movimiento desde su origen en la malla de cada vértice.

Se creó una base de entrenamiento con Pytorch, con la que cargar y limpiar los datos, preparar las estructuras necesarias (Datasets y modelos), entrenar y probar los mismos, extraer diversas métricas y finalmente exportarlos en formato ONNX. Fundamentalmente el modelo consistía en una entrada de features de vértices normalizados y aplanados en un vector, que producía una serie de deltas de desplazamiento de cada vértice. Sobre esta base se implementaron diferentes modelos y técnicas pertinentes para la mejora de la inferencia:

- **Modelos:** Se implementaron dos tipos de modelo, una RNN y un MLP. La arquitectura *many to one* dotó al modelo de percepción temporal, aumentando la coherencia de la simulación.
- **Gestión de error acumulado:** Se abordó el problema del error acumulado en tiempo de ejecución mediante distintas técnicas en el entrenamiento: inclu-

sión de ruido en los datos de entrada, aplicación del método de “unrolling” combinado con el algoritmo de retropropagación a través del tiempo (BPTT) y distintos cálculos de la función de pérdida.

- **Reducción de dimensionalidad:** Se redujo la entrada de datos del modelo a través del análisis de componentes principales (PCA).

Los modelos finales se cargaron de nuevo en Unity, a través del paquete Sentis. El componente ClothML creado consiguió sustituir el componente de Cloth de Unity, replicando en la geometría un movimiento en base a los desplazamientos inferidos a través del modelo cargado. Finalmente se desarrolló una aplicación como soporte para los experimentos, disponible en el repositorio del proyecto.

Con el pipeline descrito se plantearon experimentos sobre las distintas características que resultaban prometedoras para la optimización o mejora del resultado visual: la comparación del modelo recurrente (RNN) frente a un MLP, el efecto del uso del unrolling, la velocidad como parámetro de entrada y la reducción del input mediante PCA fueron analizados.

A nivel visual se concluye que la combinación del ruido aplicado a los parámetros de entrada, la recurrencia y el unrolling aportan de estabilidad y conservación de la estructura a través del tiempo en la simulación evaluada. La aplicación de un PCA sobre el modelo mencionado, mejora la conservación de la geometría además de suponer una progresión del rendimiento en tiempo de inferencia. No obstante, no alcanza el grado de realismo observado en el primero.

A través de las diferentes características, se consigue acotar una dirección de estudio válida para el contexto investigado. Se hacen unas pruebas de usuario, que confirman que el resultado obtenido se acerca al comportamiento de una tela real, sin llegar al nivel de naturalidad propio de esta. Se disciernen las técnicas que favorecen la reproducción de los aspectos más relevantes para este tipo de simulaciones, marcando las siguientes limitaciones y pasos para el trabajo a futuro.

6.1.1. Limitaciones

Esta investigación experimenta ciertas limitaciones que se pueden dividir en tres partes: el enfoque teórico y práctico de la simulación, los recursos limitados propios del desarrollo a pequeña escala y las limitaciones pertenecientes a los modelos resultantes.

Uno de los aspectos que más ha condicionado este proyecto ha resultado ser el alcance de la simulación base elegida para los entrenamientos y experimentación sobre técnicas. Como ya se ha mencionado anteriormente, es una simulación altamente dinámica con aleatoriedad de movimientos e inercia, que supone un desafío. En el mundo académico se encuentran algunos estudios que investigan este problema, en especial el mencionado [Bertiche et al. \(2022\)](#), pero no es contemplado en muchos de los estudios basados en poses o herramientas. Se llegó a la conclusión de

que iba a ser difícilmente resuelto a pequeña escala con tiempo limitado. El alcance inicialmente planteado no contemplaba esta dimensión. Adicionalmente, este enfoque tampoco concuerda con la aplicación más común en la industria, de la cual se posee poca información abierta al público. Esto supone un respaldo reducido para esta investigación. Hoy en día, las simulaciones con mucho movimiento todavía son relegadas a los solvers, por la inestabilidad y bajo nivel de detalle de los modelos. El uso práctico de la IA en las telas se enfoca más en reducir el coste de simulación de ropa con poco vuelo en personajes secundarios o crear arrugas que sirvan como base de modelado para artistas. Como se indica en el apartado de análisis del rendimiento 5.1, la mejora del rendimiento resulta poco compatible con la calidad de la simulación, por lo que no se pudo avanzar paralelamente en ambas. Más allá de la inercia, se resalta que existen técnicas que se han quedado fuera de esta investigación como algunos tipos de pérdidas basadas en fuerzas, energías y topología de la malla por su complejidad teórica o ser propuestas como solución a objetivos menos generalistas (por ejemplo, afinar la producción de arrugas en una herramienta específica).

Por otra parte, esta investigación cuenta con limitaciones claras esperables para un desarrollo indie a pequeña escala y este tipo de entrenamientos. No se cuenta con presupuesto o plataformas en las que delegar entrenamientos. Como limitación y parte del enfoque del estudio, todo se lleva a cabo en portátiles no especializados. Los datasets empleados son de tamaño suficiente para producir un comportamiento con sentido en una tela pequeña, pero se podrían alcanzar mejores resultados con un mayor número de frames. Cuantos más datos, más diversidad de movimientos conoce el modelo y mejor comprende su comportamiento. Por las limitaciones mencionadas de tiempo, presupuesto y hardware, en esta investigación se ha usado una media de 25000 frames por entrenamiento, mientras que en otras investigaciones que emplean bancos de simulaciones para entrenar sus modelos llegan a usar hasta 10^6 frames [Holden et al. \(2019\)](#).

En referencia a las limitaciones de los modelos implementados, se pueden comenzar por mencionar la topología fija y capacidad de generalización reducida. El modelo puede generar buenos resultados cuando la tela empleada en el entrenamiento y simulación final coinciden, pero no es capaz de generalizar a otras topologías o mallas dinámicas. También es sensible a nuevos eventos, como modificaciones notables en la actitud del colisionador. Por otra parte, cabe recalcar que el modelo no ha sido probado con telas más complejas o pegadas al cuerpo, debido a la dificultad de crear simulaciones creíbles dentro de la propia plataforma propuesta (Unity).

6.2. Trabajo Futuro

En esta sección se describen las diversas vías de desarrollo que este proyecto podría tomar. Mediante ellas podrían abordarse los desafíos actuales y completar la investigación:

- En cuanto a la infraestructura, se plantea una **automatización** completa del flujo de trabajo. Esta no ha sido una prioridad dada la naturaleza del proyecto.

Sin embargo, una **herramienta para Unity** que conecte la recogida de datos, entrenamiento y aplicación de los resultados a la propia geometría de las telas sería de interés.

- Trabajar en la **escalabilidad** del modelo es indispensable para su utilidad. Mejorar los **métodos de reducción** aplicados, alineándolos con el resto de las técnicas implementadas, resulta necesario para apoyar los próximos avances.
- La propuesta anterior permitiría también **extender los datasets** con más situaciones y probar otros **modelos más complejos**. Han quedado por probar modelos de interés como las CNNs, GNNS y redes encoder-decoder.
- Paralelamente, otra vía de desarrollo interesante acorde a la tendencia observada en el estado del arte consiste en aplicar **restricciones físicas**, entre ellas destacan las funciones de pérdida basadas en atributos físicos. Se propone añadirlas a los modelos existentes para conseguir una mayor calidad en la inferencia al margen de la topología de la tela o el tamaño de los datasets.
- Se plantea añadir la posibilidad de **extraer datasets de software especializado** como Maya o Houdini, e incluso de bancos externos de interés. La obtención de mejores referencias resultaría en modelos más óptimos y habilitaría la prueba de geometrías más complejas y de mayor calidad.
- Habiendo avanzado suficientemente en la optimización del modelo y con software y equipamiento adecuados, podrían estudiarse **otros tipos de simulación**, otros materiales, prendas pegadas al cuerpo, y potencialmente aplicar **técnicas híbridas** de animación, simulación e inteligencia artificial para dirigir la investigación a problemas más especializados. Un ejemplo sería combinar técnicas de skinning con ML, atando la tela a huesos y dejando la inercia y detalles como arrugas a la inteligencia artificial.

Contribuciones Personales

Eva

Muchas cosas.

Pau

Muchas cosas.

Mik

Muchas cosas.

Bibliografía

The sciences, each straining in its own direction, have hitherto harmed us little; but some day the piecing together of dissociated knowledge will open up such terrifying vistas of reality, and of our frightful position therein, that we shall either go mad from the revelation or flee from the deadly light into the peace and safety of a new dark age.

H.P. Lovecraft, *The Call of Cthulhu*

ASOBO STUDIO. Microsoft flight simulator 2024. PC / Xbox Series X/S. Xbox Game Studios, 2024.

AVALANCHE SOFTWARE. Hogwarts legacy. PC / PlayStation 5 / Xbox Series X/S. Warner Bros. Games, 2023.

BEAMNG. Beamng.drive. PC. BeamNG, 2015.

BERGAMIN, K., CLAVET, S., HOLDEN, D. y FORBES, J. R. Drecon: data-driven responsive control of physics-based characters. *ACM Trans. Graph.*, vol. 38(6), 2019. ISSN 0730-0301.

BERTICHE, H., MADADI, M. y ESCALERA, S. Pbns: Physically based neural simulation for unsupervised garment pose space deformation. *ACM Transactions on Graphics (TOG)*, vol. 40(6), páginas 1–14, 2021a.

BERTICHE, H., MADADI, M. y ESCALERA, S. Neural cloth simulation. *ACM Transactions on Graphics (TOG)*, vol. 41(6), páginas 1–14, 2022.

BERTICHE, H., MADADI, M., TYLSON, E. y ESCALERA, S. DeePSD: Automatic Deep Skinning And Pose Space Deformation For 3D Garment Animation. En *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*, páginas 5451–5460. IEEE, Montreal, QC, Canada, 2021b. ISBN 978-1-6654-2812-5.

CHAUDHARY, M., POKHARIYA, C. y NARAIN, R. Towards generalized position-based dynamics. *arXiv preprint arXiv:2511.23131*, 2025.

- CHEN, G., SURI, S., WU, Y., VOULGA, E., LEVIN, D. I. y PAI, D. Learning simulatable models of cloth with spatially-varying constitutive properties. *arXiv e-prints*, páginas arXiv-2507, 2025.
- CHEN, R.-C., DEWI, C., HUANG, S.-W. y CARAKA, R. E. Selecting critical features for data classification based on machine learning methods. *Journal of Big Data*, vol. 7(1), página 52, 2020.
- CHENTANEZ, N., MACKLIN, M., MÜLLER, M., JESCHKE, S. y KIM, T. Cloth and Skin Deformation with a Triangle Mesh Based Convolutional Neural Network. *Computer Graphics Forum*, vol. 39(8), páginas 123–134, 2020. ISSN 0167-7055, 1467-8659.
- GRIGOREV, A., THOMASZEWSKI, B., BLACK, M. J. y HILLIGES, O. HOOD: Hierarchical Graphs for Generalized Modelling of Clothing Dynamics. 2023. ArXiv:2212.07242 [cs].
- HECKER, C. Physics in computer games (title only). *Communications of the ACM*, vol. 43(7), páginas 34–39, 2000.
- HOLDEN, D., DUONG, B. C., DATTA, S. y NOWROUZEZAHRAI, D. Subspace neural physics: fast data-driven interactive simulation. En *Proceedings of the 18th annual ACM SIGGRAPH/Eurographics Symposium on Computer Animation*, páginas 1–12. ACM, Los Angeles California, 2019. ISBN 978-1-4503-6677-9.
- IRANZAD, R. y LIU, X. A review of random forest-based feature selection methods for data science education and applications. *International Journal of Data Science and Analytics*, vol. 20(2), páginas 197–211, 2025.
- JIM HUGUNIN, U. Unite 2016 - gpu accelerated high resolution cloth simulation. <https://www.youtube.com/watch?v=kCGHX1LR318>, 2016. Accessed: (15/04/2026).
- KENNY ERLEBEN, K. H., JON SPORRING. *Physics-based Animation*. Charles River Media, 2005.
- KUNOS SIMULAZIONI. Assetto corsa. PC / PlayStation 4 / Xbox One. 505 Games, 2014.
- MACKLIN, M., MÜLLER, M. y CHENTANEZ, N. XPBD: position-based simulation of compliant constrained dynamics. En *Proceedings of the 9th International Conference on Motion in Games*, páginas 49–54. ACM, Burlingame California, 2016. ISBN 978-1-4503-4592-7.
- MAHMOOD, N., GHORBANI, N., TROJE, N. F., PONS-MOLL, G. y BLACK, M. J. Amass: Archive of motion capture as surface shapes. páginas 5442–5451, 2019.
- MILLINGTON, I. *Game Physics Engine Development*. CRC Press, 2007. ISBN 9781482267327.

- MÜLLER, M., HEIDELBERGER, B., HENNIX, M. y RATCLIFF, J. Position based dynamics. *Journal of Visual Communication and Image Representation*, vol. 18(2), páginas 109–118, 2007. ISSN 10473203.
- PATEL, C., LIAO, Z. y PONS-MOLL, G. Tailornet: Predicting clothing in 3d as a function of human pose, shape and garment style. En *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, páginas 7365–7375. 2020.
- PLAYGROUND GAMES. Forza horizon 6. PC / Xbox Series X/S. Xbox Game Studios, 2026.
- PROVOT, X. Deformation Constraints in a Mass Spring Model to Describe Rigid Cloth Behavior. 1995.
- PROVOT, X. ET AL. Deformation constraints in a mass-spring model to describe rigid cloth behaviour. En *Graphics interface*, páginas 147–147. Canadian Information Processing Society, 1995.
- ROCKSTAR STUDIOS. Red dead redemption 2. PlayStation 4 / Xbox One / PC. Rockstar Games, 2018.
- ROCKSTEADY STUDIOS. Batman: Arkham knight. PC / PlayStation 4 / Xbox One. Warner Bros. Interactive Entertainment, 2015.
- SANTESTEBAN, I., OTADUY, M. A. y CASAS, D. Snug: Self-supervised neural dynamic garments. En *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, páginas 8140–8150. 2022.
- SUPERIOR SOFTWARE AUDIOGENIC. Exile. BBC, Electron, 1988.
- UBISOFT MONTREAL. Assassin's creed unity. PC / PlayStation 4 / Xbox One. Ubisoft, 2014.
- VA, H., CHOI, M.-H. y HONG, M. Real-time cloth simulation using compute shader in unity3d for ar/vr contents. *Applied Sciences*, vol. 11(17), 2021. ISSN 2076-3417.

Licencia de uso del documento

Esta obra está bajo una licencia [Creative Commons](http://creativecommons.org/licenses/by-sa/4.0/legalcode) «Atribución-NoComercial-CompartirIgual 4.0 Internacional».



<http://creativecommons.org/licenses/by-sa/4.0/legalcode>.

Licencia de uso del código fuente

Los archivos de código fuente para generar este documento se encuentran en <https://github.com/FratosVR/Memoria-TFG> bajo la licencia [GPL-3.0](#)