
Titulo del TFG
Title in english

Trabajo de Fin de Grado
Curso 2025–2026

Autor
Eva Paula Mik

Director
Ismael Sagredo Olivenza

Colaborador
Colaborador no definido. Usa \colaboradorPortada

Grado en Desarrollo de Videojuegos
Facultad de Informática
Universidad Complutense de Madrid

Titulo del TFG
Title in english

Trabajo de Fin de Grado en Desarrollo de Videojuegos

Autor
Eva Paula Mik

Director
Ismael Sagredo Olivenza

Colaborador
Colaborador no definido. Usa \colaboradorPortada

Convocatoria: *Junio 2026*

Grado en Desarrollo de Videojuegos
Facultad de Informática
Universidad Complutense de Madrid

17 de agosto de 2026

Dedicatoria

*A toda la gente que nos ha hecho llegar hasta
aquí,
un besazo.
A todos los que han estado a nuestro lado.*

Agradecimientos

Os amo!

Mik

Os amo!

Pau

Os amo!

Eva

Resumen

Titulo del TFG

Nuestro estudio se basa en la comparativa de distintos modelos de IA para hacer frente a la simulación de físicas costosas en proyectos 3D en motores de videojuegos.

Para ello creamos una simulación en Unity3D con un objeto con componente Cloth y una esfera que actúe como colisionador con la tela. Tras generar los datasets, los exportamos a cuadernos de Jupyter dónde los entrenamos con diferentes modelos en Pytorch (con soporte GPU): una red neuronal sencilla, una RNN, un Encoder-Decoder.

Finalmente exportamos las redes entrenadas a Unity mediante el paquete de Sentis para simular el movimiento modificando los vértices de una tela sin componente Cloth. Realizamos comparativas entre los distintos modelos, tanto en cuanto a precisión del modelo como a resultados visuales.

Observamos que el modelo que mejores resultados obtuvo en cuanto a tal métrica fue X.

Palabras clave

Inteligencia Artificial, Simulación física, Unity, Videojuegos, Optimización, PyTorch, ML

Abstract

Title in english

We need to do this.

Keywords

We need to do this.

Índice

1. Introducción	1
1.1. Motivación	2
1.2. Objetivos	2
1.3. Plan de trabajo	3
1.4. Metodología	4
2. Estado de la Cuestión	5
2.1. Motores de videojuegos	5
2.2. Motores de física	6
2.3. Simulación física en videojuegos	7
2.4. Simulación de telas	8
2.4.1. Cloth	8
2.4.2. Optimizaciones en simulación de telas	10
2.5. IA para optimización de telas	11
2.5.1. Modelos de optimización de telas	12
2.5.1.1. Subspace Neural Physics: Fast Data-Driven Interac- tive Simulation	12
2.5.1.2. Cloth and Skin Deformation with a Triangle Mesh Based Convolutional Neural Network	13
2.5.1.3. PBNS: Physically Based Neural Simulation for Un- supervised Garment Pose Space Deformation	14
2.5.1.4. SNUG	14
2.5.1.5. Neural Cloth Simulation	15
2.5.1.6. HOOD: Hierarchical Graphs for Generalized Mode- lling of Clothing Dynamics	15
2.5.2. Librerías	15
2.5.2.1. Pytorch	16
2.5.2.2. ONNX	16
2.5.2.3. Sentis	16
3. Conclusiones y Trabajo Futuro	17
3.1. Conclusiones	17

3.1.1. Limitaciones	18
3.2. Trabajo Futuro	19
Contribuciones Personales	21
Bibliografía	23
Licencia de uso del documento	27
Licencia de uso del código fuente	29

Índice de figuras

1.1. Diagrama de Gantt del proyecto. Representa la organización de las tareas en el tiempo de desarrollo del proyecto.	4
--	---

Índice de tablas

Introducción

En los últimos años, el aumento en el tamaño y la complejidad en los videojuegos ha supuesto la imprescindible optimización y automatización de diversos aspectos de su desarrollo, tanto en el ámbito del renderizado como en la lógica interna de los sistemas. Particularmente la evolución de entornos 3D, con el objetivo de obtener gráficos más detallados, ha implicado un incremento significativo en el coste computacional. Una forma de afrontar estas simulaciones para reducir su impacto computacional, es utilizar modelos de ML que permiten aproximar el comportamiento de estos elementos reduciendo el coste.

Empresas pioneras en hardware y software han desarrollado tecnologías para mejorar el rendimiento gráfico incorporando esta clase de algoritmos. Entre ellas destacan: NVIDIA con DLSS (Deep Learning Super Sampling), donde tenemos el Resident Evil Requiem que usa DLSS 4¹; y AMD con FSR (FidelityFX Super Resolution)². Asimismo, varias compañías lo incorporan en la lógica del juego simulando comportamientos y mecánicas como EA (FIFA), Embark Studios (Arc Raiders) o Ubisoft con sus múltiples líneas de investigación sobre la IA. En este contexto, un tercer campo de aplicación que está en proceso de investigación es la aplicación de modelos de aprendizaje automático en simulaciones físicas.

En el campo de la simulación física, con el incremento de la capacidad de cálculo de los sistemas actuales, se busca una mayor fidelidad en la recreación de las interacciones entre los diferentes elementos. Así por ejemplo, elementos como el cabello, los fluidos o las telas, elementos que hace poco más de una década estaban muy simplificados, en la actualidad se busca cada vez más con comportamiento realista en sus interacciones. Esta simulación física de sus comportamientos resulta en una carga computacional significativa, lo que afecta negativamente al rendimiento de los

¹**Deep Learning Super Sampling:** Aumenta el rendimiento del videojuego permitiéndolo renderizarse con una resolución más baja, ya que esta tecnología consigue reconstruir la imagen a mayor calidad en runtime. Utiliza herramientas como *Ray Reconstruction* para reemplazar sus *denoisers* manuales o DLAA (Deep Learning Anti-Aliasing) para suavizar los bordes.

²**FidelityFX Super Resolution:** técnica desarrollada por AMD de código abierto que consiste en el aumento del rendimiento en videojuegos mediante el escalado de resolución. Se diferencia del DLSS de NVIDIA por no tener requerimientos específicos de hardware.

videojuegos, en especial en términos de tasa de fotogramas. La industria se encuentra en un momento de auge en investigación y aplicación de Machine Learning para solucionarlo. Se puede observar por ejemplo, a través de los estudios de Ubisoft la Forge, el grupo de desarrollo e investigación de Ubisoft³. Entre sus investigaciones se encuentran aplicaciones recientes de ML en distintos campos de simulación; la adaptación de animaciones de personajes a interacciones físicas Bergamin et al. (2019) o la aceleración de simulaciones de cuerpos deformables Holden et al. (2019), sobre el que se profundizará en el siguiente capítulo.

1.1. Motivación

En la misma línea de otras tecnologías ya utilizadas en el desarrollo de videojuegos como la mencionada DLSS de NVIDIA, donde se aplican modelos de redes neuronales profundas para reducir la carga computacional de los juegos en el renderizado, se conducen estudios y empiezan a aplicar técnicas similares en la industria en simulación física. Nace en un contexto donde los juegos tienden a ser distribuidos ya no solo en consolas con hardware y gráficas dedicadas, sino en múltiples plataformas con el objeto de maximizar ingresos, donde no todas tienen las mismas capacidades de cómputo. El uso de estas técnicas de optimización puede permitir recrear estas simulaciones con un grado de fidelidad aceptable, en dispositivos de menor potencia como pueden ser Nintendo Switch, Handle pcs o dispositivos móviles.

Este enfoque implica una carga elevada al inicio de entrenamiento de modelos, compensado con una ejecución eficiente en tiempo real. Cabe destacar que, si bien utilizar la IA supone sacrificar la precisión absoluta de las físicas, no queremos caer en la falacia de la inmersión Salen y Zimmerman (2004). Nuestro objetivo es lograr simulaciones visualmente verosímiles, centrándonos en la percepción del usuario. Por ello, se ha optado por la simulación de telas. Este caso de estudio representa un equilibrio adecuado entre complejidad física y familiaridad con el resultado visual, de esta manera, realizaremos un análisis tanto técnico como perceptivo.

1.2. Objetivos

El objetivo general de este proyecto es la implementación de un modelo de IA que permita replicar el movimiento en tiempo real de una tela en un motor de videojuegos con baja latencia. Para cumplir con este objetivo, se plantean las siguientes metas durante el desarrollo del proyecto:

1. Generar una animación de una tela y un colisionador que varíe su movimiento en cada ejecución de la escena.

³Artículos y publicaciones de Ubisoft la Forge: <https://www.ubisoft.com/en-us/studio/laforge/publications#24A8zwsBgQ1tTM1NRp20b9%C3%A7>

2. Generar y procesar datasets con la información relevante de la tela respecto a su entorno y colisionador.
3. Implementar, entrenar y evaluar los distintos modelos de aprendizaje automático, tales como redes neuronales.
4. Analizar y comparar los resultados visuales de los distintos modelos.

1.3. Plan de trabajo

El desarrollo del proyecto se llevará a cabo en el periodo lectivo del curso 2025-2026. Dados los objetivos del apartado anterior, la planificación se divide en las siguientes iteraciones:

- **Iteración 0:** En esta etapa se concretan los objetivos reales de la investigación y se establece la planificación del trabajo respecto a la propuesta inicial.
- **Iteración 1:** Etapa de preparación, donde se cumplirán los siguientes subobjetivos para implementar un sistema de simulación adecuado para ser procesado por los modelos en un futuro.
 - **Iteración 1.1:** Se realizará una investigación de trabajos relacionados a este, relevante para dirigir el desarrollo de los experimentos. Se analizarán distintas alternativas y se decidirá cuales resultarán más interesantes de replicar, se definirán qué tipo de datos deberemos recopilar para el entrenamiento y qué tipo de redes podrán llevarlo a cabo.
 - **Iteración 1.2:** Se creará una simulación básica en Unity y un sistema de registro de datos relevantes a la tela.
- **Iteración 2:** Se establecerá un entorno de trabajo para el entrenamiento de los datos recopilados. Se generará un pipeline claro en el que se integre la simulación de recogida de datos, su limpieza y posterior uso para entrenar el modelo y, finalmente, la incorporación de este al entorno de simulación. Para poder asegurar del correcto funcionamiento de este sistema se generará un modelo simple y se comprobará que el pipeline es correcto. En esta fase se comenzarán a redactar los primeros capítulos de la memoria.
- **Iteración 3:** Con una base sólida ya montada, se aumentará la complejidad y, por consiguiente, el coste de la simulación. Se implementarán distintos modelos y se llevarán a cabo pruebas con todos ellos para asegurarse de su fiabilidad.
- **Iteración 4:** Si las anteriores iteraciones funcionan de manera correcta esta última no tendrá ninguna carga de implementación. Se alcanzará la última meta definida: hacer distintas pruebas entrenando los modelos ya desarrollados, sacar métricas de todos ellos para poder hacer comparaciones y hacer un análisis exhaustivo de estos resultados, sacando así las conclusiones de la investigación.

El desarrollo de las tareas y su planificación se puede ver en la figura 1.1.




Figura 1.1: Diagrama de Gantt del proyecto. Representa la organización de las tareas en el tiempo de desarrollo del proyecto.

1.4. Metodología

Para el desarrollo de esta investigación se emplearán herramientas de libre acceso y uso gratuito, con el objetivo de facilitar la reproducibilidad de los resultados obtenidos. El entorno de desarrollo principal será Windows 11, al tratarse del sistema operativo utilizado por el equipo de trabajo y extendido entre los potenciales usuarios. La simulación de la tela, así como la integración del modelo de inteligencia artificial, se llevarán a cabo en Unity (versión 6000.3.2f1, correspondiente a una versión de soporte a largo plazo). En cuanto a los lenguajes de programación, se empleará C# para el desarrollo dentro de Unity, incluyendo la generación de la simulación y la recopilación de datos, mientras que se utilizará Python con Pytorch para el entrenamiento de los modelos de aprendizaje automático. La integración de los modelos entrenados en el entorno de ejecución se realizará a través del paquete Unity Sentis.

Para la gestión del código fuente y el trabajo colaborativo se utilizará GitHub, basado en el sistema de control de versiones Git. Asimismo, se empleará la herramienta GitHub Projects para la planificación, asignación y seguimiento de tareas. Como herramientas adicionales, se utilizará Google Drive para el almacenamiento de documentación, apuntes de reuniones y materiales de trabajo puntuales, y Discord para la coordinación del equipo mediante reuniones online, además de encuentros presenciales semanales.

Capítulo 2

Estado de la Cuestión

En este capítulo se presenta una breve resumen del desarrollo de las simulaciones físicas en videojuegos, así como el hardware y software que ha hecho que esta evolución sea posible. También se presenta la simulación de telas, sus diferencias de implementación, los problemas de optimización que estas suponen y los avances en modelos de IA que permiten imaginar otras soluciones.

2.1. Motores de videojuegos

Si bien este proyecto se centra en la computación física, gestionada por los motores físicos, los motores de videojuegos proporcionan un conjunto más amplio de herramientas comunes para el desarrollo de videojuegos, entre los cuales encontramos también los motores de renderizado, sonido y otros componentes como los sistemas de scripting o interfaz de usuario, que se complementan para satisfacer las necesidades que requiere la creación de un juego. Existe gran cantidad de motores de videojuegos, siendo algunos de los más conocidos Unity y Unreal, que se detallarán a continuación. Además de estos motores comerciales de acceso general, muchos estudios grandes disponen de motores propios adaptados a sus necesidades y especialización. Algunos ejemplos son Frostbite de Electronic Arts y SnowDrop de Ubisoft. Los dos motores comerciales más utilizados son:

- **Unreal Engine:** Es un motor de videojuegos creado por Epic Games en 1998. Destaca por su motor gráfico, que permite gráficos realistas en tiempo real con tecnologías como Nanite para geometría virtualizada o Lumen para iluminación dinámica. Es multiplataforma y se encuentra no sólo en pequeños desarrollos independientes (indie), sino en grandes producciones multimillonarias (producciones AAA'). Se caracteriza por su sistema de programación visual (Blueprints) en programación con C++. Integraba Physx como motor físico hasta la introducción reciente de Chaos Physics en su versión 5.7, que aporta novedades que se destacarán más adelante en el apartado [2.4.2](#).
- **Unity:** Creado por Unity Technologies en 2005, abarca un porcentaje del 51 %

de juegos publicados en 2024 y un 26 % ¹ en las unidades vendidas en Steam. Es el motor de videojuegos más utilizado por desarrolladores indie y cuenta con documentación extensa, una gran comunidad y extensiones como SentiS para la integración de modelos de IA, que explicaremos más adelante. Unity3D integra PhysX como motor de físicas, pero puede incorporar otros sistemas de físicas como Havok bajo licencia ². Está basado en la arquitectura Entidad-Componente en C#, y típicamente se utiliza para juegos más pequeños y menos potentes en cuanto a gráficos.

2.2. Motores de física

Un motor de físicas es un conjunto de funciones y recursos que permite la implementación de sistemas de físicas como cuerpos rígidos con su consecuente detección de colisiones, cuerpos blandos e incluso fluidos.

Los motores de física se extendieron en los años 90, con la popularidad del 3D y gráficos en auge. Los grandes cálculos en tiempo real con su correspondiente carga para la CPU plantearon dos grandes retos: el avance de los motores físicos cada vez más precisos y potentes, y, por otro lado, la optimización del hardware para llegar a la demanda computacional que esto suponía.

En 2002 se funda Ageia Technologies, responsable de la creación del primer procesador de física dedicado para ordenadores, denominado PhysX PPU (Physics Processing Unit), así como del motor PhysX ³, que sigue siendo líder en la industria a día de hoy. Posteriormente, NVIDIA Corporation, conocida por su papel en la producción de GPUs, adquiere Ageia, impulsando el cálculo de físicas en GPU. Esto, sumado a la dificultad de penetrar en el mercado del hardware, hace que la producción de PPUs quede obsoleta.

Por otro lado, Intel adquiere en 2007 Havok ⁴, otro de los primeros motores de físicas, cancelando el programa HavokFX que pretendía llevar el cálculo de físicas a la GPU para realizar estos en sus CPUs multinúcleo. Posteriormente es adquirido por Microsoft en 2015 y se integra en las herramientas de desarrollo como DirectX. Se establece como el middleware más común en grandes producciones y simulaciones complejas en estudios, mientras que Physx se convierte en libre acceso en 2018 y se integra en motores de videojuegos como Unreal.

La incorporación de motores de física completos en el desarrollo de videojuegos aporta escalabilidad en el *gameplay*, manteniendo la coherencia de sus elementos físicos, lo que resulta imprescindible para la inmersión del jugador Hecker (2000).

¹Según The Big Engines Report 2025 por parte de Sensor Tower https://app.sensortower.com/vgi/assets/reports/The_Big_Game_Engines_Report_of_2025.pdf

²Véase distintas físicas integrables en Unity: <https://docs.unity3d.com/Manual/physics-integrations.html>

³Documentación de Physx: <https://developer.nvidia.com/physx-sdk>

⁴Documentación de Havok: <https://www.havok.com/havok-physics/>

2.3. Simulación física en videojuegos

Hasta la llegada de los motores comentados en el apartado 2.2, existían otras técnicas para representar comportamientos físicos que eran todavía muy rudimentarias: se diseñaban las interacciones físicas previamente para parecer realistas, ya que dada la capacidad de cómputo con la que solían contar las máquinas, era imposible hacer todos los cálculos físicos en tiempo real. Se realizaban detecciones de colisiones simples, sin uso de fuerzas y descripciones de movimientos o respuestas de cada elemento del juego en lugar de sistemas de física.

Estos métodos eran claramente limitados en la precisión que ofrecían, y quedaba clara la necesidad de una solución más general y reproducible. Ian Millington introduce en su libro *Game Physics Engine Development* [Millington \(2007\)](#) el juego *Exile* [Superior Software Audiogenic \(1988\)](#), creado por Peter Irvin y Jeremy Smith; si bien este juego fue publicado en 1988, ya contaba con conservación del momento en colisiones, gravedad, y fuerzas como el viento o explosiones. Resalta como uno de los primeros juegos que cuenta con un motor de físicas completo.

Actualmente existen juegos con simulaciones físicas muy realistas como *Red Dead Redemption 2* [Rockstar Studios \(2018\)](#) o *Hogwarts Legacy* [Avalanche Software \(2023\)](#) donde más allá de satisfacer necesidades de gameplay, se consiguen mundos creíbles en su conjunto. Otros juegos se basan directamente en el funcionamiento y excelencia de sus físicas, particularmente simuladores de vehículos o deformaciones como la saga de *Assetto Corsa* [Kunos Simulazioni \(2014\)](#), el nuevo *Forza Horizon 6* [Playground Games \(2026\)](#), *Microsoft Flight Simulator 2024* [Asobo Studio \(2024\)](#) o *BeamNG.drive* [BeamNG \(2015\)](#), que sigue destacando por su física basada en cuerpos blandos.

Es importante conocer la diferencia entre la simulación de un cuerpo rígido y la simulación de un cuerpo blando para comprender la complejidad que implica cada uno. Se entienden los objetos deformables o cuerpos blandos como aquellos que no son rígidos, es decir, que pueden perder o modificar su forma si reciben fuerzas físicas externas. Para un cuerpo rígido, al no ser deformable, solo hay que calcular su posición, rotación y velocidad en un momento dado, en función de su estado previo y de la interacción con otros elementos físicos. Sin embargo, en el caso de un cuerpo blando, a parte de su posición y velocidad y rotación como cuerpo, hay que calcular la posición, velocidad y rotación de las partes que lo componen, a las que se les suele denominar "partículas". Estas partículas se ven afectadas por propiedades físicas como la tensión y la deformación, que modifican el comportamiento de las mismas y su interacción con otros cuerpos. Entre los cuerpos blandos se encuentran elementos como las telas, el agua o el viento [Kenny Erleben \(2005\)](#).

Dada la complejidad de estas simulaciones, se necesita un programa que se en-

cargue de realizar los cálculos necesarios para cada partícula. A estos programas de simulación se les denomina *solvers*. Pese a encontrar múltiples acepciones en el término solver para distintas resoluciones de problemas, aquí nos referiremos como solver al algoritmo computacional que se encarga de predecir el comportamiento de estos objetos deformables en renderizados y simulaciones físicas, específicamente en la próxima sección 2.4.1, de telas.

Otro concepto de gran importancia para este estudio es el *Signed Distance Field* (SDF), que será mencionado frecuentemente en los siguientes apartados a la hora de trabajar con las colisiones con objetos externos. Los SDF representan la distancia entre un punto y la superficie más cercana de un objeto o conjunto de coordenadas. Son frecuentemente usados en la informática gráfica y generalmente se calculan como la distancia ortogonal a un espacio métrico.

2.4. Simulación de telas

El protagonista de la simulación de telas es la vestimenta: vestidos, cintas o capas moviéndose dependiendo de las acciones del jugador, viento y condiciones específicas; lo que permite a los jugadores un mayor grado de inmersión y una mayor credibilidad del mundo del videojuego. Además de tener objetos hechos a partir de tela como ropa o banderas, pueden incluso aplicarse las físicas de la tela en otros elementos como pelo, hierba o cuerpo blandos como globos; como señala Havok: “*Havok Cloth is used to create secondary motion and to enhance any object that flows*”⁵.

Algunos juegos que destacan por comenzar a usar la simulación de telas en tiempo real son *Assasins Creed Unity*(2014) Ubisoft Montreal (2014) que usó un sistema personalizado de Havok Cloth y *Batman:Arkham Knight* (2015) Rocksteady Studios (2015) con un sistema híbrido de físicas y rigging usando Apex Cloth⁶.

En esta sección se describe cómo se representa y simula una tela en tiempo real, el problema que supone y qué tipos de soluciones encontramos. Se indagará mayoritariamente en ejemplos de Unity3D, como referencia elegida de motor de videojuegos.

2.4.1. Cloth

Cloth⁷ es un componente que proporciona Unity3D que funciona junto al componente *Skinned Mesh Renderer* para simular telas. Está basado en Cloth de PhysX⁸ y fue incorporado con el objetivo de poder simular el comportamiento de la ropa de personajes dentro de un videojuego. Es altamente configurable, lo que le permite adaptarse a múltiples tipos de telas. Las características parametrizables de la tela

⁵Página de Havok Cloth: <https://www.havok.com/havok-cloth/>

⁶Página web de Apex Clothing: <https://www.nvidia.com/en-us/drivers/apex-clothing/>

⁷Documentación de Cloth (Unity): <https://docs.unity3d.com/Manual/class-Cloth.html>

⁸Documentación de Cloth (Physx): <https://archive.docs.nvidia.com/gameworks/content/gameworkslibrary/physx/guide/3.3.4/Manual/Cloth.html>

son:

- Rigidez del estiramiento: determina cuánta resistencia opone la tela a estirarse.
- Rigidez de flexión: resistencia a la deformación de la tela. Un valor bajo provoca pliegues suaves y dinámicos en la tela. Junto a la rigidez de estiramiento, define la personalidad de la tela, permite recrear el material del que está formada, así como la técnica o estructura que la construye (hilos entrelazados (*knit*) o continuos (tejido)).
- Uso de *tethers*: aplica restricciones que ayudan a prevenir el movimiento de partículas de la tela de irse muy lejos de las que están fijas y reducir así el exceso de estiramiento.
- Uso de Gravedad sobre la tela.
- *Damping* o Coeficiente de amortiguación del movimiento: define la rapidez con la que la tela retorna a su pose de reposo.
- Aceleración externa y aleatoria: permiten simular fuerzas como el viento de forma integrada, con movimientos más estables con aplicando la constante de aceleración y movimientos más erráticos (como podría ser un vendaval) aplicando el valor aleatorio.
- Escala de velocidad y aceleración del mundo: determinan cuánto afectará sobre los vértices de la tela la velocidad y aceleración del personaje en el espacio del mundo.
- Fricción: resistencia al deslizamiento que presenta la tela al colisionar con el personaje u otros colisionadores.
- Masa de colisión escalada: qué tanto aumentar la masa de las partículas en colisión.
- Uso de colisión continua: activado detecta colisiones con mayor precisión, contribuyendo a la mejora de estabilidad.
- Use virtual particles: agrega una partícula virtual por triángulo para mejorar también la estabilidad de colisión.
- Frecuencia del solver: número de iteraciones del solver de la tela por segundo. Un número alto de iteraciones mejora las colisiones, pero sobrecarga la CPU.
- Umbral de adormecimiento de la tela: valor que toma el solver de la tela para considerar las partículas como quitas o “adormecidas” y evitar sobrecargar los cálculos.
- Colisionadores: dos arrays de *CapsuleColliders* y *SphereColliders*.

Adicionalmente, tenemos las restricciones por vértice o *constraints*. Se pueden pintar a través de un mapa de calor los límites de movimiento:

- *Max Distance*: distancia máxima que un vértice de la tela puede moverse desde su posición original en la animación.
- *Surface Penetration*: cuánto puede hundirse el vértice dentro de la malla del personaje.

Physx trata la tela como una malla de partículas conectadas por restricciones. El *Skinned Renderer* calcula las transformaciones basándose en una malla de baja resolución sobre la que realiza los movimientos en los vértices, que dinámicamente se aplican en la malla real y se obtiene la simulación visual. Aquellos constraints no visibles o de distancia 0, fijos, no serán calculados. Cómo se ha podido apreciar en los puntos anteriores, la tela cuenta con capacidad de colisionar internamente y con dos tipos de colliders externos: cápsulas o esferas. Cualquier objeto externo o personaje con el que se quiera colisionar tendrá que ser un conjunto de estos colliders.

Los primeros solvers para telas se basan en algoritmos que emplean la fuerza bruta: realizan cálculos en masa para sistemas de muelles (MSS o Mass Spring Systems) basándose en la Ley de Hooke ⁹. Los vértices de la tela tienen un peso y están unidos por tres tipos de muelle que aseguran que la tela mantenga su forma, no se distorsione o doble en exceso Provot (1995). Los solvers más actuales resultan en el PBD o *Position-Based Dynamics*, proceso iterativo que proyecta las posiciones de las partículas sobre un “espacio de restricciones” Müller et al. (2007), es decir, actualizando el desplazamiento generado por cada fuerza en cada vertice de la simulación Chaudhary et al. (2025).

El solver de PhysX se basa en PBD, es decir, trabaja directamente sobre las posiciones. Asimismo XPBD: Extended Position-Based Macklin et al. (2016), es una versión extendida que, con un coste ligeramente superior, incide en la alta dependencia sobre el paso del tiempo e iteraciones de la simulación de PBD. Unreal con Chaos integrado ya acepta constraints de tipo XPBD y también puede integrarse en Unity.

2.4.2. Optimizaciones en simulación de telas

Como se ha introducido antes, la simulación de telas en tiempo real supone una serie de desafíos conocidos, de los que se sigue buscando la optimización a día de hoy. El aumento de tamaño o complejidad de una tela, con su alta carga computacional, conlleva el decaimiento inmediato de frames. A parte de dificultar el realismo en juegos y demás simulaciones a tiempo real, resulta un gran impedimento en entornos donde se requieren tasas altas de fotogramas por segundo o una menor capacidad de cómputo, por ejemplo, en dispositivos móviles sujetos a batería.

Mientras que el Cloth de PhysX puede delegar la simulación a GPUs compatibles con CUDA, el Cloth integrado por defecto en Unity realiza todo su trabajo en la

⁹La ley de Hooke establece que la fuerza necesaria para deformar un cuerpo elástico, como un muelle o resorte, es directamente proporcional a la deformación producida, siempre que no se supere su límite elástico.

CPU, lo cual puede ralentizar mucho la ejecución. En el caso de Unreal, previamente al lanzamiento de ML Cloth Simulation, Chaos Physics delegaba su mayor fuerza de trabajo también en la CPU.

Existen varios tipos de soluciones para la optimización de la simulación de telas:

- **Optimización por CPU:** La extensión de *Obi Cloth* ¹⁰ aprovecha el sistema de Jobs de Unity para paralelizar la simulación y acelerar la simulación sin salir de la CPU. Es uno de los paquetes más populares para solucionar este problema.
- **Paralelización en GPU:** a través de *shaders* se delega la fuerza de cálculo del *skinning* en la GPU. Diferentes estudios e individuos aportan diferentes enfoques para la optimización, por ejemplo, [Jim Hugunin \(2016\)](#) realiza una investigación para alcanzar altas resoluciones y evitar colisiones en las mallas, mientras que otros se centran en la mejora de rendimiento pura para adaptar simulaciones a entornos VR [Va et al. \(2021\)](#).
- **Entrenamiento con IA:** Otro enfoque es el del uso de ML para simular el comportamiento de Cloth. Esta solución ha ido cobrando fuerza en la actualidad debido a la popularización de los modelos de IA que se han aplicado con éxito en otros campos como se ha visto en la introducción 1. Se entrenan modelos de ML con los datos de las mallas animadas o poses, con el objetivo de que el modelo consiga simular el comportamiento de la tela utilizando menos cálculos al ejecutarlo que la simulación real. Se sacrifica memoria y tiempo de entrenamiento para obtener mejores y mucho más rápidas simulaciones de tela en escena. Actualmente la investigación se encuentra en el contexto de implementación para grandes empresas: Unreal ya proporciona para Chaos Cloth ¹¹ una simulación de tela a través de aprendizaje automático, en el que destaca su realismo. Aún así, cuenta con limitaciones al basarse en un *NearestNeighborSearch*: “el sistema es capaz de predecir detalles como arrugas pero no movimiento dinámico como ondulaciones o drapeados”. En la próxima sección se detallarán las numerosas investigaciones recientes que abarcan aspectos desde la reproducción de arrugas, el compromiso entre calidad, coste y rendimiento hasta colisiones y penetraciones en las mallas.

2.5. IA para optimización de telas

Aprovechando la comprobada capacidad de las redes neuronales profundas para aproximar cualquier función matemática, una aproximación que cada vez emerge con más fuerza es el uso de estos modelos de redes neuronales para ejecutar simulaciones físicas. En estas se destacan las aplicaciones sobre telas y cuerpos no rígidos similares.

¹⁰Obi en la Unity Asset Store: <https://assetstore.unity.com/packages/tools/physics/obi-cloth-81333?aid=1011134eQ>

¹¹Documentación introductoria de Chaos Cloth: <https://dev.epicgames.com/documentation/unreal-engine/machine-learning-cloth-simulation-overview>

2.5.1. Modelos de optimización de telas

Desde la introducción del PBD, la optimización de simulaciones con redes neuronales cuenta ya con un amplio recorrido. En este apartado se describen los estudios más destacados de los últimos años. Son también inspiración directa para la implementación de nuestros experimentos, con el objetivo de descubrir cuáles de estas técnicas son verdaderamente aplicables a menor escala, en desarrollo indie con recursos limitados en cuanto a hardware y especialización físico-matemática.

2.5.1.1. Subspace Neural Physics: Fast Data-Driven Interactive Simulation

Este desarrollo de la unidad de investigación Ubisoft La Forge [Holden et al. \(2019\)](#) implementa la primera técnica que incorpora reducción de modelo o el uso de subespacios con colisiones con objetos externos en la tela. El estudio se centra en conseguir un balance entre el rendimiento en tiempo real y el coste y memoria necesarios para realizar el precómputo.

El entrenamiento se realiza sobre las posiciones de una simulación realizada en Maya aplanados en un vector, al que se añade otro vector plano con los parámetros necesarios como posición del suelo, valor del viento, o collisionadores con la tela. Se aplica un PCA¹² sobre ambos denotando cuántos ejes de deformación de la tela se tienen en cuenta para representar la complejidad de la recreación: 64, 128, 256; siendo este último el que conserva casi el mismo nivel de detalle que la simulación original. La arquitectura del modelo se basa en una red neuronal estándar que opera sobre el subespacio.

Para evitar que la simulación colapse con el error que va produciendo, se aplican dos estrategias:

- Ventanas de frames superpuestas, con bloques de 32 frames con *mini-batches*¹³ para mantener la coherencia a largo plazo
- Ruido gaussiano, para que la red aprenda a corregirse.

Además, los cálculos necesarios durante la ejecución se aceleran con shaders en GPU (*GPU decompression*) y se recalculan las normales de los vértices necesarias para el renderizado.

Sus principales limitaciones residen en la necesidad de quitar a mano errores producidos en la simulación, falta de pruebas en objetos plásticos y posibles colisiones internas fallidas. Además, se resalta como limitación realizar el entrenamiento con

¹²*Principal Component Analysis*, es una técnica que disminuye el número de variables de un dataset, preservando la mayor cantidad de información y varianza posible y reduciendo así su complejidad

¹³Un *batch* o lote en IA se refiere al conjunto de datos que recibe una red en su entrenamiento de forma simultánea. Su uso sirve para la optimización de recursos y memoria.

un objeto colisionador fijo en el espacio, sin habilitar situaciones más dinámicas como por ejemplo, un escenario en el que objetos caigan por el espacio. Finalmente se remarca la cantidad elevada de datos y tiempo empleados para los entrenamientos: se necesitaron hasta 10^6 frames de simulación como referencia para obtener buenos resultados, así como entre 10 y 48 horas de entrenamiento.

2.5.1.2. Cloth and Skin Deformation with a Triangle Mesh Based Convolutional Neural Network

Este estudio [Chentanez et al. \(2020\)](#) es un ejemplo de uso de CNN (redes convolucionales ¹⁴), para la simulación de telas. Reseña la dificultad de integrar una CNN debido a la construcción de la malla, incompatible antes de su modificación con una cuadrícula 2D. Resuelve el problema entrenando mallas "manifold" triangulares: es decir, mallas cuyos bordes están conectados por al menos dos caras (menos los extremos) dejando una separación entre exterior e interior. Mapear la malla a una imagen 2D es lo que permite realizar la convolución.

La solución planteada en este trabajo es el uso de una red encoder-decoder¹⁵ formada por bloques "DownConv", para la reducción, y "UpConv", para la reconstrucción, que integra operadores nuevos de convolución¹⁶. En el bloque de "DownConv", utiliza una técnica de pooling destacable: colapasa los edges siguiendo un método en espiral. También señala la importancia de usar Leaky-CNN: para no dejar neuronas muertas, que resulta un problema en la simulación. Además de combinar funciones de pérdida L2 y L1¹⁷, para que no se quede el error acumulado en ciertos vértices.

Este estudio, a diferencia del anterior, incluye brazos y manos, y se rige en un marco de posiciones locales por cada triángulo. Afirma conseguir resultados muy cercanos al *ground truth*¹⁸ usando la base de animaciones *Berkley animation base* y una gran capacidad de hardware disponible. No obstante, resaltan una vez más los largos tiempos de entrenamiento (entre 4 y 20 horas) y la necesidad de calidad y cantidad de datos de entrenamiento. Tampoco aporta simulaciones para topología

¹⁴Las redes neuronales convolucionales (CNN) son un tipo de arquitectura de DL diseñada para el procesamiento de datos estructurados en forma de cuadrícula, como imágenes, vídeos o secuencias temporales

¹⁵**Red encoder-decoder:** Arquitectura de red neuronal diseñada para mapear una secuencia de entrada a una secuencia de salida, donde ambas pueden tener longitudes diferentes. El *Encoder* comprime la información de entrada para operar con ella fácilmente, y el *Decoder* procesa esa representación para generar la salida con las dimensiones reales.

¹⁶**Convolución:** Operación matemática donde un filtro o *kernel* realiza multiplicaciones elemento a elemento, permitiendo extraer patrones estructurales.

¹⁷**L2 y L1:** Funciones que miden la diferencia entre el valor real y el predicho. La pérdida L_1 (Error Absoluto Medio) calcula la suma de las diferencias absolutas, siendo robusta frente a valores atípicos. La pérdida L_2 (Error Cuadrático Medio) calcula la suma de los cuadrados de las diferencias, penalizando fuertemente los errores grandes.

¹⁸El *ground truth* es la información verdadera o correcta, a diferencia de los datos producidos por inferencia. En el caso de una recrear una simulación con ML podría consistir en el conjunto de animaciones creadas para entrenar o validar, es decir, los movimientos y comportamientos "correctos".

dinámica ¹⁹ y se ciñe mucho al entrenamiento. Debido a la arquitectura de CNN triangular, sumado al objetivo de alcanzar velocidad y detalle en assets específicos, se pierde la capacidad de generalización.

Otro ejemplo de estudio que usa una CNN para la simulación de telas es DeepSD: Real-time Cloth Simulation with Deep Learning [Bertiche et al. \(2021b\)](#); en la que proyecta la malla 3D en un plano utilizando sus coordenadas UV²⁰. Usa una CNN estándar, y no depende de una malla fija, pudiendo aceptar cambios en la topología de la malla, por lo que sirve para automatizar el proceso. El uso de SDF garantiza la generación de ropa que envuelva el cuerpo sin importar la conectividad de la malla durante los cálculos intermedios. No obstante, comparando con el estudio de Chentanez et al. este estudio no consigue capturar arrugas finas o superficiales con detalle y es menos eficiente debido a su enfoque volumétrico.

2.5.1.3. PBNS: Physically Based Neural Simulation for Unsupervised Garment Pose Space Deformation

PNBS [Bertiche et al. \(2021a\)](#) presenta una simulación neuronal DL no supervisada, como alternativa al enfoque clásico PBS. Integra principios físicos en el entrenamientos con funciones físicas de energía, entre ellas restricciones de fijación. La arquitectura consiste en un perceptron multicapa (MLP, por sus siglas en inglés *Multi-Layer Perceptron*) con funciones ReLU²¹ que genera deformaciones tipo PSD sobre modelos LBS, cuya aplicación en el mundo 3D garantiza la compatibilidad con los motores gráficos y su alta eficiencia. Esta metodología entrena sobre datasets públicos como *AMASS* [Mahmood et al. \(2019\)](#) y *CMU MoCap*, siendo capaz de manejar colisiones en poses extremas, así como colisiones cloth-to-cloth. Asimismo, permite la obtención de prendas que se ajustan a diferentes cuerpos (garment resizing). En comparación a otros métodos como TailorNet [Patel et al. \(2020\)](#), logra una mayor consistencia física y generalización, además de un coste computacional considerablemente menor, incluso sin GPU. Sin embargo, se ve limitado por su enfoque en poses estáticas.

2.5.1.4. SNUG

Siguiendo la tendencia hacia el aprendizaje no supervisado basado en físicas, la técnica SNUG [Santesteban et al. \(2022\)](#) va más allá de la deformación basada en poses mencionado en el estudio anterior. Si bien trabaja con 6,519 fotogramas de la misma base de datos, gracias a una red recurrente (cuya arquitectura no se explica con exactitud) consigue mejores tiempos de entrenamiento y resultados más detallados que la técnica anterior. Pone el foco del aprendizaje en crear una serie de funciones de loss basadas en las físicas reales de deformaciones dinámicas:

¹⁹La topología dinámica aquí se refiere a la topología adaptativa en mallas, requeridas en aplicaciones de diseño y edición de mallas.

²⁰Las UVs son coordenadas bidimensionales que definen cómo se proyecta una textura 2D sobre la superficie de un modelo 3D. El mapeo UV consiste en aplanar o desplegar una malla 3D sobre una superficie plana.

²¹Función de activación *Rectified Linear Unit* se define matemáticamente como $f(x) = \max(0, x)$

“Membrane Strain Energy” (la energía transmitida entre dos puntos en base a la elasticidad del material), “Bending Energy” (el ángulo diédrico entre dos caras en relación a su propiedad de rigidez), “Gravity” (gravedad) y “Collision Penalty” (la distancia prudencial entre el modelo y el cuerpo).

2.5.1.5. Neural Cloth Simulation

Neural Cloth Simulation [Bertiche et al. \(2022\)](#) también propone una metodología no supervisada, unificando simulación y entrenamiento. Sigue el esquema clásico de este tipo de solvers, donde el estado de la tela depende de los instantes previos, gestionado por ventanas de frames cuyo tamaño y complejidad dependen del tipo de tela procesada. Su arquitectura consiste en un encoder-decoder recurrente que separa componentes estáticos y dinámicos, haciendo uso de modelos GRU en estos últimos y la cual permite mejorar la generalización y estabilidad del entrenamiento. Este se realiza mediante funciones de pérdida inspiradas en simulación física, incluyendo restricciones físicas en relación a deformaciones, colisiones e inercia. El dataset utilizado también es AMASS [Mahmood et al. \(2019\)](#), que recopila información de mas de 40.000 poses, y el modelo físico extiende la idea del modelo mass-spring [Provot et al. \(1995\)](#). En comparación con PBNS o SNUG, esta metodología consigue soluciones más robustas y simples que dan a simulaciones detalladas a costa de mayores tiempo de entrenamiento que sus predecesores, compensando, no obstante, la disminución de recursos al no realizar procesos de generación de datos. Esta perspectiva va de la mano con tendencias actuales en la industria, como la ya mencionada e implementada Chaos Cloth de Unreal Engine.

2.5.1.6. HOOD: Hierarchical Graphs for Generalized Modelling of Clothing Dynamics

En investigaciones más recientes, se aborda la cuestión de la posibilidad de abstraer también la topología de la tela del aprendizaje. En este caso, HOOD utiliza GNNs, una arquitectura de envío de mensajes jerárquico y por supuesto la función de pérdida basada en la física que puede verse en los previos estudios [Grigorev et al. \(2023\)](#). Los graph neural networks permiten crear un gráfico que incorpora los vértices del cuerpo colisionador. A través de este se propagan los mensajes de aceleración recursivamente, lo que permite ajustar la precisión de la inferencia y adaptarse a distintos materiales, topologías y modelos de colisión.

Este estudio sigue estando limitado en aspectos como la velocidad de simulación o colisiones internas. Al fin y al cabo, este sigue siendo un campo de estudio en crecimiento, en el que todavía queda mucho por avanzar.

2.5.2. Librerías

Por último, en este apartado se describen las librerías que han resultado indispensables para entrenar los modelos de IA y conectarlos a la simulación en Unity.

2.5.2.1. Pytorch

Pytorch²² es una de las librerías de código abierto que permite implementar redes neuronales propias. Los tensores²³, matrices multi-dimensionales análogas a los NumPy arrays de Python, permiten optimizar las redes tanto para el uso de CPU como de GPU. Suele ser la más elegida en entornos académicos, ya que permite prototipado rápido y entrenamiento dinámico. Fue originalmente desarrollado por Meta, y todavía cuenta con una enorme comunidad de desarrolladores.

2.5.2.2. ONNX

ONNX (*Open Neural Network Exchange*)²⁴ es un formato creado para representar modelos de aprendizaje automático. Fue introducido por Facebook y Microsoft en 2017, con el objetivo de facilitar el cambio de entornos de trabajo en aprendizaje automático. Estandariza la estructura de redes neuronales y tipos de datos, definiendo un conjunto común de operadores y un formato de archivo estándar, permitiendo entrenar y desplegar modelos entrenados en distintos ecosistemas. Es un formato ampliamente aceptado por fabricantes de hardware como NVIDIA o Intel, que proporcionan proveedores de ejecución especializados para la conexión.

2.5.2.3. Sentis

Sentis (previamente Inference Engine)²⁵ es una librería de inferencia de redes neuronales para Unity, predecesora introducida en el 2023 de la librería Barracuda. Permite importar modelos de redes neuronales entrenados a Unity y ejecutarlos en tiempo real tanto con la CPU como con la GPU de forma local en el usuario, reduciendo latencia y costes de servidores en la nube.

Los modelos pueden ejecutarse localmente en las plataformas que soportan Unity, lo que permite que pueda adaptarse a diferentes tipos de hardware: tanto en PC, como en móviles, consolas o web. Su compatibilidad reside en los modelos importados en formato ONNX, cuyos grafos se optimizan después para la ejecución del juego.

Algunos usos de Sentis son las estimaciones de poses en tiempo real o NPCs que reaccionen a texto o voz del jugador.

²²Documentación de Pytorch: <https://docs.pytorch.org/docs/stable/index.html>

²³Documentación correspondiente a los tensores: <https://docs.pytorch.org/docs/2.12/tensors.html>

²⁴Página web de ONNX: <https://onnx.ai/>

²⁵Documentación del paquete Sentis: <https://docs.unity3d.com/Packages/com.unity.ai.inference@2.4/manual/index.html>

Conclusiones y Trabajo Futuro

3.1. Conclusiones

El objetivo de esta investigación era conseguir replicar el movimiento de una tela en un motor de videojuegos a tiempo real con baja latencia, haciéndolo accesible para desarrolladores indies y pudiéndose ejecutarse en equipos de rendimiento menor como portátiles de potencia reducida o móviles.

Se crearon simulaciones de telas con geometrías simples y movimientos dinámicos provocados por un objeto colisionador en Unity. Durante la ejecución se extrajeron los datos de interés de la tela y se convirtieron a formato CSV. A partir de estos datasets se configuró un modelo que fuera capaz de aprender el comportamiento de la tela, adoptando poses de reposo y deformaciones realizadas por el colisionador sin colapsar. En el comienzo de la investigación se plantearon seis características (que conformarían 13 features) sobre los vértices, que podían ser relevantes para capturar la esencia de la tela en la simulación: la posición, el SDF (distancia a superficie colisionadora más cercana), la velocidad, el gradiente de SDF o normales respecto al colisionador, las coordenadas UVs y la máxima distancia de movimiento desde su origen en la malla de cada vértice. Finalmente, se resaltan las siguientes características como la clave para alcanzar el resultado:

- **Reducción de features:** De las características mencionadas, las tres más útiles para recrear el movimiento fueron la posición, SDF y velocidad. Los modelos finales cuentan únicamente con ellas como input.
- **Reurrencia:** El modelo óptimo resultó ser una RNN, red neuronal recurrente. Conocer el contexto histórico de las simulaciones es esencial para dotar al modelo de cierta percepción temporal y aumentar la coherencia de la simulación.
- **Unrolling:** A esta RNN se le aplicó la técnica de “unrolling”, que permite aplicar el algoritmo de retropropagación a través del tiempo (BPTT). De esta manera, el modelo infiere una secuencia de predicciones, corrigiendo su error de manera más acertada.

- **Noise:** Modificar los datos de entrenamiento aplicándoles ruido, ha sido clave para conseguir un modelo más robusto, que pueda recuperarse de pequeños errores en la inferencia sin colapsar por el error acumulado.
- **Grandes datasets:** En la medida de lo posible, los entrenamientos con grandes cantidades de datos han demostrado naturalmente preparar al modelo para una mayor variedad de escenarios.

El modelo entrenado se exportó a formato ONNX y se cargó de nuevo en Unity, a través del paquete Sents. El componente ClothML creado consiguió sustituir el componente de Cloth de Unity, replicando en la geometría un movimiento fiel al de una tela convencional a través del modelo cargado. No sólo se puede afirmar que el modelo alcanza resultados satisfactorios a través de su “vertex error” o distancia entre posiciones predichas y reales en el testing, sino que se confirma el resultado obtenido a efecto visual: se alcanza una simulación natural y fiable al comportamiento de la tela original.

Con respecto a la reducción de latencia y tasa de frames alcanzada, se consigue llegar a doblar la tasa de frames en un ordenador de X características. ClothML, el componente generado en esta investigación permite conducir la simulación a Xfps, mientras que la tela original la limita a quedarse en Xfps.

3.1.1. Limitaciones

El estudio resultante queda con las siguientes limitaciones:

- **Dataset pequeño** en comparación con el estado del arte. Para el nivel de simplicidad de la tela empleado en la simulación, el dataset generado ha sido suficiente para generar un comportamiento fiable a nivel visual. Sin embargo se podrían producir resultados mejores, así como menos dependencia con el objeto colisionador, introduciendo más diversidad de movimiento y número de frames totales. Por limitaciones de tiempo, presupuesto y hardware, en esta investigación se ha usado una media de 5000 frames por entrenamiento, mientras que en otras investigaciones que emplean bancos de simulaciones para entrenar sus modelos llegan a usar hasta 10^6 frames [Holden et al. \(2019\)](#).
- **Topología y generalización.** El modelo puede generar buenos resultados cuando la tela empleada en el entreamiento y simulación final coinciden. No es capaz de generalizar a otras topologías o mallas dinámicas.
- **Complejidad.** Como se menciona en el apartado del Dataset, debido a la dificultad para generarlas en Unity, el modelo no ha sido probado con telas más complejas o pegadas al cuerpo como camisetas o globos con forma. Podría no resultar óptimo e incluso no producir resultados aceptables en la inferencia.
- **Optimización.** Con objeto de producir los mejores resultados posibles en el modelo y en el aspecto visual, se ha enfocado la fuerza de trabajo en el

entrenamiento y no se ha llevado a cabo una optimización exhaustiva de la aplicación del modelo en Unity. Detalles como podría ser reducir el cálculo de distancias a los colisionadores no han entrado dentro del plazo de desarrollo disponible.

Todas estas limitaciones conducen a las siguientes propuestas de trabajo futuro.

3.2. Trabajo Futuro

El trabajo a futuro de este estudio se puede centrar en varios esfuerzos:

- **Extender los datasets** con más situaciones y probar otros **modelos más complejos**. Han quedado por probar modelos de interés como las CNNs, GNNS y redes encoder-decoder.
- Probar con **otros tipos de tela**, otros materiales, prendas pegadas al cuerpo, y potencialmente aplicar **técnicas híbridas** de animación, simulación e inteligencia artificial para conseguir mejores resultados. Un ejemplo sería combinar técnicas de skinning con ML, atando la tela a huesos y dejando la inercia y detalles como arrugas a la inteligencia artificial.
- Añadir la posibilidad de **extraer datasets de software especializado** como Maya o Blender, e incluso de bancos externos de interés. La obtención de mejores referencias habilitaría la prueba de geometrías más complejas y de mayor calidad.

Contribuciones Personales

Eva

Muchas cosas.

Pau

Muchas cosas.

Mik

Muchas cosas.

Bibliografía

The sciences, each straining in its own direction, have hitherto harmed us little; but some day the piecing together of dissociated knowledge will open up such terrifying vistas of reality, and of our frightful position therein, that we shall either go mad from the revelation or flee from the deadly light into the peace and safety of a new dark age.

H.P. Lovecraft, *The Call of Cthulhu*

ASOBO STUDIO. Microsoft flight simulator 2024. PC / Xbox Series X/S. Xbox Game Studios, 2024.

AVALANCHE SOFTWARE. Hogwarts legacy. PC / PlayStation 5 / Xbox Series X/S. Warner Bros. Games, 2023.

BEAMNG. Beamng.drive. PC. BeamNG, 2015.

BERGAMIN, K., CLAVET, S., HOLDEN, D. y FORBES, J. R. Drecon: data-driven responsive control of physics-based characters. *ACM Trans. Graph.*, vol. 38(6), 2019. ISSN 0730-0301.

BERTICHE, H., MADADI, M. y ESCALERA, S. Pbns: Physically based neural simulation for unsupervised garment pose space deformation. *ACM Transactions on Graphics (TOG)*, vol. 40(6), páginas 1–14, 2021a.

BERTICHE, H., MADADI, M. y ESCALERA, S. Neural cloth simulation. *ACM Transactions on Graphics (TOG)*, vol. 41(6), páginas 1–14, 2022.

BERTICHE, H., MADADI, M., TYLSON, E. y ESCALERA, S. DeePSD: Automatic Deep Skinning And Pose Space Deformation For 3D Garment Animation. En *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*, páginas 5451–5460. IEEE, Montreal, QC, Canada, 2021b. ISBN 978-1-6654-2812-5.

CHAUDHARY, M., POKHARIYA, C. y NARAIN, R. Towards generalized position-based dynamics. *arXiv preprint arXiv:2511.23131*, 2025.

- CHENTANEZ, N., MACKLIN, M., MÜLLER, M., JESCHKE, S. y KIM, T. Cloth and Skin Deformation with a Triangle Mesh Based Convolutional Neural Network. *Computer Graphics Forum*, vol. 39(8), páginas 123–134, 2020. ISSN 0167-7055, 1467-8659.
- GRIGOREV, A., THOMASZEWSKI, B., BLACK, M. J. y HILLIGES, O. HOOD: Hierarchical Graphs for Generalized Modelling of Clothing Dynamics. 2023. ArXiv:2212.07242 [cs].
- HECKER, C. Physics in computer games (title only). *Communications of the ACM*, vol. 43(7), páginas 34–39, 2000.
- HOLDEN, D., DUONG, B. C., DATTA, S. y NOWROUZEZAHRAI, D. Subspace neural physics: fast data-driven interactive simulation. En *Proceedings of the 18th annual ACM SIGGRAPH/Eurographics Symposium on Computer Animation*, páginas 1–12. ACM, Los Angeles California, 2019. ISBN 978-1-4503-6677-9.
- JIM HUGUNIN, U. Unite 2016 - gpu accelerated high resolution cloth simulation. <https://www.youtube.com/watch?v=kCGHX1LR3l8>, 2016. Accessed: (15/04/2026).
- KENNY ERLEBEN, K. H., JON SPORRING. *Physics-based Animation*. Charles River Media, 2005.
- KUNOS SIMULAZIONI. Assetto corsa. PC / PlayStation 4 / Xbox One. 505 Games, 2014.
- MACKLIN, M., MÜLLER, M. y CHENTANEZ, N. XPBD: position-based simulation of compliant constrained dynamics. En *Proceedings of the 9th International Conference on Motion in Games*, páginas 49–54. ACM, Burlingame California, 2016. ISBN 978-1-4503-4592-7.
- MAHMOOD, N., GHORBANI, N., TROJE, N. F., PONS-MOLL, G. y BLACK, M. J. Amass: Archive of motion capture as surface shapes. páginas 5442–5451, 2019.
- MILLINGTON, I. *Game Physics Engine Development*. CRC Press, 2007. ISBN 9781482267327.
- MÜLLER, M., HEIDELBERGER, B., HENNIX, M. y RATCLIFF, J. Position based dynamics. *Journal of Visual Communication and Image Representation*, vol. 18(2), páginas 109–118, 2007. ISSN 10473203.
- PATEL, C., LIAO, Z. y PONS-MOLL, G. Tailornet: Predicting clothing in 3d as a function of human pose, shape and garment style. En *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, páginas 7365–7375. 2020.
- PLAYGROUND GAMES. Forza horizon 6. PC / Xbox Series X/S. Xbox Game Studios, 2026.

- PROVOT, X. Deformation Constraints in a Mass Spring Model to Describe Rigid Cloth Behavior. 1995.
- PROVOT, X. ET AL. Deformation constraints in a mass-spring model to describe rigid cloth behaviour. En *Graphics interface*, páginas 147–147. Canadian Information Processing Society, 1995.
- ROCKSTAR STUDIOS. Red dead redemption 2. PlayStation 4 / Xbox One / PC. Rockstar Games, 2018.
- ROCKSTEADY STUDIOS. Batman: Arkham knight. PC / PlayStation 4 / Xbox One. Warner Bros. Interactive Entertainment, 2015.
- SALEN, K. y ZIMMERMAN, E. *Rules of Play: Game Design Fundamentals*. MIT Press, 2004.
- SANTESTEBAN, I., OTADUY, M. A. y CASAS, D. Snug: Self-supervised neural dynamic garments. En *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, páginas 8140–8150. 2022.
- SUPERIOR SOFTWARE AUDIOGENIC. Exile. BBC, Electron, 1988.
- UBISOFT MONTREAL. Assassin's creed unity. PC / PlayStation 4 / Xbox One. Ubisoft, 2014.
- VA, H., CHOI, M.-H. y HONG, M. Real-time cloth simulation using compute shader in unity3d for ar/vr contents. *Applied Sciences*, vol. 11(17), 2021. ISSN 2076-3417.

Licencia de uso del documento

Esta obra está bajo una licencia [Creative Commons](http://creativecommons.org/licenses/by-sa/4.0/legalcode) «Atribución-NoComercial-CompartirIgual 4.0 Internacional».



<http://creativecommons.org/licenses/by-sa/4.0/legalcode>.

Licencia de uso del código fuente

Los archivos de código fuente para generar este documento se encuentran en <https://github.com/FratosVR/Memoria-TFG> bajo la licencia [GPL-3.0](#)